

# Informe técnico

## Cierre de las capas Silver y Gold

*TFG - Análisis de cliente y geomarketing en moda íntima*

*Caso de estudio: Selmark S.L.U.*

|                          |                       |
|--------------------------|-----------------------|
| <b>Universidad</b>       | Alfonso X El Sabio    |
| <b>Escuela</b>           | Business & Tech       |
| <b>Grado</b>             | Ingeniería Matemática |
| <b>Fecha del informe</b> | Mayo de 2026          |
| <b>Entrega TFG</b>       | Junio de 2026         |

# 1. Resumen ejecutivo

Este informe documenta el cierre de las capas Silver y Gold del modelo de datos del Trabajo de Fin de Grado *Análisis de cliente y geomarketing en moda íntima - Caso de estudio Selmark S.L.U.* Tras la finalización de la fase de procesamiento, la arquitectura Medallion del proyecto queda completamente operativa, con las seis tablas Silver validadas individualmente y la tabla analítica única `gold.cliente_360` construida y verificada.

La tabla final reúne 3.492 clientes activos de la cartera de Selmark del cuatrienio 2022-2025, descritos por 56 variables organizadas en cinco bloques temáticos: identificación, geográfico, económico B2B, comportamiento y económico retail, y temporal. Sobre esta base se construirán los análisis del Trabajo de Fin de Grado: descripción general de la cartera, segmentación mediante clustering, geomarketing y análisis de churn.

## Cifras clave del proyecto

| Indicador                                      | Valor                                     |
|------------------------------------------------|-------------------------------------------|
| Clientes activos en la cartera                 | 3.492                                     |
| Mercado nacional / internacional               | 2.105 / 1.387 clientes                    |
| Líneas de pedido B2B procesadas                | 339.705 (silver) sobre 470.963 bronze     |
| Operaciones retail procesadas                  | 2.867.565 (silver) sobre 4.009.222 bronze |
| Códigos postales enriquecidos MOSAIC           | 6.457                                     |
| Cobertura MOSAIC sobre cartera nacional        | 96,82 % (2.038 / 2.105 clientes)          |
| Países identificados (cartera internac.)       | 53 (97,48 % cobertura)                    |
| Facturación B2B 2022-2025                      | 85,2 millones €                           |
| Facturación retail neta 2022-2025              | 84,9 millones €                           |
| Facturación total documentada                  | <b>≈ 170 millones €</b>                   |
| Columnas finales <code>gold.cliente_360</code> | 56 en 5 bloques temáticos                 |

Tabla 1. Cifras clave del proyecto al cierre de la capa Gold.

## 2. Arquitectura del modelo de datos

El modelo de datos del proyecto sigue el patrón **Medallion**, ampliamente adoptado en la comunidad de ingeniería de datos. La arquitectura organiza el procesamiento en tres capas sucesivas:

**Capa Bronze.** Ingesta directa de las fuentes operacionales facilitadas por Selmark, sin transformación. Esta capa garantiza la trazabilidad de cualquier transformación posterior.

**Capa Silver.** Limpieza, normalización, enriquecimiento y aplicación de reglas de negocio sobre cada fuente Bronze de forma independiente. Cada tabla Silver se valida individualmente antes de pasar a la siguiente capa.

**Capa Gold.** Integración de la información de todas las tablas Silver en una única tabla analítica con una fila por cliente, denominada `gold_cliente_360`. Constituye el resultado central del pipeline.


### Stack técnico

| Herramienta           | Función en el proyecto                           |
|-----------------------|--------------------------------------------------|
| DuckDB                | Motor analítico (almacenamiento y procesamiento) |
| Python 3.11           | Lenguaje de orquestación y análisis              |
| Jupyter Notebook      | Entorno de desarrollo y documentación            |
| pandas, numpy         | Manipulación de datos tabulares                  |
| holidays              | Calendario oficial español de festivos           |
| VS Code + Claude Code | Editor con asistencia al desarrollo              |
| Anaconda              | Gestión de entornos y dependencias               |

Tabla 2. Stack técnico empleado en el proyecto.

### Diagrama del flujo Bronze → Silver → Gold

El siguiente diagrama representa visualmente el flujo de transformación entre las tres capas, indicando para cada tabla su volumen final y las claves de unión empleadas para integrarlas en la tabla analítica.



Arquitectura Medallion — Selmark TFG · Proyecto cerrado tras capas Silver y Gold

Figura 1. Arquitectura Medallion del proyecto. Las flechas de Bronze a Silver indican las transformaciones principales aplicadas; las de Silver a Gold representan los joins que componen la tabla analítica final.

### 3. Capa Bronze

La capa Bronze recibe las cuatro fuentes operacionales en su formato CSV original, sin aplicar transformaciones. Su única responsabilidad es la carga inicial en DuckDB y la preservación íntegra del origen.

| Tabla Bronze              | Registros | Origen                                     |
|---------------------------|-----------|--------------------------------------------|
| bronze.dim_cliente        | 3.492     | Maestro de clientes del ERP                |
| bronze.fact_lineas_pedido | 470.963   | Líneas de pedido B2B formalizadas          |
| bronze.ventas_minoristas  | 4.009.222 | Operaciones de venta minorista (2019-2026) |
| bronze.mosaic             | 6.457     | Códigos postales enriquecidos por Experian |

Tabla 3. Tablas que componen la capa Bronze con su volumetría inicial.

### 4. Capa Silver

La capa Silver aplica limpieza, normalización y enriquecimiento sobre cada tabla Bronze de forma independiente. Cada subsección a continuación documenta el esquema final de la tabla, las transformaciones aplicadas y las validaciones superadas.

#### 4.1 silver.dim\_cliente

Tabla maestra de clientes con 3.492 registros. Incorpora la clasificación entre los mercados NACIONAL e INTERNACIONAL mediante cuatro reglas combinadas (A, B, C y D), donde la regla D rescata explícitamente a doce clientes españoles mal clasificados por inconsistencias del ERP.

| Columna                  | Tipo    | Descripción                              |
|--------------------------|---------|------------------------------------------|
| id_cliente               | VARCHAR | Identificador único del cliente          |
| nombre_cliente           | VARCHAR | Razón social                             |
| nombre_comercial_cliente | VARCHAR | Nombre comercial                         |
| direccion_cliente        | VARCHAR | Dirección postal                         |
| localidad_cliente        | VARCHAR | Localidad                                |
| codigo_postal_original   | VARCHAR | Código postal original del ERP           |
| codigo_postal_norm       | VARCHAR | Código postal normalizado (5 dígitos)    |
| codigo_provincia_cliente | VARCHAR | Código de provincia                      |
| es_cliente_espanol       | BOOLEAN | Flag de cliente español (reglas A/B/C/D) |
| tipo_mercado             | VARCHAR | NACIONAL o INTERNACIONAL                 |

Tabla 4. Esquema de silver.dim\_cliente (10 columnas, 3.492 filas).

#### 4.2 silver.mapeo\_paises

Tabla auxiliar construida durante la investigación documentada en el notebook 03b, que mapea los códigos de provincia internacionales con sus países correspondientes. Cubre 53 países distintos con una cobertura del 97,48 % de la cartera internacional.

| Columna                  | Tipo    | Descripción                         |
|--------------------------|---------|-------------------------------------|
| codigo_provincia_cliente | VARCHAR | Código de provincia internacional   |
| pais                     | VARCHAR | Nombre del país asociado            |
| region                   | VARCHAR | Región o subdivisión administrativa |

Tabla 5. Esquema de silver.mapeo\_paises.

### 4.3 silver.fact\_lineas\_pedido

Tabla de pedidos B2B formalizados, con 339.705 líneas tras aplicar el filtro temporal (2022-2025), el descarte de pedidos anulados y la validación del rango razonable de *días hasta entrega* (0 a 180 días). La decisión metodológica clave es el uso de `MAX(importe_total_pedido) GROUP BY id_pedido` para calcular la facturación, en respuesta al hallazgo del ratio de inflación 7,47x documentado en el notebook 04.

| Columna principal    | Tipo    | Descripción                                 |
|----------------------|---------|---------------------------------------------|
| id_pedido            | VARCHAR | Identificador único del pedido              |
| id_cliente           | VARCHAR | Cliente asociado (FK a dim_cliente)         |
| fecha_pedido         | DATE    | Fecha de formalización del pedido           |
| fecha_entrega        | DATE    | Fecha de entrega real o prevista            |
| dias_hasta_entrega   | INTEGER | Diferencia entre fecha de entrega y pedido  |
| esta_anulado         | BOOLEAN | Flag de pedido anulado                      |
| id_producto          | VARCHAR | Identificador del producto                  |
| cantidad             | DOUBLE  | Unidades de la línea                        |
| importe_total_pedido | DOUBLE  | Importe total del pedido (a nivel cabecera) |
| importe_total_linea  | DOUBLE  | Importe de la línea                         |
| [+ otros campos]     | -       | IVA, base imponible, etc.                   |

Tabla 6. Esquema de silver.fact\_lineas\_pedido (columnas principales). 339.705 filas.

#### 4.4 silver.ventas\_minoristas

Tabla del canal retail con 2.867.565 operaciones tras filtrado temporal. La actualización del ERP permitió incorporar las dos columnas económicas (`importe_total` y `importe_total_con_descuento`) con cobertura del 100 %, además del campo derivado `descuento_aplicado`.

| Columna                                                                                        | Tipo    | Descripción                                                     |
|------------------------------------------------------------------------------------------------|---------|-----------------------------------------------------------------|
| <code>fecha_venta</code>                                                                       | DATE    | Fecha de la operación                                           |
| <code>id_cliente</code>                                                                        | VARCHAR | Cliente (FK a <code>dim_cliente</code> )                        |
| <code>cod_modelo</code> , <code>cod_color</code> , <code>cod_serie</code> , <code>talla</code> | VARCHAR | Códigos identificativos del producto                            |
| <code>desc_modelo</code> , <code>desc_color</code> , <code>desc_serie</code>                   | VARCHAR | Descripciones textuales del producto                            |
| <code>id_sku</code>                                                                            | VARCHAR | Identificador derivado (modelo-color-talla)                     |
| <code>id_tipo_pedido</code> , <code>desc_tipo_pedido</code>                                    | VARCHAR | Canal de venta y su descripción                                 |
| <code>es_devolucion</code>                                                                     | BOOLEAN | Flag de devolución (códigos 3, 10, 12, D77/88, EDEV, DPER, ZCR) |
| <code>cantidad_neta</code>                                                                     | BIGINT  | Unidades netas de la operación                                  |
| <code>cantidad_ventas_sin_devoluciones</code>                                                  | BIGINT  | Unidades de venta (excluye devoluciones)                        |
| <code>importe_total</code>                                                                     | DOUBLE  | Importe bruto en euros                                          |
| <code>importe_total_con_descuento</code>                                                       | DOUBLE  | Importe neto en euros                                           |
| <code>descuento_aplicado</code>                                                                | DOUBLE  | Diferencia entre importe bruto y neto                           |
| <code>id_temporada</code>                                                                      | BIGINT  | Identificador de temporada del producto                         |

Tabla 7. Esquema de `silver.ventas_minoristas` (19 columnas, 2.867.565 filas).

#### 4.5 silver.mosaic

Tabla de enriquecimiento sociodemográfico que cruza por código postal con la cartera nacional. Para evitar coincidencias accidentales con códigos postales internacionales de igual formato numérico, el JOIN con esta tabla se restringe en la capa Gold a clientes con `tipo_mercado` = 'NACIONAL'.

| Columna                             | Tipo    | Descripción                                  |
|-------------------------------------|---------|----------------------------------------------|
| <code>codigo_postal_norm</code>     | VARCHAR | Código postal normalizado (clave de cruce)   |
| <code>grupo_mosaic</code>           | VARCHAR | Grupo MOSAIC dominante (11 valores posibles) |
| <code>peso_grupo</code>             | DOUBLE  | Proporción de hogares del grupo dominante    |
| <code>segmento_mosaic</code>        | VARCHAR | Segmento fino dentro del grupo               |
| <code>peso_segmento</code>          | DOUBLE  | Proporción de hogares del segmento           |
| <code>renta_media</code>            | DOUBLE  | Renta media estimada del código postal       |
| <code>perfil_premium</code>         | BOOLEAN | Flag perfil premium                          |
| <code>perfil_familiar_joven</code>  | BOOLEAN | Flag perfil familiar joven                   |
| <code>perfil_turistico</code>       | BOOLEAN | Flag perfil turístico                        |
| <code>perfil_rural</code>           | BOOLEAN | Flag perfil rural                            |
| <code>perfil_precio_sensible</code> | BOOLEAN | Flag perfil sensible al precio               |

*Tabla 8. Esquema de silver.mosaic (11 columnas, 6.457 filas).*



## 4.6 silver.tiempo

Dimensión temporal con 1.461 días (cuatro años naturales) generada con Python. Incluye variables estándar de calendario y atributos específicos del sector textil (temporadas de moda, rebajas y eventos comerciales clave).

| Columna                         | Tipo    | Descripción                                |
|---------------------------------|---------|--------------------------------------------|
| fecha                           | DATE    | Fecha (clave primaria)                     |
| anio, mes, trimestre            | INTEGER | Variables estándar de calendario           |
| dia_mes, dia_semana, num_semana | INTEGER | Variables estándar de calendario           |
| nombre_mes, nombre_dia_semana   | VARCHAR | Nombres en castellano                      |
| temporada_moda                  | VARCHAR | PV, OI o REBAJAS                           |
| es_festivo_nacional             | BOOLEAN | Flag de día festivo (biblioteca holidays)  |
| es_rebajas                      | BOOLEAN | Flag de periodo de rebajas (enero y julio) |
| es_black_friday                 | BOOLEAN | Flag del Black Friday                      |
| es_san_valentin                 | BOOLEAN | Flag de San Valentín                       |
| es_navidad                      | BOOLEAN | Flag de Navidad                            |
| es_dia_madre                    | BOOLEAN | Flag del Día de la Madre                   |

Tabla 9. Esquema de silver.tiempo (1.461 filas, una por día).

## 5. Capa Gold - Detalle de gold.cliente\_360

La tabla `gold.cliente_360` integra la información de todas las tablas Silver en una única tabla analítica con una fila por cliente. Consta de 3.492 filas y 56 columnas organizadas en cinco bloques temáticos que se documentan a continuación, indicando para cada columna su tabla Silver de origen.

### Bloque 1 - Identificación (9 columnas)

Origen: `silver.dim_cliente` y `silver.mapeo_paises`.

| Columna                  | Tipo    | Origen Silver                                |
|--------------------------|---------|----------------------------------------------|
| id_cliente               | VARCHAR | silver.dim_cliente                           |
| nombre_cliente           | VARCHAR | silver.dim_cliente                           |
| nombre_comercial_cliente | VARCHAR | silver.dim_cliente                           |
| localidad_cliente        | VARCHAR | silver.dim_cliente                           |
| codigo_postal_norm       | VARCHAR | silver.dim_cliente                           |
| codigo_provincia_cliente | VARCHAR | silver.dim_cliente                           |
| es_cliente_espanol       | BOOLEAN | silver.dim_cliente                           |
| tipo_mercado             | VARCHAR | silver.dim_cliente                           |
| pais                     | VARCHAR | silver.mapeo_paises (vía JOIN por provincia) |

## Bloque 2 - Geográfico (12 columnas)

Origen: `silver.mosaic`, mediante LEFT JOIN restringido a `tipo_mercado = 'NACIONAL'` para evitar coincidencias accidentales entre códigos postales españoles e internacionales con el mismo formato.

| Columna                | Tipo    | Origen Silver                 |
|------------------------|---------|-------------------------------|
| grupo_mosaic           | VARCHAR | silver.mosaic                 |
| peso_grupo             | DOUBLE  | silver.mosaic                 |
| segmento_mosaic        | VARCHAR | silver.mosaic                 |
| peso_segmento          | DOUBLE  | silver.mosaic                 |
| renta_media            | DOUBLE  | silver.mosaic                 |
| perfil_premium         | BOOLEAN | silver.mosaic                 |
| perfil_familiar_joven  | BOOLEAN | silver.mosaic                 |
| perfil_turistico       | BOOLEAN | silver.mosaic                 |
| perfil_rural           | BOOLEAN | silver.mosaic                 |
| perfil_precio_sensible | BOOLEAN | silver.mosaic                 |
| tiene_mosaic           | BOOLEAN | Calculado (flag de presencia) |
| [+1 columna auxiliar]  | -       | Derivada                      |

## Bloque 3 - Económico B2B (6 columnas)

Origen: `silver.fact_lineas_pedido`. Las agregaciones aplican `MAX(importe_total_pedido) GROUP BY id_pedido` para capturar el total real del pedido.

| Columna                  | Tipo    | Origen Silver                                     |
|--------------------------|---------|---------------------------------------------------|
| num_pedidos_b2b          | BIGINT  | silver.fact_lineas_pedido (COUNT DISTINCT)        |
| facturacion_b2b          | DOUBLE  | silver.fact_lineas_pedido (SUM de MAX por pedido) |
| ticket_medio_b2b         | DOUBLE  | Derivado                                          |
| iva_aporteado_b2b        | DOUBLE  | silver.fact_lineas_pedido                         |
| base_imponible_total_b2b | DOUBLE  | silver.fact_lineas_pedido                         |
| tiene_facturacion_b2b    | BOOLEAN | Calculado (flag de presencia)                     |

## Bloque 4 - Comportamiento y económico retail (17 columnas)

Origen: `silver.ventas_minoristas`. Incluye 12 métricas operativas y las 5 nuevas métricas económicas retail incorporadas tras la actualización del ERP.

| Columna                                   | Tipo    | Origen Silver                                                                      |
|-------------------------------------------|---------|------------------------------------------------------------------------------------|
| <code>num_operaciones</code>              | BIGINT  | <code>silver.ventas_minoristas</code> (sin devoluciones)                           |
| <code>unidades_vendidas</code>            | BIGINT  | <code>silver.ventas_minoristas</code>                                              |
| <code>num_operaciones_devol</code>        | BIGINT  | <code>silver.ventas_minoristas</code> (devoluciones)                               |
| <code>unidades_devueltas</code>           | BIGINT  | <code>silver.ventas_minoristas</code>                                              |
| <code>pct_ratio_devoluciones</code>       | DOUBLE  | Calculado                                                                          |
| <code>num_skus_distintos</code>           | BIGINT  | <code>silver.ventas_minoristas</code> (COUNT DISTINCT <code>id_sku</code> )        |
| <code>num_modelos_distintos</code>        | BIGINT  | <code>silver.ventas_minoristas</code>                                              |
| <code>num_temporadas_activas</code>       | BIGINT  | <code>silver.ventas_minoristas</code>                                              |
| <code>pct_pedidos_temporada</code>        | DOUBLE  | <code>silver.ventas_minoristas</code> ( <code>tipo='1'</code> )                    |
| <code>pct_pedidos_repeticion</code>       | DOUBLE  | <code>silver.ventas_minoristas</code> ( <code>tipo='2'</code> )                    |
| <code>canal_principal</code>              | VARCHAR | <code>silver.ventas_minoristas</code> (MODE)                                       |
| <code>es_cuenta_corporativa</code>        | BOOLEAN | Calculado                                                                          |
| <code>facturacion_retail_bruta_eur</code> | DOUBLE  | <code>silver.ventas_minoristas</code> ( <code>importe_total</code> )               |
| <code>facturacion_retail_neta_eur</code>  | DOUBLE  | <code>silver.ventas_minoristas</code> ( <code>importe_total_con_descuento</code> ) |
| <code>ticket_medio_retail_eur</code>      | DOUBLE  | Calculado                                                                          |
| <code>importe_devoluciones_eur</code>     | DOUBLE  | <code>silver.ventas_minoristas</code>                                              |
| <code>descuento_total_eur</code>          | DOUBLE  | <code>silver.ventas_minoristas</code>                                              |
| <code>tiene_actividad_minorista</code>    | BOOLEAN | Calculado (flag de presencia)                                                      |

## Bloque 5 - Temporal (12 columnas)

Origen: `silver.ventas_minoristas` cruzada con `silver.tiempo`. Las métricas se calculan excluyendo devoluciones. La variable `recencia_dias` servirá como proxy directo del estado de churn en el análisis del capítulo 7.

| Columna                              | Tipo   | Origen Silver                                                         |
|--------------------------------------|--------|-----------------------------------------------------------------------|
| <code>fecha_primera_operacion</code> | DATE   | <code>silver.ventas_minoristas</code> (MIN <code>fecha_venta</code> ) |
| <code>fecha_ultima_operacion</code>  | DATE   | <code>silver.ventas_minoristas</code> (MAX <code>fecha_venta</code> ) |
| <code>antiguedad_dias</code>         | BIGINT | Calculado (referencia 2025-12-31)                                     |
| <code>recencia_dias</code>           | BIGINT | Calculado (referencia 2025-12-31)                                     |
| <code>meses_activo</code>            | BIGINT | Calculado (COUNT DISTINCT meses)                                      |
| <code>frecuencia_mensual</code>      | DOUBLE | Calculado                                                             |
| <code>pct_operaciones_pv</code>      | DOUBLE | <code>silver.tiempo</code> ( <code>temporada_moda</code> = 'PV')      |
| <code>pct_operaciones_oi</code>      | DOUBLE | <code>silver.tiempo</code> ( <code>temporada_moda</code> = 'OI')      |
| <code>pct_operaciones_rebajas</code> | DOUBLE | <code>silver.tiempo</code> ( <code>es_rebajas</code> )                |
| <code>op_black_friday</code>         | BIGINT | <code>silver.tiempo</code> ( <code>es_black_friday</code> )           |
| <code>op_san_valentin</code>         | BIGINT | <code>silver.tiempo</code> ( <code>es_san_valentin</code> )           |
| [+1 columna auxiliar]                | -      | Derivada                                                              |

## 6. Claves de unión entre tablas

Esta sección documenta de forma explícita las claves utilizadas para unir las seis tablas de la capa Silver durante la construcción de `gold.cliente_360`. La comprensión de estas uniones es esencial para la trazabilidad del modelo y para futuras extensiones del mismo.

### 6.1 Mapa global de uniones

La tabla siguiente recoge, para cada par de tablas que se unen en el pipeline, la columna concreta empleada como clave, el tipo de JOIN utilizado y las condiciones adicionales que se aplican.

| Tabla origen                           | Tabla destino                 | Clave de unión                                | Tipo de JOIN            | Filtro adicional                   |
|----------------------------------------|-------------------------------|-----------------------------------------------|-------------------------|------------------------------------|
| <code>silver.dim_cliente</code>        | <code>gold.cliente_360</code> | <code>id_cliente</code>                       | Base (CREATE TABLE)     | —                                  |
| <code>silver.mapeo_paises</code>       | <code>gold.cliente_360</code> | <code>codigo_provincia_cliente</code>         | LEFT JOIN               | Solo INTERNACIONAL                 |
| <code>silver.mosaic</code>             | <code>gold.cliente_360</code> | <code>codigo_postal_norm</code>               | LEFT JOIN               | Solo NACIONAL                      |
| <code>silver.fact_lineas_pedido</code> | <code>gold.cliente_360</code> | <code>id_cliente</code>                       | LEFT JOIN agregado      | GROUP BY <code>id_cliente</code>   |
| <code>silver.ventas_minoristas</code>  | <code>gold.cliente_360</code> | <code>id_cliente</code>                       | LEFT JOIN agregado (B4) | GROUP BY <code>id_cliente</code>   |
| <code>silver.ventas_minoristas</code>  | <code>silver.tiempo</code>    | <code>fecha_venta</code> = <code>fecha</code> | INNER JOIN (en CTE)     | <code>es_devolucion</code> = FALSE |
| [resultado anterior]                   | <code>gold.cliente_360</code> | <code>id_cliente</code>                       | LEFT JOIN agregado (B5) | GROUP BY <code>id_cliente</code>   |

Tabla 10. Mapa de uniones entre las tablas Silver durante la construcción de `gold.cliente_360`.

### 6.2 Detalle de cada unión por bloque

**Bloque 1 - Identificación.** La tabla base de `gold.cliente_360` es `silver.dim_cliente` (3.492 filas, una por cliente), por lo que no hay JOIN en este bloque sino una sentencia `CREATE TABLE AS SELECT`. La columna `pais` se incorpora a continuación mediante un `LEFT JOIN` contra `silver.mapeo_paises` usando como clave `codigo_provincia_cliente`. Este JOIN solo afecta a clientes internacionales; para los nacionales el valor se asigna como literal 'España'.

**Bloque 2 - Geográfico.** Se realiza un `LEFT JOIN` entre la tabla base y `silver.mosaic` usando como clave `codigo_postal_norm`. La condición `AND tipo_mercado = 'NACIONAL'` se incluye dentro de la cláusula `ON` del JOIN, no como un `WHERE` posterior, para evitar coincidencias accidentales entre códigos postales españoles e internacionales con idéntico formato numérico (caso documentado del CP 28100 que existe tanto en Madrid como en la ciudad italiana de Novara).

**Bloque 3 - Económico B2B.** Las métricas se calculan en una CTE (Common Table Expression) intermedia que agrupa `silver.fact_lineas_pedido` por `id_cliente`. La CTE aplica internamente `MAX(importe_total_pedido) GROUP BY id_pedido` para evitar la inflación de importes por la granularidad documentada en el notebook 04. La CTE resultante se une a la tabla base mediante `LEFT JOIN` por `id_cliente`.

**Bloque 4 - Comportamiento y económico retail.** Mismo patrón que el Bloque 3: una CTE intermedia agrupa `silver.ventas_minoristas` por `id_cliente`, calculando las 17 métricas operativas y económicas (volumen, devoluciones, facturación retail, ticket medio, descuentos). La CTE se une mediante `LEFT JOIN` por `id_cliente`. Las métricas incluyen el filtro `es_devolucion = FALSE` para las variables que reflejan compra real, separando las devoluciones en variables específicas.

**Bloque 5 - Temporal.** Es el JOIN más complejo del modelo. Dentro de una CTE intermedia se realiza primero un `INNER JOIN` entre `silver.ventas_minoristas` y `silver.tiempo` usando la igualdad `fecha_venta = fecha`, con el filtro `es_devolucion = FALSE`. El resultado se agrupa por `id_cliente` para calcular las métricas temporales y se une finalmente a la tabla base mediante `LEFT JOIN`.

### 6.3 Validación de la integridad referencial

Tras cada JOIN se han realizado validaciones específicas para confirmar la integridad referencial del modelo. Las principales conclusiones son las siguientes:

| Validación                                 | Resultado                                         |
|--------------------------------------------|---------------------------------------------------|
| Cobertura silver.mapeo_paises              | 1.352 de 1.387 internacionales = 97,48 %          |
| Cobertura silver.mosaic (cartera nacional) | 2.038 de 2.105 = 96,82 %                          |
| Cobertura silver.fact_lineas_pedido        | 3.083 clientes con facturación B2B (88,29 %)      |
| Cobertura silver.ventas_minoristas         | 3.054 clientes con actividad retail (87,46 %)     |
| Huérfanos en silver.ventas_minoristas      | 1 cliente (id 32437, sin registro en dim_cliente) |
| Huérfanos en silver.fact_lineas_pedido     | 0 (integridad referencial perfecta)               |

*Tabla 11. Resultados de las validaciones de integridad referencial tras los JOINS.*

La cobertura observada es elevada en todas las uniones. El único huérfano detectado (id\_cliente 32437 en silver.ventas\_minoristas) corresponde a una única operación de noviembre de 2025 sin registro en la dimensión maestra, atribuible a un retraso en la sincronización del ERP. Su impacto sobre el modelo es despreciable y se documenta como caso conocido.

## 7. Hallazgos metodológicos relevantes

Durante la construcción del modelo se han adoptado decisiones metodológicas que merecen ser documentadas explícitamente, tanto por su impacto cuantitativo en los resultados como por su valor pedagógico para futuras revisiones del proyecto.

### 7.1 Regla D - Rescate explícito de doce clientes españoles

Tras detectar que El Corte Inglés aparecía clasificado como cliente internacional con país 'Sin identificar', se realizó una investigación específica (notebooks 03b y 03c) que reveló doce clientes españoles erróneamente clasificados por inconsistencias del ERP. La solución adoptada fue añadir una cuarta regla de clasificación que rescata explícitamente a estos doce clientes por su `id_cliente`, agrupados en tres patrones: cuentas corporativas españolas sin datos geográficos (ECI, Ventas Amazon, Ventas Mitele), personas con provincia 036 sin datos completos, y clientes con localidad y CP españoles pero provincia errónea. El cambio incrementó la cartera nacional de 2.093 a **2.105 clientes**.

### 7.2 Granularidad de `fact_lineas_pedido` y uso de MAX por pedido

El análisis comparativo entre los campos a nivel línea y a nivel pedido reveló una divergencia sistemática: el 55,03 % de las líneas presenta valores distintos entre `importe_total_linea` e `importe_total_pedido`, y la suma agregada del segundo supera al del primero en un factor próximo a 7,5. Este hallazgo indica que la exportación del ERP contiene una sola línea representativa por pedido, mientras que el campo cabecera conserva el total real. La decisión adoptada es calcular la facturación B2B mediante `MAX(importe_total_pedido) GROUP BY id_pedido`, lo que captura el volumen real del negocio (85,2 M€ documentados).

### 7.3 Restricción del JOIN MOSAIC a la cartera nacional

Una primera versión del JOIN con `silver.mosaic` producía falsos positivos: clientes internacionales cuyo código postal coincidía numéricamente con un código español obtenían enriquecimiento incorrecto (por ejemplo, el código italiano 28100 de Novara con el 28100 de Madrid). La solución fue añadir la condición `tipo_mercado = 'NACIONAL'` dentro del propio JOIN, restringiendo el cruce exclusivamente a clientes españoles.

### 7.4 Identificación de cuentas técnicas en B2B

Durante el análisis del Top 10 de facturación B2B se identificaron dos cuentas con volúmenes de pedidos extraordinariamente elevados que, al corresponder a personas físicas, resultan incompatibles con un patrón realista de compra: REGO, JAVIER (50.730 pedidos en el cuatrienio) y HERREROS CASTRO, SORAYA (92.460 pedidos). Su perfil sugiere que se trata de cuentas técnicas u operativas del ERP. Estas cuentas se mantienen en `gold.cliente_360` pero requerirán tratamiento explícito en la fase de clustering.

## 8. Exportación a CSV

Como cierre de la fase de procesamiento, las siete tablas finales se han exportado a archivos CSV individuales para garantizar la portabilidad de los datos, conservar una copia de respaldo en formato abierto independiente de DuckDB, y disponer de los archivos necesarios para los anexos del Trabajo de Fin de Grado.

### Configuración técnica de la exportación

| Parámetro         | Valor                         |
|-------------------|-------------------------------|
| Formato           | CSV (texto delimitado)        |
| Delimitador       | Punto y coma ( ; )            |
| Separador decimal | Punto (.)                     |
| Codificación      | UTF-8 (por defecto en DuckDB) |
| Valores nulos     | Cadena vacía                  |
| Booleanos         | True / False literales        |
| Cabecera          | Incluida (HEADER)             |

Tabla 12. Configuración técnica adoptada en la exportación a CSV.

### Archivos generados

| Ruta                               | Filas     | Contenido                   |
|------------------------------------|-----------|-----------------------------|
| data/silver/dim_cliente.csv        | 3.492     | Maestro de clientes         |
| data/silver/mapeo_paises.csv       | ≈ 100     | Mapeo provincia → país      |
| data/silver/fact_lineas_pedido.csv | 339.705   | Pedidos B2B (silver)        |
| data/silver/ventas_minoristas.csv  | 2.867.565 | Operaciones retail (silver) |
| data/silver/mosaic.csv             | 6.457     | Enriquecimiento Experian    |
| data/silver/tiempo.csv             | 1.461     | Dimensión calendario        |
| data/gold/cliente_360.csv          | 3.492     | Tabla analítica final       |

Tabla 13. Archivos exportados al cierre de la capa Gold.

El conjunto total exportado pesa aproximadamente 500 MB en disco, de los cuales el archivo `ventas_minoristas.csv` representa cerca del 90 % del volumen. Para su lectura con tildes preservadas en Microsoft Excel, se recomienda importarlo desde el menú Datos → Obtener datos en lugar de abrirlo con doble clic.

## 9. Sigüientes pasos del proyecto

Con la capa Gold cerrada y exportada, queda completada la fase de procesamiento del Trabajo de Fin de Grado. Los siguientes capítulos del TFG, ya plenamente desbloqueados, corresponderán a las fases de análisis cuantitativo:



| Capítulo TFG | Título                                | Notebook    | Contenido principal                  |
|--------------|---------------------------------------|-------------|--------------------------------------|
| Capítulo 4   | Análisis descriptivo de la cartera    | Notebook 09 | Caracterización general              |
| Capítulo 5   | Segmentación mediante clustering      | Notebook 11 | K-Means + validación con silhouette  |
| Capítulo 6   | Geomarketing y perfiles MOSAIC        | Notebook 13 | Cruce con perfiles sociodemográficos |
| Capítulo 7   | Análisis de churn y riesgo de pérdida | Notebook 14 | Segmentación por recencia            |
| Capítulo 8   | Conclusiones, recomendaciones y ROI-  |             | Síntesis y análisis de retorno       |

*Tabla 14. Plan de los capítulos analíticos pendientes del TFG.*

Cada uno de estos capítulos partirá directamente de la tabla `gold.cliente_360`, sin necesidad de regenerar las capas Bronze ni Silver. La arquitectura modular del proyecto garantiza que cualquier ajuste futuro en el modelo (incorporación de nuevos clientes, actualización de los datos del ERP, refresco del enriquecimiento MOSAIC) podrá realizarse re-ejecutando únicamente los notebooks afectados, preservando el resto del trabajo realizado.

*- Fin del informe -*