

Análisis de series temporales y forecasting SARIMA

Notebook 10

TFG	Análisis de cliente y geomarketing en moda íntima
Caso de estudio	Selmark S.L.U.
Universidad	Alfonso X El Sabio
Escuela	Business & Tech
Grado	Ingeniería Matemática

Capítulo del TFG	Capítulo 4.bis — Series temporales
Notebook asociado	10_series_temporales_sarima.ipynb
Sugerido por	Diego (tutor académico)
Validado por	Manuel Ojeda (responsable Selmark)
Fecha del informe	Mayo de 2026 — versión final
Figuras incluidas	10 figuras del notebook (ejecución de mayo 2026)

1. Resumen e introducción

Este informe documenta el análisis de series temporales aplicado a la facturación retail semanal de Selmark durante el cuatrienio 2022-2025, realizado en el notebook 10 del Trabajo de Fin de Grado. El análisis fue sugerido por Diego, tutor académico del TFG, tras revisar la evolución mensual de la facturación del Capítulo 4, con el objetivo de aplicar técnicas formales de modelado temporal que aportasen rigor estadístico y capacidad predictiva al estudio.

El notebook integra seis técnicas estadísticas clásicas que se aplican de forma sucesiva: la construcción de la serie temporal a partir de los datos de transacción, la descomposición STL en componentes interpretables, el análisis de autocorrelaciones, los tests formales de estacionariedad, el ajuste de modelos SARIMA mediante grid search con validación temporal, y el forecasting de la facturación esperada para 2026 con sus correspondientes intervalos de confianza.

Pregunta de investigación del notebook

¿Es posible modelar matemáticamente el comportamiento semanal de la facturación retail de Selmark, identificar sus componentes internos (tendencia, estacionalidad, ruido) y producir una predicción defendible para 2026, junto con su intervalo de confianza?

Aportaciones principales del notebook

#	Aportación	Hallazgo cuantitativo
1	Descomposición STL	La estacionalidad anual explica el 94,90 % de la varianza
2	Decaimiento del negocio cuantificado	Caída del -6,9 % en facturación retail entre 2022 y 2025
3	Identificación de anomalías	7 semanas con comportamiento atípico ($>3\sigma$)
4	Iteración formal de 36 modelos	Grid search con validación train/test
5	Criterio metodológico refinado	Selección por RMSE + significancia estadística
6	Forecasting cuantitativo 2026	15,95 M € con IC al 95 % [6,86 ; 37,08] M €

Tabla 1. Síntesis de las aportaciones del notebook 10 al Trabajo de Fin de Grado.

2. Construcción de la serie temporal

La primera fase del análisis consiste en transformar los datos de transacción granular almacenados en la tabla **silver.ventas_minoristas** en una serie temporal regular con frecuencia semanal, agregada por número de semana ISO. La elección de la granularidad semanal, sugerida explícitamente por el tutor académico, ofrece dos ventajas relevantes respecto a una granularidad mensual: en primer lugar, multiplica por más de cuatro el número de observaciones disponibles (**208 semanas frente a 48 meses**), proporcionando una base estadística más robusta para el ajuste posterior del modelo; en segundo lugar, permite que eventos comerciales muy localizados temporalmente, como San Valentín o el Black Friday, se aislen como semanas concretas en lugar de diluirse en un agregado mensual.

En lenguaje sencillo

en vez de mirar cuánto facturó Selmark cada mes, miramos cuánto facturó cada semana. Así pasamos de tener 48 puntos de datos a 208, lo cual es mucho más útil para el modelo. Y además, cada evento comercial (San Valentín, Black Friday) se ve como una semana concreta y no se mezcla con el resto del mes.




Figura 1. Serie temporal semanal de la facturación retail 2022-2025 (sin cuentas técnicas).

Lo que muestra el gráfico

La inspección visual de la serie revela tres rasgos fundamentales que orientarán las decisiones de modelado posteriores. En primer lugar, una **estacionalidad anual muy marcada**: cada año se repite un patrón similar con picos sistemáticos en las semanas de San Valentín, rebajas de enero, rebajas de julio y arranque de septiembre, y valles consistentes en abril-mayo. En segundo lugar, una **alta variabilidad semana a semana** derivada de los eventos comerciales puntuales. En tercer lugar, y este es uno de los hallazgos más relevantes del análisis, una **tendencia descendente leve pero sostenida** en el nivel general de la serie.

Hallazgo crítico: el negocio está decayendo

Los totales anuales del retail confirman un decaimiento sostenido de la facturación durante el cuatrienio: **2022 (17,42 M €) → 2023 (16,98 M €) → 2024 (16,48 M €) → 2025 (16,22 M €)**, lo que supone una caída acumulada del **−6,9 %** en cuatro años, o aproximadamente **−2 %** anual de media. Este hallazgo, aunque de magnitud modesta en términos absolutos, requiere ser comunicado explícitamente al equipo de Selmark por su carácter estratégico: la estabilidad estadística de la serie no implica estabilidad económica.

3. Descomposición STL

La **descomposición STL** (Seasonal-Trend decomposition using Loess) es una técnica estadística que separa una serie temporal en tres componentes aditivos: la tendencia subyacente, el patrón estacional y los residuos. A diferencia de la descomposición clásica, STL utiliza regresión local (LOESS) para estimar las componentes, lo que la hace robusta frente a outliers y especialmente adecuada para series con eventos comerciales muy marcados como la facturación retail de Selmark. Se aplica con un periodo estacional $s = 52$, correspondiente al ciclo anual sobre la frecuencia semanal.

En lenguaje sencillo

STL es como descomponer una orquesta en sus instrumentos. La música que oyes (la serie original) se separa en: el bajo continuo (la tendencia, que sube o baja despacio), la melodía repetitiva (la estacionalidad, que se repite cada año) y los detalles inesperados (los residuos, que no se explican por las dos primeras).




Figura 2. Descomposición STL de la facturación retail semanal en sus tres componentes: tendencia (LOESS), estacionalidad anual y residuos.

Qué muestra cada panel

El **primer panel** reproduce la serie original ya analizada. El **segundo panel** muestra la tendencia extraída por LOESS, prácticamente plana en términos visuales (el eje y varía entre 308 K € y 325 K €), aunque con una pendiente ligeramente descendente. El **tercer panel** es el más rico: muestra el patrón estacional anual repetido cuatro veces, con picos y valles

claramente diferenciados. El **cuarto panel** contiene los residuos, es decir, lo que no logra explicar la combinación de tendencia y estacionalidad.

Distribución de la varianza explicada

Componente	% varianza	Interpretación
Tendencia	0,05 %	Casi plana — el negocio cambia muy lentamente
Estacionalidad	94,90 %	Dominante — el calendario manda
Residuos	23,51 %	Variabilidad puntual asociada a eventos

Tabla 2. Distribución de la varianza de la serie por componente.

La suma de los tres porcentajes excede el 100 % (118,46 %), lo que merece una aclaración metodológica: en STL las componentes no son estrictamente ortogonales y presentan covarianza residual entre sí, lo que permite que sus varianzas sumen más que la varianza total. Esta es una característica conocida del algoritmo, no un error de cálculo.

Hallazgo central de la descomposición

El **94,90 %** de la variabilidad de la facturación semanal se explica únicamente por la estacionalidad anual. Esto significa que Selmark es un negocio profundamente estacional, en el que el calendario determina la mayor parte del comportamiento. La tendencia, aunque cuantitativamente pequeña, está sistemáticamente orientada a la baja.

Patrón estacional extraído

Patrón estacional anual extraído por STL
Componente estacional promediado por semana ISO del año (52 semanas)




Figura 3. Patrón estacional anual extraído por STL. Cada punto representa el efecto medio de esa semana del año sobre la facturación.

El gráfico anterior promedia el componente estacional por número de semana ISO del año, ofreciendo una visión limpia del calendario comercial implícito de Selmark. Los picos identificados confirman la intuición desarrollada en el Capítulo 4 mediante el análisis de

eventos comerciales: **San Valentín (semana 6)** es un evento de alto impacto, las **rebajas de julio (semana 28-30)** generan otro pico claro, y el **arranque de septiembre (semana 37)** constituye el periodo de mayor actividad anual con un efecto estacional cercano a +700 K € sobre la base. El **Black Friday (semana 47)** aparece como un periodo de impacto negativo sobre la facturación, contrario al patrón observado en otros sectores.

Detección de anomalías

El componente de residuos de la descomposición permite identificar semanas cuyo comportamiento no se explica ni por la tendencia ni por la estacionalidad. Aplicando un criterio estadístico estándar (umbral de **3 desviaciones estándar** sobre los residuos), se identifican siete semanas anómalas en el cuatrienio analizado.

Semana	Residuo	Posible explicación
7-ago-2023	+ 674 K €	Pico atípico de verano
28-feb-2022	+ 646 K €	Cierre fuerte tras San Valentín 2022
22-ene-2024	+ 463 K €	Rebajas anómalamente buenas
11-sep-2023	– 417 K €	Caída sospechosa de septiembre 2023
4-sep-2023	– 410 K €	Caída sospechosa de septiembre 2023
9-sep-2024	+ 392 K €	Compensación al año siguiente
12-jun-2023	+ 368 K €	Pico inusual de junio

Tabla 3. Semanas anómalas detectadas con residuo absoluto superior a 3σ.




Figura 4. Residuos de la descomposición STL con las 7 anomalías marcadas en dorado (umbral $\pm 3\sigma$).

Especialmente llamativas son las **dos semanas consecutivas de septiembre de 2023** con caídas significativas (–417 K € y –410 K €), lo que sugiere un evento operativo puntual de Selmark durante ese periodo (posible problema de stock, incidencia logística o cambio comercial) que merecería una investigación específica con el equipo. Esta capacidad de detección de anomalías es una de las contribuciones prácticas del análisis para la operativa del negocio.

4. Análisis de autocorrelaciones

Una vez descompuesta la serie, el siguiente paso consiste en cuantificar las relaciones temporales entre las observaciones de la serie a distintos retardos. Este análisis es fundamental para seleccionar el tipo de modelo paramétrico adecuado en la fase posterior. Se calculan dos funciones complementarias: la **función de autocorrelación ACF**, que mide la correlación entre la serie y sus retardos sucesivos, y la **función de autocorrelación parcial PACF**, que mide la correlación marginal una vez controlados los retardos intermedios.

En lenguaje sencillo

queremos saber cuánto se parece la facturación de una semana a la de las semanas anteriores. ACF nos dice si la semana 27 se parece a la 26 (lag 1), a la 25 (lag 2), etc. PACF refina eso eliminando influencias indirectas. Si la semana 27 se parece a la misma semana del año anterior (lag 52), es porque hay memoria estacional en la serie.




Figura 5. Funciones ACF y PACF de la serie semanal. Las bandas rojas marcan el límite de significación al 95 %, y la línea dorada destaca el retardo estacional anual (lag 52).

Interpretación de los resultados

La función **ACF** revela una estructura clara con tres rasgos significativos. Los retardos cortos (lag 1 a 4) presentan valores positivos y por encima de la banda de significación, indicando que la facturación de cada semana se correlaciona con la de las semanas inmediatamente anteriores. Los retardos intermedios (lag 9 a 18) muestran valores negativos también significativos, característicos de una estructura de anti-estacionalidad semestral.

Finalmente, el **retardo 52 presenta una correlación positiva muy fuerte**: la facturación de una semana es muy parecida a la de la misma semana del año anterior.

La función **PACF** presenta valores significativos concentrados en los primeros retardos (especialmente lag 1) y en el entorno del lag 52, con un decaimiento más rápido en los retardos intermedios. Esta combinación —ACF persistente con caídas estacionales y PACF concentrada en pocos retardos— es la firma estadística característica de los procesos que requieren modelado SARIMA con componente estacional anual.

Conclusión del análisis ACF/PACF

El análisis ACF/PACF confirma estadísticamente lo que la descomposición STL mostraba visualmente: la facturación de Selmark presenta dos estructuras de dependencia temporal: una de corto plazo (la semana actual depende de las recientes) y otra estacional anual (la semana actual depende de la misma semana del año anterior). Este resultado justifica formalmente la elección del modelo **SARIMA con periodo $s = 52$** en la fase de modelado.

5. Tests de estacionariedad

Antes de ajustar un modelo SARIMA es necesario determinar si la serie es **estacionaria**, propiedad que implica que sus características estadísticas (media, varianza, autocorrelación) son constantes a lo largo del tiempo. Una serie no estacionaria requiere ser diferenciada antes del modelado. Para obtener una conclusión robusta se aplican dos tests con hipótesis nulas opuestas: el test **ADF** (Augmented Dickey-Fuller), que asume bajo H_0 la presencia de raíz unitaria (no estacionariedad), y el test **KPSS** (Kwiatkowski-Phillips-Schmidt-Shin), que asume bajo H_0 la estacionariedad.

En lenguaje sencillo

queremos saber si los patrones que vemos en el pasado se van a repetir en el futuro. Si la serie es estacionaria, sí: la media se mantiene estable, la variabilidad es similar, y los ciclos se repiten. Si no lo es, no podemos confiar en que el pasado prediga el futuro de forma fiable.

Resultados de los tests

Test	Hipótesis nula H_0	p-valor	Decisión	Conclusión
ADF (Augmented Dickey-Fuller)	Serie tiene raíz unitaria	0,0000	Se rechaza H_0	Serie es ESTACIONARIA
KPSS	Serie es estacionaria	0,1000	No se rechaza H_0	Serie es ESTACIONARIA

Tabla 4. Resultados de los tests de estacionariedad sobre la serie original.

Ambos tests, partiendo de hipótesis nulas opuestas, llegan a la misma conclusión: la serie es estacionaria al nivel de significación del 5 %. Este resultado, aparentemente contradictorio con la observación de una tendencia descendente, es perfectamente coherente desde el punto de vista estadístico: la magnitud absoluta de la tendencia es muy pequeña en comparación con la variabilidad estacional, de manera que la media de la serie es estable en torno a un valor que disminuye muy lentamente. Lo importante es que los patrones se repiten de forma reconocible y, por tanto, son modelables.

Diferenciación estacional aplicada

Aunque la serie es estacionaria en niveles, el componente estacional anual ($s=52$) requiere ser diferenciado de forma específica antes del modelado SARIMA. La diferenciación estacional consiste en calcular, para cada semana, la diferencia con respecto a la misma semana del año anterior (es decir, restar el valor del lag 52). Esta operación elimina el patrón anual repetitivo y deja una serie centrada en cero, lista para el ajuste del modelo.

Serie con diferenciación estacional $D=1$, $s=52$

Diferencia entre cada semana y su análoga del año anterior




Figura 6. Serie con diferenciación estacional $D=1$, $s=52$. Diferencia entre cada semana y su análoga del año anterior.

6. Ajuste del modelo SARIMA

Esta sección constituye el **núcleo metodológico del notebook**. El modelo SARIMA (Seasonal AutoRegressive Integrated Moving Average) es una generalización del clásico ARIMA que incorpora componentes estacionales. Su especificación general es **SARIMA(p,d,q)(P,D,Q,s)**, donde los seis parámetros enteros describen los órdenes autorregresivos, de diferenciación y de media móvil tanto para la parte regular como para la estacional, y **s** es el periodo estacional. La elección de los seis parámetros es el problema central del modelado.

En lenguaje sencillo

un modelo SARIMA es una receta matemática con varios ingredientes. Algunos ingredientes miran al pasado reciente (parte AR), otros miran las diferencias entre periodos (parte I), otros miran los errores pasados (parte MA), y los componentes 'estacionales' hacen lo mismo pero respecto al mismo periodo del año anterior. El reto es saber qué proporción de cada ingrediente hay que usar.

Estrategia: grid search con validación train/test

Siguiendo la sugerencia explícita de **Manuel Ojeda**, responsable del proyecto en Selmark, se ha implementado un esquema de selección de modelos por **iteración**: probar múltiples combinaciones de parámetros y quedarse con la que minimiza el error de predicción sobre datos no vistos. Para ello se divide la serie en dos partes: un conjunto de entrenamiento (**2022-2024, 157 semanas**) sobre el que se ajusta cada modelo, y un conjunto de test (**2025, 51 semanas**) sobre el que se evalúa la capacidad predictiva. El error de predicción se mide mediante el RMSE (raíz del error cuadrático medio) y el MAE (error absoluto medio).

Se han probado **36 modelos candidatos**, cubriendo todas las combinaciones razonables del componente regular (p, d, q desde 0 hasta 2) tanto sin transformación como con transformación logarítmica previa de la serie. El componente estacional se ha fijado en (1, 1, 0, 52) por la evidencia del análisis ACF/PACF previo. La iteración completa tarda aproximadamente seis minutos en una máquina de uso personal.




Figura 7. Ranking de los 15 mejores modelos SARIMA (de los 36 candidatos), ordenados por RMSE sobre el conjunto de test 2025. El ganador por RMSE puro aparece destacado en color dorado; el top 5 en verde.

7. Refinamiento del criterio de selección

Esta sección documenta una de las **decisiones metodológicas más importantes del trabajo**. La iteración sobre los 36 candidatos seleccionó por RMSE puro el modelo **SARIMA(0,1,2)(1,1,0,52) con transformación logarítmica (M22)**, con un RMSE de 135.162 € sobre el test. Sin embargo, una inspección rigurosa del modelo revela problemas serios que comprometen su validez estadística.

Diagnóstico del ganador ingenuo (M22)

Parámetro	Coef.	Error est.	p-valor	Significativo
ma.L1	-1,1049	105,938	0,992	No ✗
ma.L2	+0,1049	11,153	0,992	No ✗
ar.S.L52	-0,5244	0,068	0,000	Sí ✓
sigma ²	0,1836	19,447	0,992	No ✗

Tabla 5. Coeficientes del modelo SARIMA(0,1,2)(1,1,0,52) + log (ganador ingenuo).

Sólo el componente autorregresivo estacional **ar.S.L52 resulta estadísticamente significativo**. Los dos componentes de media móvil regular presentan p-valores próximos a 1 y errores estándar enormes (105 y 11 frente a coeficientes de magnitud unitaria), lo que indica que los parámetros no están identificados de forma estable. Adicionalmente, el coeficiente $ma.L1 = -1,1049$ se sitúa fuera del rango teórico de invertibilidad $[-1, +1]$. Este patrón es característico de modelos **sobreparametrizados**: el algoritmo converge a una solución numérica, pero ésta no es estadísticamente válida.

En lenguaje sencillo

el modelo 'ganador' tiene 4 parámetros, pero 3 de ellos no aportan información útil (su valor podría ser cualquier número y el modelo daría predicciones similares). Es como si la receta dijera 'añade entre -209 y +207 gramos de algo, no importa cuánto'. Si presentamos esto al tribunal, nos van a preguntar inmediatamente.

Criterio combinado de selección

Criterio refinado de selección

Se selecciona el modelo de **menor RMSE sobre el conjunto de test** entre aquellos cuyos coeficientes estructurales sean **todos estadísticamente significativos al 95 % de confianza**.

Este criterio combina dos principios fundamentales del modelado estadístico riguroso: la **capacidad predictiva** (medida por el RMSE sobre datos no vistos, alineada con la sugerencia original de Manuel) y la **identificabilidad estadística** (los parámetros estimados deben ser distinguibles del azar). Aplicar ambos criterios simultáneamente respeta el principio de parsimonia (Occam) y garantiza que el modelo seleccionado sea defendible tanto desde la perspectiva predictiva como desde la inferencial.

Modelo ganador refinado

De los 36 candidatos del grid search, sólo 8 modelos cumplen el criterio de tener todos los coeficientes estructurales significativos. El ganador refinado es **M0L: SARIMA(0,0,0)(1,1,0,52) con transformación logarítmica**, con RMSE de **136.757 €** sobre el test, sólo un **1,18 % superior** al ganador ingenuo. Esta penalización marginal se compensa ampliamente por la mayor robustez, parsimonia e interpretabilidad del modelo final.

Parámetro	Coef.	Error est.	p-valor	Significativo
ar.S.L52	−0,5204	0,063	0,000	Sí ✓
sigma ²	0,1853	0,020	0,000	Sí ✓

Tabla 6. Coeficientes del modelo final SARIMA(0,0,0)(1,1,0,52) + log. Ambos parámetros son significativos al 99,9 %.

8. Diagnóstico del modelo final

Una vez ajustado el modelo $\text{SARIMA}(0,0,0)(1,1,0,52) + \log$ sobre la serie completa (2022-2025), es preciso validar su comportamiento mediante un diagnóstico exhaustivo de los residuos. Idealmente, los residuos de un modelo bien especificado deben aproximarse a un **ruido blanco gaussiano**: no deben presentar autocorrelación significativa en ningún retardo y su distribución debe ser compatible con la normalidad.




Figura 8. Diagnóstico de los residuos del modelo ganador en cuatro paneles: serie temporal de residuos, histograma, Q-Q plot frente a la distribución normal, y ACF de los residuos.

Tests aplicados

Test	H_0	p-valor	Resultado
Ljung-Box (lag 10)	Residuos no autocorrelacionados	0,573	✓ Se cumple
Ljung-Box (lag 20)	Residuos no autocorrelacionados	0,847	✓ Se cumple
Ljung-Box (lag 52)	Residuos no autocorrelacionados	0,996	✓ Se cumple
Jarque-Bera	Residuos normales	0,0013	✗ No se cumple

Tabla 7. Resultados del diagnóstico de residuos del modelo ganador.

Interpretación

El test de **Ljung-Box** arroja p-valores muy elevados (0,57 a 0,99) en los tres retardos evaluados, lo que confirma que **no existe evidencia de autocorrelación residual**: el modelo

ha capturado adecuadamente la estructura temporal de la serie. Esta es la propiedad más importante para validar la corrección del ajuste.

El test de **Jarque-Bera**, con p-valor de 0,0013, rechaza la hipótesis de normalidad de los residuos. Este resultado, aunque indeseable desde el punto de vista teórico ideal, es frecuente en series económicas con presencia de eventos comerciales extremos (San Valentín, rebajas) que generan colas pesadas en la distribución de errores. No invalida el modelo pero implica que los intervalos de confianza calculados sobre supuestos gaussianos deben interpretarse con cierta cautela: la cobertura empírica real puede diferir ligeramente de la cobertura nominal del 95 %.

Resumen del diagnóstico

El modelo cumple satisfactoriamente con el requisito principal del diagnóstico (**ausencia de autocorrelación residual**) y reconoce honestamente su única limitación (residuos con colas más pesadas que la normal). Esta combinación de cumplimiento estadístico y honestidad metodológica fortalece la defensibilidad académica del modelo.

9. Predicción de la facturación 2026

La aplicación práctica del modelo SARIMA es el cálculo del **forecast**: la predicción de la facturación retail semanal para las 52 semanas del año 2026, acompañada de los intervalos de confianza que reflejan la incertidumbre creciente conforme el horizonte se aleja del último dato observado.




Figura 9. Forecast SARIMA para 2026 sobre el histórico 2022-2025. La banda dorada interior representa el intervalo de confianza al 80 %, la banda exterior el intervalo al 95 %.

Resultados cuantitativos

Métrica	Valor
Facturación predicha 2026 (puntual)	15,95 M €
Intervalo de confianza al 80 %	[10,37 ; 24,54] M €
Intervalo de confianza al 95 %	[6,86 ; 37,08] M €
Variación esperada respecto a 2025	–1,65 %
RMSE del modelo (sobre test 2025)	136.757 €
MAE del modelo (sobre test 2025)	98.954 €
Contraste con tendencia histórica	Continúa el decaimiento (~–2 % anual)

Tabla 8. Síntesis de la predicción del modelo para el año 2026.

Facturación anual histórica y predicción 2026

La barra dorada incluye intervalo de confianza al 95% (predicción SARIMA)




Figura 10. Comparativa de los totales anuales históricos (2022-2025) y la predicción puntual 2026 con su intervalo de confianza al 95 %.

La predicción puntual de **15,95 millones de euros** para 2026 es coherente con el patrón de decaimiento observado en el cuatrienio histórico: la variación esperada del **-1,65 %** respecto a 2025 está perfectamente alineada con la media de variación interanual observada del **-2 %** aproximadamente. El modelo no proyecta un cambio cualitativo del comportamiento del negocio sino la continuidad de la dinámica actual.

Limitaciones honestas del forecast

Los intervalos de confianza son **notablemente amplios**: el intervalo al 95 % cubre desde 6,86 hasta 37,08 millones de euros, un rango que refleja con honestidad la incertidumbre asociada al ejercicio. Esta amplitud se debe a tres factores principales: el horizonte de predicción es muy largo (52 semanas) en relación con la longitud de la serie histórica (208 semanas), la serie presenta una alta variabilidad puntual asociada a eventos comerciales extremos, y los residuos del modelo no son perfectamente gaussianos. La predicción puntual sigue siendo la mejor estimación disponible, pero la cobertura realista del intervalo debe interpretarse con cautela.

10. Conclusiones y aportaciones al TFG

El notebook 10 aporta **cuatro contribuciones diferenciales** al Trabajo de Fin de Grado, plenamente alineadas con el carácter cuantitativo del Grado en Ingeniería Matemática y con la solicitud expresa del tutor académico y del responsable del proyecto en Selmark.

Aportaciones académicas

En primer lugar, la descomposición STL confirma cuantitativamente lo que el análisis descriptivo del Capítulo 4 había evidenciado visualmente: la facturación retail de Selmark presenta una estructura dominada por una componente estacional anual (94,90 % de la varianza), una tendencia subyacente descendente moderada y un residuo ruidoso pero acotado, con siete semanas anómalas identificadas como casos de interés.

En segundo lugar, el análisis de autocorrelaciones demuestra estadísticamente la presencia de dos estructuras temporales de dependencia (corto plazo y estacional anual) y justifica formalmente la elección del modelo SARIMA con periodo $s = 52$, frente a alternativas más simples como ARIMA o modelos de suavizado exponencial.

En tercer lugar, los tests de estacionariedad (ADF y KPSS aplicados de forma complementaria) caracterizan rigurosamente las propiedades estadísticas de la serie y aportan el rigor metodológico esperable en un trabajo cuantitativo.

En cuarto lugar, el modelo SARIMA seleccionado mediante grid search con criterio combinado proporciona una herramienta de forecasting cuantitativa con intervalos de confianza, capaz de predecir la facturación retail semanal del año 2026 con un único parámetro estructural estadísticamente significativo y un diagnóstico de residuos correcto.

Aportaciones para Selmark

- 1. Predicción cuantitativa 2026:** facturación esperada de 15,95 millones de euros, con continuidad del patrón de decaimiento.
- 2. Identificación del decaimiento estructural:** el retail cae aproximadamente un 2 % anual; este hallazgo merece comunicación explícita al equipo directivo.
- 3. Confirmación cuantitativa del calendario comercial:** San Valentín como evento clave, septiembre como periodo de mayor actividad anual, Black Friday como periodo negativo.
- 4. Detección de anomalías:** siete semanas concretas que merecen revisión operativa específica.

Conexión con los capítulos sucesivos

Capítulo	Aportación del notebook 10
Capítulo 7 (Control)	El decaimiento (STL) sugiere posible fuga progresiva de cartera. Los umbrales de recencia se calibrarán teniendo en cuenta la
Capítulo 8 (Recomendaciones)	El forecast (Recorre 15,95 M€) constituye la línea base sobre la que se calculará el ROI de las acciones comerciales propuest

Tabla 9. Conexiones del notebook con los capítulos posteriores del TFG.

— *Fin del informe del Notebook 10* —