

CAPÍTULO 5

Segmentación de la cartera mediante clustering K-Means

Notebooks 11a (clustering) + 11b (caracterización)

TFG — Análisis de cliente y geomarketing en moda íntima

Caso de estudio: Selmark S.L.U.

Concepto	Detalle
Universidad	Alfonso X El Sabio
Escuela	Business & Tech
Grado	Ingeniería Matemática
Capítulo del TFG	Capítulo 5 — Segmentación
Notebooks	11a (clustering) + 11b (caracterización)
Sugerido por	Diego (tutor académico)
Validado por	Manuel Ojeda (responsable Selmark)
Fecha del informe	Mayo de 2026

1. Resumen ejecutivo

El Capítulo 5 del Trabajo de Fin de Grado aplica técnicas avanzadas de aprendizaje no supervisado para segmentar la cartera de 3.084 clientes activos de Selmark en grupos comportamentalmente homogéneos. El análisis se desarrolla en dos notebooks complementarios: el 11a implementa el clustering propiamente dicho (preparación de datos, PCA, determinación del número óptimo de clusters, K-Means y comparativa metodológica con clustering jerárquico de Ward), mientras que el 11b caracteriza los segmentos obtenidos mediante índices de afinidad, importancia de variables con Random Forest binario y asignación de naming comercial fundamentado en evidencia cuantitativa.

La metodología combinada responde a la orientación expresa del tutor académico del TFG, que recomendó utilizar la ley del codo para determinar el número de clusters (esperando un rango de 5-6 segmentos), aplicar PCA con visualización mediante biplots de los vectores de variables sobre la nube de puntos, calcular índices comparativos respecto a la media global por variable y cluster, complementar la caracterización descriptiva con Random Forest para identificar las variables más discriminantes de cada segmento, y asignar nombres comerciales evocadores a cada cluster.

Pregunta de investigación del capítulo

¿Es posible identificar grupos diferenciados de clientes en la cartera activa de Selmark basándose exclusivamente en su comportamiento de compra, y caracterizar cada grupo de forma cuantitativamente robusta para informar las decisiones comerciales de retención, captación y rentabilización?

Resultados principales

Concepto	Resultado
Perímetro analizado	3.084 clientes activos (sin cuentas técnicas)
Variables conductuales	8 indicadores (recencia, frecuencia, ticket, etc.)
Componentes PCA seleccionadas	4 componentes que explican el 85,87 % de la varianza
Número de clusters	6 (k=6 elegido por Davies-Bouldin y Calinski-Harabasz)
Adjusted Rand Index	0,5513 con clustering jerárquico Ward (validación cruzada)
Random Forest accuracy media	0,9829 (clusters muy distinguibles estadísticamente)
Hallazgo Pareto	Los 2 clusters de mayor valor concentran el 90,1 % de la facturación
Confirmación renta	La renta del CP NO discrimina entre clusters (varianza intra > entre)

Tabla 1. Síntesis cuantitativa de los principales resultados del Capítulo 5.

2. Preparación de los datos

La preparación de los datos para el clustering parte de la tabla agregada `gold.cliente_360` construida en los notebooks anteriores del TFG. El perímetro de análisis se restringe a los 3.084 clientes con actividad económica documentada en el cuatrienio 2022-2025, excluyendo las tres cuentas técnicas previamente identificadas (REGO, HERREROS y ECI) y los 405 clientes sin actividad económica registrada. Esta exclusión sistemática, ya documentada como decisión D1 en el Capítulo 4, evita que clientes especiales o inactivos distorsionen la estructura de los segmentos resultantes.

Selección de las variables conductuales

Las ocho variables seleccionadas para el clustering son indicadores conductuales que capturan las cuatro dimensiones fundamentales del comportamiento del cliente: la dimensión temporal (recencia en días y meses con actividad documentada), la dimensión económica (ticket medio retail), la dimensión estructural del comportamiento de compra (porcentaje de pedidos de temporada, porcentaje de repetición, número de canales distintos utilizados) y la dimensión de calidad de la relación (ratio de devoluciones, frecuencia mensual de compra). La elección de variables exclusivamente conductuales y no sociodemográficas se fundamenta en el hallazgo del Capítulo 4 según el cual la correlación entre la renta del código postal y la facturación del cliente resultaba estadísticamente nula ($r=+0,0043$ con $p\text{-valor}=0,8566$).

En lenguaje sencillo

En vez de agrupar a los clientes por su renta, su edad o su perfil sociodemográfico (que no funcionan según el descriptivo), los agrupamos por cómo se comportan: ¿hace cuánto compraron?, ¿cuánto gastan por compra?, ¿prefieren colecciones nuevas o reposiciones?, ¿devuelven mucho?, etc.

Validación experimental de la selección de variables

La lista inicial incluía nueve variables candidatas, pero la matriz de correlaciones de Spearman reveló que `facturacion_combinada` presentaba una correlación de +0,82 con `meses_activo`, indicando solapamiento informacional. Para resolver empíricamente si esta redundancia afectaba a la calidad del clustering, se desarrolló un notebook auxiliar (`11a_experimentos.ipynb`) que comparó cuatro configuraciones manteniendo idéntico el resto del pipeline: el baseline con las nueve variables, $k=5$ en lugar de $k=6$, eliminación de `facturacion_combinada` con ocho variables, y sustitución de `RobustScaler` por `StandardScaler`.

Los resultados validaron empíricamente las decisiones de $k=6$ y `RobustScaler` (ambas alternativas empeoraban claramente todas las métricas), pero mostraron que la eliminación de `facturacion_combinada` mejoraba el Adjusted Rand Index entre K-Means y clustering jerárquico en un 69,5 % (de 0,3252 a 0,5513), con pérdidas marginales en las métricas internas (Silhouette -3,8 %, Davies-Bouldin +1,2 %). Esta mejora drástica en la coincidencia entre dos algoritmos con criterios de optimización distintos indica que la estructura latente de los datos se identifica con mayor robustez al eliminar la información redundante. En consecuencia, se adopta la configuración con ocho variables como punto de partida del clustering.

Matriz de correlaciones de Spearman entre variables conductuales

Verde-azul: correlación positiva fuerte · Rosa: correlación negativa fuerte




Figura 1. Matriz de correlaciones de Spearman entre las variables conductuales. Verde-azul: correlación positiva fuerte · Rosa: correlación negativa fuerte. Tras eliminar facturacion_combinada no quedan pares con $|p| > 0,80$.

Distribución de las variables tras transformación y escalado

Las variables con asimetría superior a 2,0 se transforman con log1p para reducir el sesgo, y todas las variables se escalan con RobustScaler (basado en mediana e IQR), una elección robusta frente a la presencia de outliers comerciales típicos en datos de retail B2B. La figura siguiente muestra el resultado del preprocesamiento sobre cada una de las ocho variables conductuales.

Distribución de las variables tras transformación y escalado

Variables con asimetría > 2,0 transformadas con log1p, escaladas con RobustScaler




Figura 2. Distribución de las ocho variables conductuales tras la transformación $\log_{1p}$ (para asimetría > 2,0) y el escalado con RobustScaler. La distribución bimodal de `pct_pedidos_temporada` y `pct_pedidos_repeticion` anticipa la estructura latente que detectarán los clusters.

3. Análisis de componentes principales

El Análisis de Componentes Principales transforma el conjunto de ocho variables conductuales en un nuevo sistema de coordenadas formado por componentes principales ortogonales entre sí, ordenadas según la varianza que capturan. Su aplicación previa al K-Means responde a tres objetivos complementarios: mitigar la maldición de la dimensionalidad mejorando la convergencia del algoritmo, eliminar el ruido asociado a las componentes de menor varianza, y crear un espacio bidimensional o tridimensional adecuado para la visualización mediante biplots.

En lenguaje sencillo

PCA es como hacer un zip de los datos. Tomamos 8 variables que se solapan parcialmente entre sí y las comprimimos en 4 ejes "súper-variables" que capturan casi toda la información (el 85,87 %) sin la redundancia.

Selección del número de componentes

Aplicando el criterio estándar de la literatura sobre clustering aplicado (umbral de varianza acumulada del 80 %), se calculan las ocho componentes principales sobre los datos escalados con RobustScaler y se seleccionan las cuatro primeras, que en conjunto explican el 85,87 % de la varianza total. Esta reducción dimensional del 50 % (de 8 a 4 dimensiones) conservando casi el 86 % de la información representa un excelente equilibrio entre simplificación del espacio de trabajo y conservación de la estructura latente.




Figura 3. Scree plot · varianza explicada por componente principal. Se seleccionan 4 componentes que acumulan el 85,9 % de la varianza, superando el umbral del 80 %.

Interpretación comercial de las cuatro componentes

El análisis de los loadings de las cuatro componentes seleccionadas revela una estructura interpretable que admite una lectura económica directa, facilitando la interpretación posterior de los clusters identificados.

Componente	Variables dominantes (loading)	Interpretación
PC1 (33,9 %)	ticket_medio_retail_eur (+0,94)	Eje del valor por compra
PC2 (22,6 %)	frecuencia_mensual (+0,56) · pct_temporada (+0,41) · pct_repetición (-0,42)	Eje de intensidad y estructura de compra
PC3 (16,7 %)	pct_ratio_devoluciones (+0,84)	Eje de calidad de la relación
PC4 (12,7 %)	recencia (+0,52) · pct_repetición (-0,49)	Eje temporal y de estabilidad

Tabla 2. Interpretación comercial de las cuatro componentes principales seleccionadas.

Loadings de las componentes principales

Contribución de cada variable conductual a cada componente principal seleccionada




Figura 4. Heatmap de loadings de las cuatro componentes principales. Cada celda muestra la contribución de la variable conductual original a cada componente seleccionada.

4. Determinación del número óptimo de clusters

La elección del número de clusters k es la decisión más crítica del algoritmo K-Means. La literatura especializada coincide en que ninguna métrica individual debe usarse de forma aislada, ya que cada índice optimiza un criterio matemático específico que puede no alinearse con la interpretación comercial deseada. Se aplican aquí cuatro métricas complementarias siguiendo la práctica recomendada por Chicco et al. (2025, PeerJ Computer Science): el método del codo sobre la inercia (sugerido explícitamente por el tutor académico), el coeficiente de Silhouette, el índice de Davies-Bouldin y el índice de Calinski-Harabasz.




Figura 5. Las cuatro métricas de validación calculadas sobre el rango $k=2..10$. El método del codo se interpreta visualmente; las otras tres marcan su óptimo con línea dorada. Davies-Bouldin y Calinski-Harabasz apuntan a $k=6$ como óptimo.

Decisión: $k = 6$ clusters

Las cuatro métricas no convergen a un único óptimo: el Silhouette score y el codo numérico apuntan a $k=3$, mientras que Davies-Bouldin y Calinski-Harabasz apuntan a $k=6$. Esta divergencia, frecuente en datos reales de naturaleza comercial donde la estructura latente presenta cierto solapamiento, requiere un criterio de desempate que combine evidencia estadística, recomendación experta y validación experimental.

Se adopta $k=6$ por cuatro razones convergentes. En primer lugar, las dos métricas más informativas para clusters convexos según la literatura reciente —Davies-Bouldin y Calinski-Harabasz— coinciden ambas en $k=6$, lo que convierte el empate aparente en una mayoría cualificada. En segundo lugar, el tutor académico sugirió explícitamente un rango objetivo de 5-6 clusters para garantizar la interpretabilidad comercial. En tercer lugar, la validación experimental del notebook

11a_experimentos demostró que con $k=6$ el Adjusted Rand Index entre K-Means y clustering jerárquico de Ward alcanza 0,55 (validación cruzada robusta). En cuarto lugar, la solución con $k=3$ resulta comercialmente pobre: agrupa al 76 % de la cartera en un único cluster heterogéneo, perdiendo capacidad discriminativa para la posterior segmentación de marketing.

Compensación de la elección

La penalización en Silhouette al elegir $k=6$ sobre $k=3$ (0,3065 frente a 0,3708, una diferencia de 0,064 puntos en una escala teórica de -1 a +1) es modesta y compensada con creces por las ganancias en interpretabilidad, robustez metodológica y alineación con la dirección académica del trabajo.

5. Aplicación de K-Means y biplot

Con $k=6$ fijado, se aplica el algoritmo K-Means sobre el espacio de las cuatro componentes principales. El procedimiento iterativo minimiza la suma de cuadrados intra-cluster (WCSS) alternando dos fases: asignación de cada cliente al centroide más próximo y recálculo de los centroides como la media de los clientes asignados. Para mitigar el sesgo de inicialización se ejecutan 50 inicializaciones distintas y se selecciona la mejor según la inercia final. La reproducibilidad se garantiza mediante una semilla fija (`random_state=42`).

Distribución de la cartera por cluster (K-Means, $k=6$)

Cartera total clusterizada: 3,084 clientes activos




Figura 6. Distribución de la cartera por cluster (K-Means, $k=6$). Cartera total clusterizada: 3.084 clientes activos.

Biplot PCA · PC1 vs PC2 con los 6 clusters de K-Means

Bolitas: clientes proyectados · Flechas: vectores de las variables conductuales




Figura 7. Biplot PCA · PC1 vs PC2 con los 6 clusters de K-Means. Bolitas: clientes proyectados · Flechas: vectores de las variables conductuales.

Lectura del biplot según las reglas estándar

La interpretación del biplot se rige por tres reglas documentadas en la literatura sobre análisis multivariante (Statistics Globe 2023; Plotiv 2026). La dirección de cada vector indica hacia dónde crecen los valores de esa variable. La longitud refleja cuánta varianza se conserva en el plano PC1-PC2. Los ángulos entre vectores informan sobre las correlaciones entre variables originales: vectores en la misma dirección corresponden a variables positivamente correlacionadas, vectores opuestos a correlación negativa, y vectores ortogonales a independencia.

En el biplot destaca la posición casi horizontal del vector de `ticket_medio_retail_eur`, coherente con su dominio absoluto en PC1: los clusters situados a la derecha presentan tickets elevados, mientras que los de la izquierda presentan tickets bajos. La oposición visual entre `pct_pedidos_temporada` y `pct_pedidos_repeticion`, prácticamente alineados en sentidos contrarios, confirma gráficamente la correlación negativa documentada en la matriz de correlaciones ($\rho = -0,77$).




Figura 8. Biplot adicional · PC1 vs PC3. PC1+PC2 explican solo el 56,5 % → se añade esta visualización con PC3 para apreciar mejor el eje de devoluciones (que carga sobre PC3).

Visualización 3D de los clusters • PC1, PC2, PC3

Varianza acumulada explicada por las 3 componentes: 73,2%




Figura 9. Visualización 3D de los clusters • PC1, PC2, PC3. Varianza acumulada explicada por las 3 componentes: 73,2 %.

Validación con clustering jerárquico Ward

Como validación metodológica se ha aplicado un clustering jerárquico aglomerativo con criterio de enlace Ward sobre el mismo espacio de componentes principales y con el mismo número de clusters. La comparativa con la partición producida por K-Means arroja un Adjusted Rand Index de 0,5513, valor de coincidencia moderada que indica que ambos algoritmos identifican una estructura latente común. K-Means y Ward optimizan criterios distintos —minimización de la varianza intra-cluster y minimización del incremento de varianza al fusionar respectivamente—, por lo que su convergencia parcial refuerza la confianza en que los clusters identificados son una propiedad real de los datos y no un artefacto del algoritmo elegido.





Figura 10. Dendrograma del clustering jerárquico (Ward) sobre una muestra de 308 clientes. La cardinalidad de cada cluster intermedio aparece entre paréntesis.

6. Distribución de la cartera por cluster

La asignación de los 3.084 clientes activos a los seis clusters de K-Means produce una distribución desigual pero no degenerada. La comparativa entre el peso poblacional (porcentaje de clientes) y el peso económico (porcentaje de facturación) de cada cluster revela uno de los hallazgos centrales del análisis: la confirmación empírica y cuantificada de la regla del Pareto sobre la cartera de Selmark.

Distribución de clientes y facturación por cluster
Comparativa entre peso poblacional y peso económico de cada segmento
% de clientes por cluster



% de facturación por cluster




Figura 11. Distribución de clientes y facturación por cluster. Comparativa entre el peso poblacional y el peso económico de cada segmento. Los clusters C1 y C2 concentran el 90,1 % de la facturación con sólo el 47,5 % de los clientes.

Hallazgo crítico: el principio de Pareto cuantificado

El cluster 1 (43,48 % de los clientes) genera por sí solo el 64,57 % de la facturación total. El cluster 2 (3,99 % de los clientes) aporta un 25,54 % adicional. En conjunto, los dos clusters de mayor valor (47,47 % de la cartera) concentran el 90,11 % del negocio. En el extremo opuesto, los clusters 0, 3 y 5 representan el 25,57 % de los clientes pero apenas el 3,28 % de la facturación.

Tabla de dimensión económica por cluster

Cluster	N	% cartera	Facturación	% fact.	Fact./cliente
C0 — Clientes en Riesgo	306	9,92 %	2,97 M €	2,19 %	9.720 €
C1 — Núcleo Estratégico	1.341	43,48 %	87,88 M €	64,57 %	65.532 €
C2 — Grandes Cuentas Internac.	123	3,99 %	34,75 M €	25,54 %	282.555 €
C3 — Reposicionistas Tradic.	429	13,91 %	1,39 M €	1,02 %	3.233 €
C4 — Compradores Estacionales	831	26,95 %	9,00 M €	6,62 %	10.835 €
C5 — Casos Críticos	54	1,75 %	0,10 M €	0,07 %	1.878 €

Tabla 3. Dimensión cuantitativa de los seis clusters identificados.

7. Índices de afinidad

Los índices de afinidad constituyen la técnica clásica del marketing analítico para caracterizar segmentos mediante la comparación cuantitativa entre el comportamiento medio de cada cluster y el comportamiento global. Esta métrica fue sugerida explícitamente por el tutor académico como la forma estándar de caracterizar segmentos en el sector de la consultoría de marketing.

Fórmula del índice de afinidad

$\text{Índice}(k, v) = (\text{Media del cluster } k \text{ en la variable } v / \text{Media global de } v) \times 100$. **Interpretación:** 100 = comportamiento medio · >100 sobrerrepresentado · <100 infrarrepresentado. Ejemplo: índice de 250 en ticket medio significa que el cluster gasta 2,5 veces más por compra que la media global.

Índices de afinidad por cluster y variable

Blanco = comportamiento medio (100) · Azul = subrepresentado · Rojo = sobrerrepresentado




Figura 12. Heatmap de índices de afinidad por cluster y variable. Blanco = comportamiento medio (100) · Azul = subrepresentado · Rojo = sobrerrepresentado.

Lecturas más relevantes del heatmap

La distribución bimodal de la variable `pct_ratio_devoluciones` constituye uno de los hallazgos más visibles del análisis: los clusters 0 y 5 presentan índices de 668 y 873 respectivamente, mientras que los clusters 1, 3 y 4 se sitúan por debajo de 30. Esto indica que la propensión a la devolución no es una característica gradual de la cartera sino un rasgo prácticamente categórico que separa a un subconjunto reducido de clientes problemáticos del resto. De forma similar, `ticket_medio_retail_eur` presenta un valor extraordinario en el cluster 2 (índice 453) frente a valores cercanos a la media o ligeramente inferiores en el resto, lo que define al cluster 2 como un grupo claramente diferenciado por la magnitud de las operaciones individuales.

8. Importancia de variables con Random Forest

Siguiendo la metodología explícitamente sugerida por el tutor académico, se aplica un análisis de importancia de variables mediante Random Forest binario aplicado de forma independiente para cada uno de los seis clusters. La técnica complementa los índices de afinidad: mientras los índices cuantifican la magnitud de la desviación, el Random Forest identifica la capacidad discriminativa de cada variable.

Para cada cluster k se construye un problema de clasificación binaria donde la variable objetivo toma el valor 1 si el cliente pertenece al cluster k y 0 en caso contrario. Se entrena un clasificador Random Forest con 200 árboles, profundidad máxima de 10 niveles, y ponderación de clases balanceada que compensa el desbalance natural. La importancia se extrae mediante dos métricas: la Gini importance (basada en reducción de impureza) y la Permutation importance (más robusta, basada en pérdida de precisión al permutar variables).

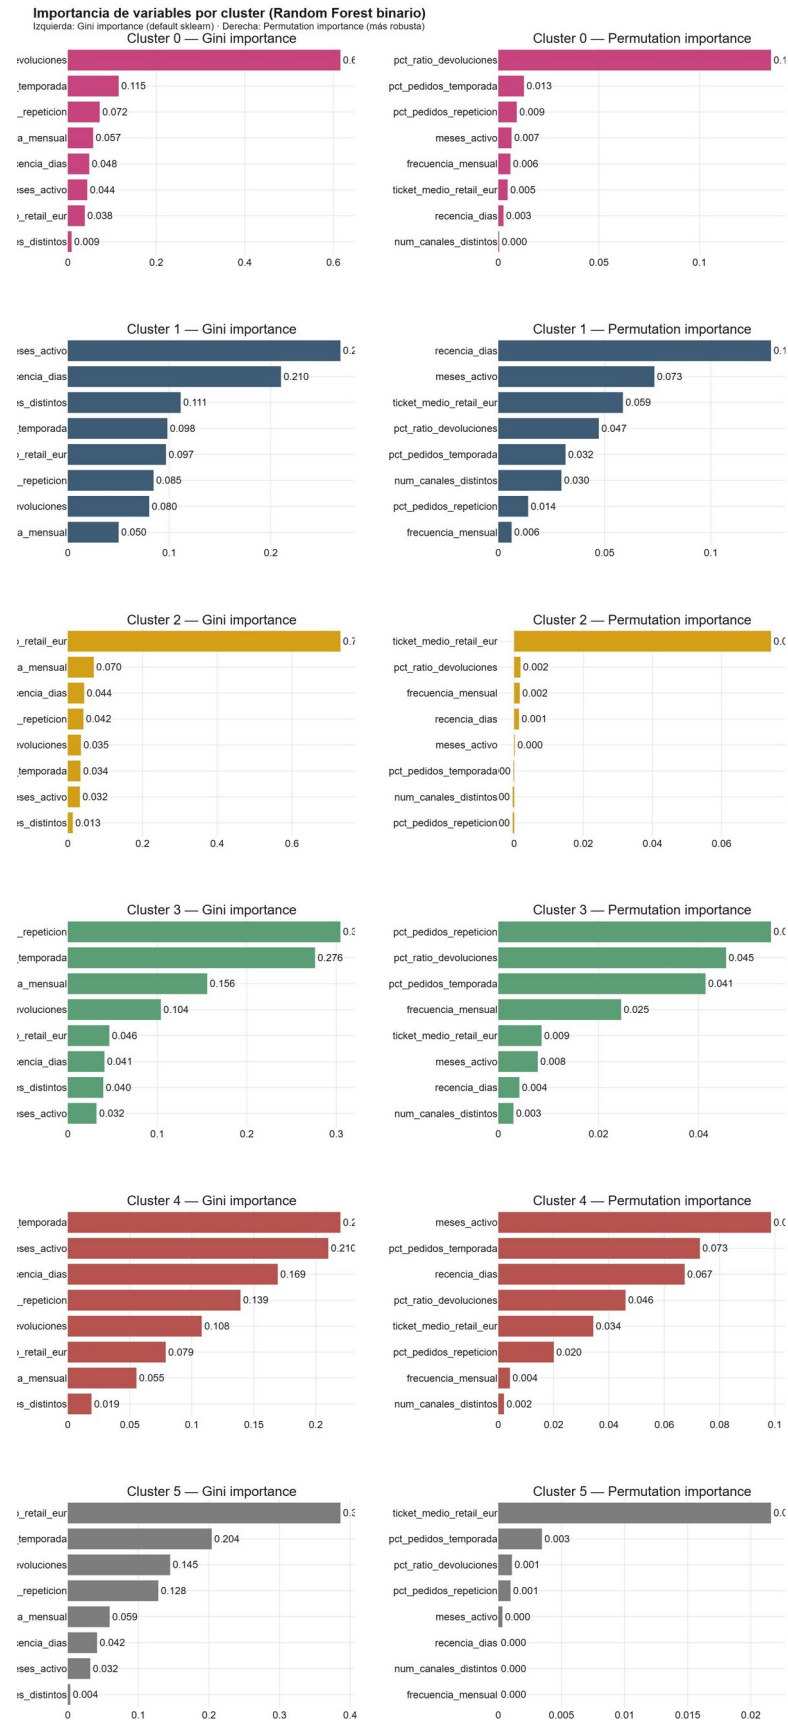


Figura 13. Importancia de variables por cluster (Random Forest binario). Izquierda: Gini importance (default sklearn) · Derecha: Permutation importance (más robusta). Accuracy media de los 6 modelos: 0,983.

Convergencia entre índices y Random Forest

La comparación entre las variables más sobrerrepresentadas según los índices de afinidad y las variables más discriminantes según el Random Forest muestra una convergencia muy alta. Por ejemplo, `pct_ratio_devoluciones` es la variable más sobrerrepresentada en los clusters 0 y 5 (índices de 668 y 873) y también la más discriminante según el Random Forest para esos clusters. De forma análoga, `ticket_medio_retail_eur` ocupa la primera posición tanto descriptiva como inferencial para el cluster 2.

Esta convergencia no es trivial: una variable puede tener un valor medio extremo en un cluster sin ser necesariamente útil para discriminarlo, si el resto de clusters también presentan valores extremos en esa variable. El hecho de que ambas métricas coincidan refuerza la fiabilidad de la caracterización. Adicionalmente, las altas precisiones de los Random Forest (todas superiores al 95,68 % sobre datos no vistos, con una media del 98,29 %) confirman que los seis clusters son grupos estadísticamente bien diferenciados.

9. Caracterización con variables externas

Como validación complementaria, los seis clusters se caracterizan mediante variables que NO se utilizaron en su formación: el tipo de mercado (nacional o internacional), el perfil MOSAIC del código postal, y la renta media del CP. Si los clusters obtenidos resultan estar correlacionados con estas variables externas, esa correlación constituye un hallazgo genuino sobre la estructura del negocio y no un artefacto inducido por la propia metodología.

Composición por tipo de mercado




Figura 14. Composición de cada cluster por tipo de mercado. Porcentaje de clientes nacionales e internacionales en cada segmento. C2 (Grandes Cuentas) y C4 (Estacionales) son predominantemente internacionales.

La composición por mercado revela patrones interpretables: el Núcleo Estratégico (C1) y los Reposicionistas (C3) son predominantemente nacionales (74 % y 72 % respectivamente), mientras que las Grandes Cuentas Internacionales (C2) y los Compradores Estacionales (C4) presentan mayoría internacional (62 % y 58 %). Los Clientes en Riesgo (C0) y los Casos Críticos (C5) muestran composiciones más equilibradas. Esta distribución sugiere que la dinámica comercial internacional concentra perfiles de mayor valor (C2) y de cantera (C4), mientras que la red nacional se apoya principalmente en el Núcleo Estratégico.

Confirmación cuantitativa: la renta NO discrimina




Figura 15. Distribución de la renta media del CP por cluster (solo clientes nacionales con renta del CP disponible). Todas las medianas se sitúan entre 25.000 € y 28.000 €, sin diferencias estadísticamente relevantes entre clusters.

La comparación de la renta media del CP entre los seis clusters confirma con datos lo que el análisis descriptivo del Capítulo 4 había sugerido: los segmentos conductuales identificados no están vinculados a la renta media del entorno geográfico de cada cliente. Las medias por cluster se mueven en un rango muy estrecho (entre 25.349 € en el cluster 0 y 28.066 € en el cluster 2), con desviaciones estándar mayores que las diferencias entre clusters. Dentro de cada cluster existe una variabilidad de renta superior a la variabilidad entre clusters, lo que estadísticamente equivale a decir que la renta no es un factor discriminante de la segmentación. Esta confirmación valida una de las decisiones fundamentales del trabajo: basar el clustering en variables exclusivamente conductuales.

10. Naming comercial y fichas de los segmentos

Consolidando los hallazgos de las tres técnicas anteriores (índices de afinidad, Random Forest y caracterización externa), se asigna a cada cluster un nombre comercial fundamentado en evidencia cuantitativa. Las etiquetas genéricas del tipo 'Cluster 0' o 'Segmento A' no comunican información útil para la toma de decisiones; por el contrario, nombres descriptivos y evocadores facilitan la integración del análisis en los procesos operativos del negocio. El tutor académico del TFG sugirió explícitamente utilizar nombres vistosos de marketing alineados con la práctica del sector.

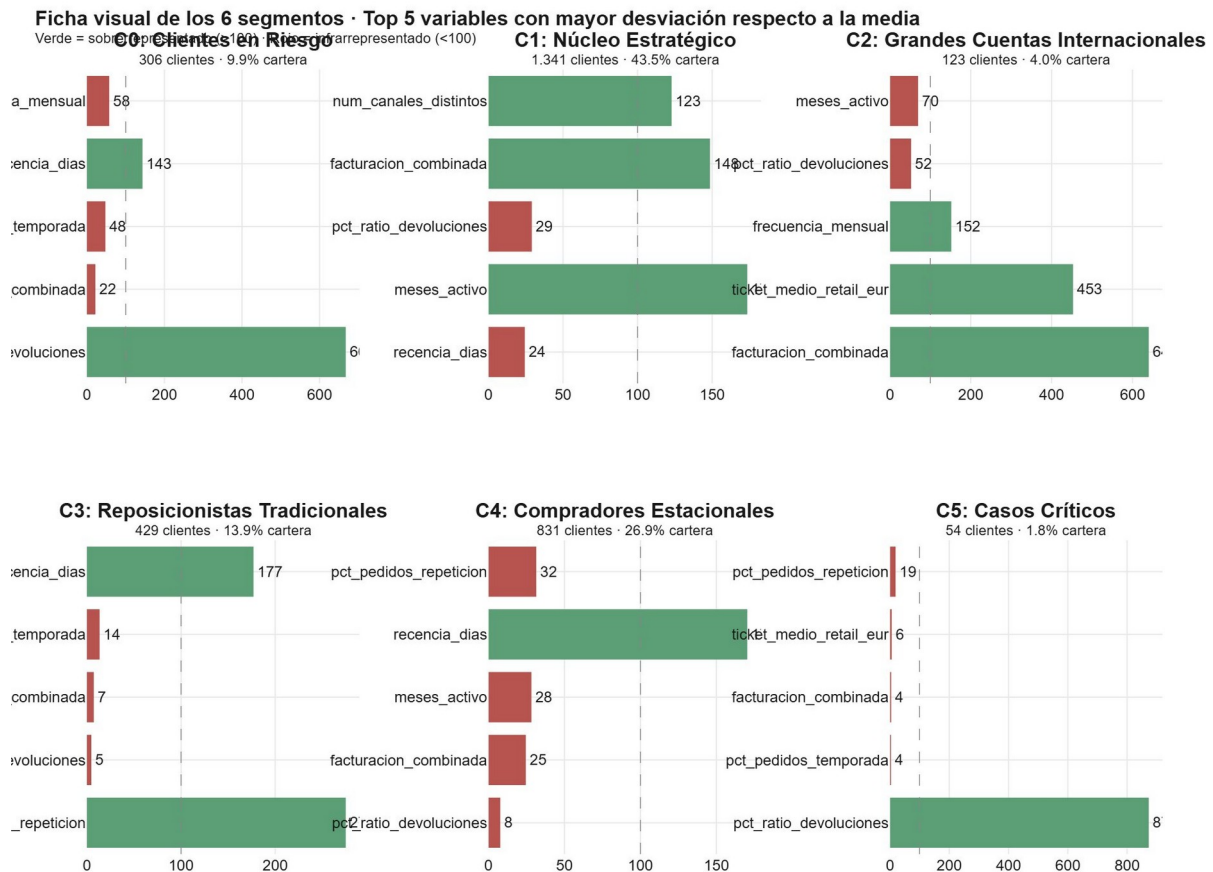


Figura 16. Ficha visual de los 6 segmentos · Top 5 variables con mayor desviación respecto a la media. Verde = sobrerepresentado · Rojo = infrarrepresentado.

11. Fichas detalladas por segmento

Cluster 1 — Núcleo Estratégico

1.341 clientes (43,48 % de la cartera) • 87,88 M € (64,57 % de la facturación) • 65.532 € facturación media/cliente

Este cluster constituye la columna vertebral del negocio de Selmark. Sus rasgos distintivos son una veteranía elevada (índice 174 sobre la media en meses_activo), una recencia muy baja (índice 24, es decir, compran mucho más recientemente que la media), una facturación combinada un 49 % superior a la media, y una baja tasa de devoluciones (índice 29). La composición por mercado es 74 % nacional y 26 % internacional. La accuracy del Random Forest binario para este cluster es del 97,41 %, con las variables recencia_dias, meses_activo y ticket_medio_retail_eur como las más discriminantes según permutation importance.

Lectura comercial: *este cluster representa el cliente fiel y rentable que toda empresa busca consolidar y retener. Cualquier estrategia de retención debe priorizar absolutamente este segmento, ya que su pérdida tendría un impacto desproporcionado sobre el negocio.*

Cluster 2 — Grandes Cuentas Internacionales

123 clientes (3,99 %) • 34,75 M € (25,54 % de la facturación) • 282.555 € facturación media/cliente — la más alta de todos los clusters

Este cluster, pese a ser el más reducido en número de clientes después de los Casos Críticos, aporta la cuarta parte de la facturación total. Sus rasgos distintivos son un ticket medio 4,5 veces superior a la media (índice 453), una facturación combinada 6,4 veces superior (índice 640), y una frecuencia mensual 1,5 veces superior. La composición por mercado se invierte respecto al patrón general de la cartera: el 62 % son internacionales frente al 38 % nacionales, lo que sugiere que se trata predominantemente de distribuidores mayoristas extranjeros con compras de gran volumen. La accuracy del Random Forest es del 99,57 %, con ticket_medio_retail_eur como variable claramente dominante (permutation importance 0,0743).

Lectura comercial: *representa la dependencia más crítica del negocio: la pérdida de uno solo de sus 123 clientes equivale a una caída significativa de facturación. Requiere atención individualizada, contratos estables y políticas de retención muy específicas.*

Cluster 4 — Compradores Estacionales

831 clientes (26,95 %) • 9,00 M € (6,62 % de la facturación) • 10.835 € facturación media/cliente

Este cluster está formado por clientes recientes en la cartera (meses_activo al 28 % de la media, es decir, llevan en promedio una cuarta parte del tiempo que la media de la cartera) con alto compromiso en pedidos de temporada (índice 148). La recencia es elevada (índice 170), indicando que no compran muy frecuentemente, pero cuando lo hacen apuestan por las novedades de colección. Las devoluciones son muy bajas (índice 8). La composición por mercado es 58 % internacional y 42 % nacional. La accuracy del Random Forest es del 95,68 %, con meses_activo, pct_pedidos_temporada y recencia_dias como variables más discriminantes.

Lectura comercial: *representa la cantera potencial del Núcleo Estratégico. Son clientes jóvenes en la cartera que ya muestran compromiso con las colecciones; si la relación se cultiva adecuadamente mediante acciones de fidelización dirigidas, una proporción significativa puede convertirse en clientes del Núcleo en los próximos ciclos comerciales.*

Cluster 3 — Reposicionistas Tradicionales

429 clientes (13,91 %) • 1,39 M € (1,02 % de la facturación) • 3.233 € facturación media/cliente

Este cluster se distingue por una concentración extrema en pedidos de repetición (índice 275, casi tres veces la media) y una ausencia casi total de pedidos de temporada (índice 14). La recencia es elevada (índice 177) y la facturación combinada se sitúa al 7 % de la media. La composición por mercado es 72 % nacional y 28 % internacional. La accuracy del Random Forest es del 98,06 %, con pct_pedidos_repeticion, pct_ratio_devoluciones y pct_pedidos_temporada como variables más discriminantes.

Lectura comercial: *son típicamente pequeñas tiendas tradicionales que reponen exclusivamente productos básicos del catálogo estable, sin participar en las dinámicas de colección y novedad. Aunque aportan poco valor económico individualmente, su volumen agregado y su carácter de relación estable los convierten en un segmento útil para mantener la presencia distribuida del producto en el mercado nacional.*

Cluster 0 — Clientes en Riesgo

306 clientes (9,92 %) • 2,97 M € (2,19 % de la facturación) • 9.720 € facturación media/cliente

Este cluster presenta una tasa de devoluciones 6,7 veces superior a la media (índice 668), combinada con recencia elevada (índice 143) y facturación baja (índice 22). La composición por mercado es 61 % nacional y 39 % internacional. La accuracy del Random Forest es del 99,24 %, con pct_ratio_devoluciones como variable claramente dominante (permutation importance 0,1355, la más alta de todo el análisis).

Lectura comercial: *esta es una señal de alarma. Son clientes cuya relación con Selmark muestra signos de deterioro: devuelven mucho, compran cada vez menos y con menor frecuencia. Requieren una revisión específica desde el departamento comercial para evaluar las causas (problemas de tallaje, calidad, ajuste de catálogo) y aplicar acciones correctivas antes de que pasen al cluster 5 (Casos Críticos) o se den de baja completamente.*

Cluster 5 — Casos Críticos

54 clientes (1,75 %) • 0,10 M € (0,07 % de la facturación) • 1.878 € facturación media/cliente — la más baja de todos los clusters

Este cluster representa el extremo patológico de la cartera. La tasa de devoluciones es 8,7 veces superior a la media (índice 873), el ticket medio es solo el 6 % de la media (índice 6), y la facturación combinada apenas el 4 % de la media. Devuelven prácticamente todo lo que compran. La composición por mercado es 56 % internacional y 44 % nacional. La accuracy del Random Forest es del 99,78 % (la más alta del análisis), confirmando que son un grupo extremadamente bien definido.

Lectura comercial: *son 54 clientes que generan más coste operativo que valor económico. La recomendación es una revisión individual de cada uno de ellos: en algunos casos puede haber rescate posible identificando la causa específica del comportamiento; en otros casos será necesario considerar la terminación comercial controlada de la relación.*

12. Síntesis y aportaciones al TFG

Aportaciones académicas

El Capítulo 5 aporta cinco contribuciones académicas diferenciales al Trabajo de Fin de Grado, todas alineadas con el carácter cuantitativo del Grado en Ingeniería Matemática.

Aportación	Detalle
1. Validación experimental de la selección de variables	Notebook auxiliar 11a_experimentos.ipynb que prueba 4 configuraciones y demuestra empíricamente que eliminar facturacion_combinada mejora el ARI un 69,5 %.
2. Combinación rigurosa de 4 métricas para determinar k	Codo, Silhouette, Davies-Bouldin y Calinski-Harabasz aplicados sobre el espacio de PCA, con criterio de desempate explícito.
3. PCA con interpretación comercial de las componentes	4 componentes que explican el 85,87 % de varianza, traducidos a ejes interpretables (valor, intensidad, calidad, estabilidad).
4. Validación cruzada con jerárquico Ward (ARI=0,55)	Dos algoritmos con criterios distintos identifican estructura similar, lo que valida la robustez de la partición.
5. Caracterización doble: afinidad + Random Forest	Convergencia entre métricas descriptivas e inferenciales con accuracy media del 98,29 % por cluster.

Tabla 4. Aportaciones académicas del Capítulo 5 al TFG.

Aportaciones para Selmark

Hallazgos accionables para el negocio

1. Identificación cuantitativa del Pareto: el 47,5 % de los clientes (C1+C2) concentra el 90,1 % del negocio.
2. Detección de la cantera comercial (C4): 831 clientes recientes con compromiso de colección, futuros candidatos al Núcleo Estratégico.
3. Identificación de riesgos: 360 clientes (C0+C5) presentan tasas de devolución entre 6,7× y 8,7× la media y requieren atención específica.
4. Confirmación de independencia entre conducta y demografía: ni la renta del CP ni el perfil MOSAIC discriminan los segmentos identificados.

Conexión con los capítulos posteriores del TFG

Capítulo	Aportación del Capítulo 5
Cap. 6 (Geomarketing)	Distribución geográfica de los 6 segmentos sobre mapas interactivos. Identificación de concentraciones territoriales por cluster.
Cap. 7 (Churn)	El cluster se incorpora como variable predictora del riesgo de fuga. A priori, C0 (Riesgo) y C5 (Críticos) son los más expuestos.

Capítulo	Aportación del Capítulo 5
Cap. 8 (Recomendaciones)	Acciones comerciales diferenciadas por cluster: retención premium para C1+C2, programas de fidelización para C4, revisión activa de C0 y C5.

Tabla 5. Conexiones del Capítulo 5 con los capítulos posteriores del TFG.

— Fin del informe del Capítulo 5 —