

GUÍA DETALLADA · PARA ENTENDERLO TODO

El modelo predictivo de churn, explicado a fondo y desde cero

Versión ampliada: además de qué hace cada paso del Notebook 13, explica *cómo funciona por dentro* cada técnica, con ejemplos numéricos, los cálculos detrás de cada métrica y las decisiones que se tomaron y por qué.

CÓMO LEER ESTA GUÍA

Cada sección sigue el orden del notebook. Los recuadros de colores te ayudan a fijar ideas: **EN CRISTIANO** traduce un concepto técnico, **EJEMPLO** lo aterriza con números, **POR QUÉ** explica una decisión, y **OJO** avisa de algo importante. Al final tienes un glosario y un apartado de posibles preguntas del tribunal.

Trabajo Fin de Grado · Ingeniería Matemática · Universidad Alfonso X el Sabio · Junio 2026

1. El problema y por qué se resuelve con un modelo

Semark vende ropa interior por dos canales: a tiendas (mayorista, B2B) y a particulares por su web (minorista, B2C). Con el tiempo, algunos clientes dejan de comprar. A eso lo llamamos **churn** (abandono). Cada cliente que se va es facturación que desaparece, y captar uno nuevo cuesta bastante más que retener uno existente. De ahí el valor de anticiparse.

Podríamos usar una regla simple («si lleva más de X meses sin comprar, está en riesgo»), pero una regla así ignora el resto de señales (si compraba mucho o poco, si venía bajando, en qué campañas, etc.). Un **modelo** combina todas esas señales a la vez y aprende qué combinaciones predicen el abandono, asignando a cada cliente una **probabilidad** de churn entre 0 y 1.

EN CRISTIANO

Un modelo es como un médico con experiencia: ha visto miles de casos pasados y, ante un paciente nuevo, combina muchas señales (edad, análisis, hábitos) para estimar un riesgo. Aquí el paciente es el cliente y la enfermedad es dejar de comprar.

2. Conceptos de machine learning, desde cero

Para seguir el resto de la guía conviene tener claras seis ideas. No hace falta saber programar, solo entender qué significan.

Concepto	Qué es
Feature (variable)	Un dato que describe a un cliente: facturación, recencia, número de pedidos...
Target (objetivo)	Lo que queremos adivinar. Aquí es binario: churn (1) o activo (0).
Clasificación binaria	El tipo de problema: separar a los clientes en dos grupos (se va / se queda).
Entrenar	Mostrar al modelo muchos clientes pasados con su resultado conocido para que aprenda los patrones.
Train / Test	Se entrena con una parte de los clientes y se examina con otra distinta que no ha visto.
Sobreajuste (overfitting)	Cuando el modelo se aprende los datos «de memoria» y luego falla con datos nuevos.

POR QUÉ separamos train y test

Si examináramos al modelo con los mismos clientes con los que aprendió, sacaría un 10 sin haber entendido nada (se los sabe de memoria). Por eso se reserva un grupo de test que el modelo nunca ve durante el entrenamiento: es el examen de verdad. Aquí se usó un reparto 70 % entrenamiento / 30 % test.

3. De dónde salen los datos

Los datos viven en una base local (DuckDB) organizada en tres niveles, de más bruto a más limpio (arquitectura *medallion*): **bronze** (datos crudos tal como llegan), **silver** (datos ya limpios, p. ej. la tabla de ventas minoristas con fecha, cantidad e importe) y **gold** (la tabla maestra *gold.cliente_360*, con una fila por cliente y unas 50 columnas ya calculadas). El notebook parte de gold y, cuando necesita un cálculo que no está, lo construye con consultas SQL sobre silver.

EN CRISTIANO

Bronze es la compra del súper tal cual; silver son los ingredientes ya lavados y cortados; gold es el plato casi montado. Nosotros cocinamos a partir de gold y, si falta un ingrediente, lo preparamos desde silver.

4. Qué queremos adivinar: el target y la regla de oro

Definimos que un cliente está en **churn** si **no realizó ninguna compra durante el año 2025**. La ventana de doce meses es el estándar del textil, que tiene dos colecciones al año. Si compró algo en 2025 es «activo» (0); si no, es «churn» (1).

LA REGLA DE ORO

Para predecir 2025 solo se puede usar información ANTERIOR a 2025. Cualquier dato del propio 2025 que se cuele convierte la predicción en trampa: equivale a mirar la respuesta del examen. Toda la sección 5 va de esto.

5. El gran arreglo: la trampa (data leakage) y cómo se quitó

La primera versión del modelo acertaba casi siempre (acierto de 0,98). Cuando un modelo parece perfecto, casi siempre esconde un truco. Aquí el truco se llama **data leakage** (fuga de información del futuro).

5.1 Qué era exactamente la trampa

Variables como «meses activos» o «número de operaciones» estaban calculadas sobre **toda la vida del cliente, incluyendo 2025**. Como un churner no compra en 2025, esas variables le salían bajas *precisamente porque era churner*. El modelo leía la respuesta por la puerta de atrás.

EJEMPLO con números

Mira las medianas que medimos: en la variable «meses_activo» (que incluía 2025), los activos tenían 21 y los churners 6,5. En «num_operaciones», 818 frente a 211. Esa caída brutal del grupo churn no es que compraran poco: es que les falta TODO el 2025. La variable estaba, sin querer, contando la respuesta.

LA ANALOGÍA

Es como predecir si un alumno aprobará el examen final usando como pista «¿fue a clase el mes del examen?». El que no fue, suspende. No predices nada: cueles la respuesta. Por eso el modelo «acertaba» tanto.

5.2 La corrección, en dos pasos

Paso 1 — congelar el reloj a 31/12/2024 («as-of 2024»). Recalculamos todas las variables de comportamiento usando solo lo ocurrido hasta el 31/12/2024 (les pusimos el sufijo `_pre`). Así ninguna mira a 2025. La «recencia» pasa a ser «días sin comprar a fecha 31/12/2024»: ese dato sí existiría en la vida real en el momento de predecir, así que es legítimo y, además, muy informativo.

Paso 2 — quitar las etiquetas de cluster. Los grupos del Capítulo 5 se habían formado con variables que incluían 2025, así que arrastraban la misma trampa de forma indirecta. Por eso se excluyen las variables `cluster_*` del modelo.

Resultado: el acierto bajó de 0,98 (inflado) a **0,88** (honesto). El modelo no empeoró; dejó de hacer trampa. Y 0,88 es justo el rango que la literatura considera realista para churn (0,75–0,90).

5.3 La segunda mejora: «fresh churn»

Al revisar los datos vimos que muchos «churners de 2025» ya llevaban 2–3 años sin comprar. Predecirlos es trivial e inútil (no recuperas a quien se fue hace años). Por eso nos quedamos solo con los clientes que **todavía compraban en 2024** (recencia inferior a 365 días) y predecimos quién, de ese grupo recuperable, abandona en 2025. Es el llamado *fresh churn*, el setup estándar y el único útil para retención.

El embudo que define el grupo de estudio final quedó así:

Filtro aplicado	Cientes que quedan
Total en gold.cliente_360	3.492
Con histórico de compras hasta 31/12/2024	2.795
Con al menos 1 año de antigüedad	2.533
Con cluster asignado y sin «Casos Críticos» (ya inactivos)	2.484
Activos al corte (recencia < 365) → fresh churn	-603
GRUPO FINAL DE ESTUDIO	1.881 clientes

RESULTADO DE LOS ARREGLOS

Grupo de estudio: **1.881 clientes activos**. Tasa de abandono real: **15,2 %** (286 churners, 1.595 activos). Es más baja que el 33 % de antes porque ahora medimos solo el abandono NUEVO, no el de los ya inactivos. Y todas las variables son ya «as-of 2024»: ninguna mira al futuro.

6. Mirar los datos antes de modelar

6.1 El desbalance y por qué importa

De 1.881 clientes, solo 286 abandonan (15,2 %): hay casi 6 activos por cada churner (ratio 1:5,58). Esto se llama **desbalance de clases** y hay que tenerlo en cuenta, porque un modelo perezoso podría decir «nadie abandona» y acertar el 85 % de las veces sin servir para nada. Por eso más adelante daremos peso extra a la clase rara y mediremos con métricas que no se dejen engañar por el desbalance (como PR-AUC).

6.2 Churn por grupo de clientes (validación de los clusters)

Comprobamos el abandono en cada grupo del Capítulo 5. Si la segmentación es buena, los grupos deberían comportarse muy distinto. Y así es:

Grupo (cluster)	Nº clientes	Tasa de abandono
Núcleo Estratégico (los más fieles)	1.216	4,0 %
Grandes Cuentas Internacionales	71	22,5 %
Clientes en Riesgo	175	31,4 %
Reposicionistas Tradicionales	149	36,2 %
Compradores Estacionales (los más volátiles)	270	41,5 %

6.3 Tests estadísticos: ¿qué variables se relacionan con el churn?

Antes de modelar comprobamos, con tests estadísticos, qué variables están relacionadas con el abandono. El test de **Mann-Whitney** compara si una variable numérica se distribuye distinto en activos y churners; un **p-valor** muy pequeño (típicamente < 0,05) significa «la diferencia es real, no casualidad». Las variables más asociadas fueron las operaciones y facturación de 2024 y la recencia.

Variable	Mediana activo	Mediana churn	¿Significativa?
ops_y2024 (compras en 2024)	207	24	Sí (p < 0,001)
fact_y2024 (facturación 2024)	4.444 €	594 €	Sí
recencia_pre (días sin comprar)	49	164	Sí
tendencia_ops_24_vs_23	-0,01	-0,54	Sí

Para variables de categorías se usa el test de **chi-cuadrado**. El resultado más relevante: el **cluster** está fuertemente asociado al churn (p < 0,001), lo que confirma su utilidad; en cambio, otras como el tipo de mercado o el grupo MOSAIC no resultaron significativas.


7. Las variables (features) del modelo

El modelo usa 33 variables que describen a cada cliente, agrupadas en seis familias. Cada una captura una intuición distinta del comportamiento de compra:

Familia	Qué intuición captura	Ejemplos
RFM	Cada cuánto, hace cuánto y cuánto compra	recencia_pre, num_operaciones_pre, facturacion_retail_pre
Estacional	En qué campañas concentra sus compras	pct_operaciones_pv, pct_operaciones_rebajas
Tendencia	Si va a más o a menos respecto al año previo	tendencia_ops_24_vs_23
Producto	Variedad y calidad de su relación	num_modelos_distintos_pre, pct_ratio_devoluciones
Sociodemográfica	Perfil de su zona	renta_media, perfiles MOSAIC
Geográfica	Su contexto territorial (Cap. 6)	penetración de problemáticos en su provincia

7.1 Quitar variables que dicen lo mismo (multicolinealidad)

Algunas variables miden casi lo mismo y suben y bajan juntas (por ejemplo «número de operaciones» y «unidades vendidas»). Tener duplicados no aporta y mete ruido. Para detectarlos calculamos una **matriz de correlaciones**: cada casilla mide cuánto se parecen dos variables (rojo intenso = se mueven igual; azul = al revés). De cada bloque de variables «gemelas» nos quedamos con una y descartamos las demás. Así se eliminaron 2 variables y el modelo final quedó en 33.



Matriz de correlaciones. Los bloques rojos son grupos de variables que miden lo mismo; de cada grupo se conserva una sola.

8. Los cuatro modelos: cómo funcionan por dentro

Probamos cuatro técnicas y nos quedamos con la mejor. Conviene entender la idea de cada una:

8.1 Regresión Logística (la sencilla)

Asigna un peso a cada variable y los combina en una fórmula que devuelve una probabilidad. Es transparente (se ve el peso de cada variable) y sirve de referencia (*baseline*). En nuestro caso, su coeficiente más fuerte fue ops_y2024 con signo negativo: a más compras en 2024, menos riesgo de churn — exactamente lo esperable.

8.2 Árbol de decisión, Random Forest y boosting (los potentes)

Un **árbol de decisión** es una cadena de preguntas tipo «¿llevaba más de 200 días sin comprar? ¿facturó menos de 1.000 € en 2024?» que va dividiendo a los clientes hasta estimar su riesgo. Un solo árbol es simple y se equivoca; la gracia está en combinar muchos:

Técnica	Idea
Random Forest	Cientos de árboles distintos que votan; el resultado es la media. Reduce errores y es muy robusto.
XGBoost	Árboles contruidos en cadena: cada uno corrige los fallos del anterior (boosting). Muy preciso.
LightGBM	Como XGBoost pero más rápido y eficiente.

POR QUÉ damos peso extra a la clase rara

Como solo hay un 15 % de churners, todos los modelos se entrenan con `class_weight='balanced'` (o `scale_pos_weight`), que hace que equivocarse con un churner «pese» más. Así el modelo no se conforma con ignorar la clase rara. No se usó SMOTE (crear churners artificiales) porque tiende a descalibrar las probabilidades.

8.3 Ajuste de hiperparámetros (GridSearchCV)

Cada técnica tiene «mandos» (número de árboles, profundidad, velocidad de aprendizaje...) llamados **hiperparámetros**. Para elegir la mejor combinación se usa **GridSearchCV**: prueba muchas combinaciones ($24 \times 3 = 72$ ajustes por modelo) y se queda con la que mejor funciona en **validación cruzada** (entrenar y probar varias veces rotando los datos). Por ejemplo, el Random Forest ganador usa 400 árboles; el XGBoost, profundidad 8 y velocidad de aprendizaje 0,1.

9. Cómo se puntúa un modelo (las métricas, con cálculos)

Estos son los números que aparecen por todas partes. Los explico con el ejemplo real de nuestro modelo, cuyos aciertos y fallos sobre los 565 clientes del examen fueron: 55 churners detectados, 31 churners que se escaparon, 50 falsas alarmas y 429 activos bien clasificados.

Métrica	Qué mide y cómo se calcula (con nuestros números)
Recall	De los churners reales, cuántos pillamos. $= 55 / (55+31) = 64 \%$.
Precision	De los que marcamos como riesgo, cuántos lo eran. $= 55 / (55+50) = 52 \%$.
F1	Equilibrio entre recall y precision en un número. $\sim 0,58$.
Accuracy	Aciertos totales. $= (429+55) / 565 = 86 \%$.
AUC-ROC	Si coges un churner y un activo al azar, probabilidad de dar más riesgo al churner. 0,88 (0,5 = azar).
PR-AUC	Como AUC, centrada en acertar churners. Su «aprobado raso» es 0,15 (el % de churn); nosotros 0,64 .
Brier	Cómo de afinadas están las probabilidades (cuanto más bajo, mejor). 0,088 .

OJO · accuracy engaña con desbalance

Un modelo que dijera «nadie abandona» tendría un 85 % de accuracy (porque el 85 % son activos) y sería inútil. Por eso no nos fijamos solo en accuracy, sino sobre todo en recall, PR-AUC y AUC, que sí valoran acertar la clase rara.


9.1 Comparativa de los cuatro modelos

Modelo	AUC-ROC	PR-AUC	F1	Brier
Logistic Regression	0,851	0,532	0,521	0,157
Random Forest (elegido)	0,880	0,638	0,613	0,088
XGBoost	0,870	0,620	0,527	0,102
LightGBM	0,873	0,623	0,559	0,103

Se elige por PR-AUC (la métrica más exigente con la clase rara), y gana **Random Forest**. En las curvas de abajo, cuanto más se pega la línea a la esquina superior izquierda (ROC) o se mantiene arriba

(Precision-Recall), mejor; la diagonal de puntos sería responder al azar.

Comparativa de los 4 modelos · Conjunto de test




Curvas ROC (izquierda) y Precision-Recall (derecha) de los cuatro modelos. Random Forest domina.

10. Afinar las probabilidades y el umbral

10.1 Calibración


Un modelo está «bien calibrado» si, cuando dice «70 % de probabilidad», de cada 100 clientes así abandonan unos 70 de verdad. Se ajusta con **isotonic regression**. En nuestro caso las probabilidades ya estaban bien (el Brier apenas cambió), señal de que Random Forest las estimaba con sensatez.



Izquierda: probabilidad que dice el modelo frente a la realidad (cuanto más pegada a la diagonal, mejor calibrada). Derecha: los activos se agolpan cerca de 0 y los churners cerca de 1.

10.2 El umbral de decisión

El modelo da una probabilidad (0 a 1); hay que decidir a partir de qué valor damos la alarma. Lo normal es 0,5, pero pocas veces es lo óptimo. Si bajamos el umbral, pillamos más churners (sube recall) pero damos más falsas alarmas (baja precision). Probando un rango de valores, el mejor equilibrio (F1 máximo) está en **0,35**.



Recall, precision y F1 según el umbral. El mejor equilibrio (F1 máximo) se alcanza en 0,35.

Con umbral 0,35, así quedan aciertos y fallos sobre los clientes del examen (la **matriz de confusión**):

	El modelo dice ACTIVO	El modelo dice CHURN
Realmente ACTIVO (479)	429 (aciertos)	50 (falsa alarma)
Realmente CHURN (86)	31 (se escapan)	55 (detectados)

11. Por qué el modelo decide lo que decide (SHAP)


Random Forest es potente pero opaco: acierta, pero no es evidente por qué. Los **SHAP values** (basados en teoría de juegos) abren esa «caja negra»: para cada cliente reparten la decisión entre las variables, diciendo cuánto empuja cada una hacia «churn» o hacia «activo». Parten de un **valor base** (el riesgo medio, ~15 %) y van sumando o restando.

EJEMPLO de cómo suma

Imagina un cliente que parte del riesgo medio (15 %). Lleva 300 días sin comprar (+20 puntos), compró poco en 2024 (+15) pero su zona tiene renta alta (-3). Su riesgo final sería aproximadamente $15 + 20 + 15 - 3 \sim 47$ %. SHAP hace exactamente esto, variable a variable, para cada cliente.

Sumando todos los clientes obtenemos qué variables pesan más en general. Y aquí está la prueba de que ya no hay trampa: las dominantes son todas legítimas y anteriores a 2025 — las compras y facturación de 2024, la recencia al corte y la tendencia interanual.

En la gráfica de barras (izquierda), barra más larga = variable más importante. En el diagrama de puntos (derecha), cada punto es un cliente: rojo = valor alto de esa variable, azul = bajo; si el punto está a la derecha, empuja hacia churn. Se ve, por ejemplo, que mucha recencia (rojo, a la derecha) empuja al abandono.



Izquierda: importancia global de cada variable. Derecha: cómo influye en cada cliente (rojo = valor alto; a la derecha = empuja hacia churn).

12. Comprobar que no hay truco (robustez)


Como el resultado es bueno, lo sometemos a tres pruebas independientes más una validación geográfica.

12.1 Modelo «puro»

Reentrenamos quitando las 14 variables acumulativas (más delicadas) y dejando solo históricos anuales, tendencias y datos socioeconómicos. El acierto apenas baja, de 0,880 a 0,854 (diferencia de solo 0,026). Conclusión: el modelo no depende de esas variables, así que no queda fuga escondida.

12.2 Bootstrap (repetir el examen 1.000 veces)


El **bootstrap** consiste en rehacer el examen 1.000 veces con muestras ligeramente distintas de los mismos clientes (remuestreo con reemplazo), para ver si el resultado es estable o fue suerte. El acierto se mantiene siempre en un rango estrecho: el **intervalo de confianza al 95 % es [0,841 – 0,918]**. Eso significa que el rendimiento es una propiedad real del modelo, no de la muestra concreta que tocó.



Repetiendo la evaluación 1.000 veces, las métricas se concentran en un rango estrecho: el modelo es estable.

12.3 Calibración por grupo y validación por provincia

Comprobamos que el modelo acierta las probabilidades por igual en todos los grupos (la diferencia máxima entre lo predicho y lo real es del 5,9 %, por debajo del 10 % aceptable) y que, agregando por provincia, reproduce bien las tasas reales (p. ej. Pontevedra: predice 21,4 % y la realidad es 19,6 %), lo que enlaza con el Capítulo 6.



Por cada grupo: probabilidad media predicha (azul) frente a tasa real (rosa). Casi se solapan.

13. La lista final de clientes en riesgo

El producto operativo del capítulo es la lista de los 100 clientes activos con mayor probabilidad de abandonar, ordenados de más a menos riesgo. Suman **470.774 €** de facturación histórica. Gracias al arreglo, ahora son clientes que compraban hace poco (no inactivos de hace años), así que se puede actuar sobre ellos.

Cliente	Grupo	Facturación	Días sin comprar	Riesgo
16352	Núcleo Estratégico	19.608 €	19	61 %
5124	Núcleo Estratégico	15.204 €	305	61 %
1929	Núcleo Estratégico	9.523 €	188	63 %
1512	Compradores Estac.	1.472 €	113	79 %

CASO NARRADO

El cliente 16352 es del Núcleo Estratégico, ha facturado casi 20.000 € y compró hace solo 19 días; aun así el modelo le da un 61 % de riesgo. ¿Por qué, si compró hace nada? Porque otras señales (su tendencia y patrón de actividad) apuntan a un enfriamiento. Es justo el tipo de aviso valioso: un cliente top que conviene que un comercial llame YA. Esta lista es la entrada del Capítulo 8, donde se calcula el dinero recuperable.

14. Limitaciones honestas

Un buen TFG reconoce sus límites. Tres principales: (1) solo hay 4 años de histórico (2022–2025), lo que deja las tendencias interanuales en pocos puntos; (2) el target es binario y no dice *cuándo* abandonará el cliente (un modelo de supervivencia lo haría); y (3) faltan variables externas (campañas comerciales, incidencias de CRM, factores macroeconómicos) que podrían mejorar la predicción.

15. Posibles preguntas del tribunal

«Un AUC de 0,88 sigue siendo alto, ¿no?»

Está en el rango realista del sector (0,75–0,90) y, sobre todo, está ganado de forma honesta: la variable que manda es la recencia al corte y las compras del año anterior, predictores legítimos. Lo demuestra el diagnóstico de leakage y el modelo «puro», que sigue dando 0,854.

«¿Cómo sabes que no hay data leakage?»

Tres evidencias: (1) todas las variables se recalcularon as-of 2024 y se excluyeron los clusters contaminados; (2) el SHAP muestra que ninguna variable dominante incluye 2025; (3) el modelo puro, sin las variables acumulativas, apenas pierde acierto.

«¿Por qué Random Forest y no LightGBM?»

Por PR-AUC, la métrica más adecuada con clases desbalanceadas, gana Random Forest (0,638). Los cuatro modelos están muy igualados (0,87–0,88 de AUC); la elección es defendible y consistente.

16. Resumen y glosario

EN 30 SEGUNDOS

«Construí un modelo que predice qué clientes dejarán de comprar. La primera versión hacía trampa (usaba datos del año que quería adivinar), así que la corregí: recalculé todo con datos solo hasta 2024 y me centré en los clientes que seguían activos. El modelo final (Random Forest) acierta 0,88 —el nivel realista del sector— y lo comprobé de tres formas. El resultado es una lista de 100 clientes en riesgo, con 470.000 € en juego, sobre la que actuar.»

Glosario

Término	Qué significa
Churn	Que un cliente deje de comprar (aquí: sin compras en todo 2025).
Feature / variable	Dato que describe al cliente y que el modelo usa para predecir.
Target	Lo que se quiere adivinar (churn = 1, activo = 0).
Clasificación binaria	Problema de separar en dos grupos (se va / se queda).
Train / test	Datos para aprender vs. datos reservados para el examen.
Overfitting	Aprenderse los datos de memoria y fallar con datos nuevos.
Data leakage	Usar sin querer información del futuro que el modelo no debería conocer.
As-of 2024	Variables calculadas solo con datos hasta el 31/12/2024.
Fresh churn	Predecir el abandono solo entre los clientes que seguían activos.
Desbalance	Que una clase (churn) sea mucho menos frecuente que la otra.
Recencia	Días que lleva el cliente sin comprar.
Cluster	Grupo de clientes parecidos (del Capítulo 5).
GridSearchCV	Probar muchas combinaciones de ajustes y quedarse con la mejor.
Validación cruzada	Entrenar y probar varias veces rotando los datos.
AUC-ROC	Nota de 0,5 (azar) a 1 (perfecto) de cómo ordena el riesgo.
PR-AUC	Como AUC pero centrada en acertar la clase rara (churn).
Recall	% de churners reales detectados.
Precision	% de aciertos entre los marcados como riesgo.
F1	Número que equilibra recall y precision.

Término	Qué significa
Umbral (threshold)	Probabilidad a partir de la cual se da la alarma (aquí 0,35).
Calibración	Que las probabilidades coincidan con la realidad.
SHAP	Técnica que explica cuánto pesa cada variable en cada predicción.
Bootstrap	Repetir la evaluación muchas veces para ver si es estable.
Brier score	Medida de cómo de afinadas están las probabilidades (menor = mejor).