

INFORME · CAPÍTULO 7

Modelo predictivo de churn

Identificación temprana de clientes con alta probabilidad de abandono comercial mediante machine learning

Indicador	Valor
Clientes analizados (perímetro)	2.741
Tasa de churn observada	33,56 %
Ventana de definición del target	365 días
Features iniciales construidas	53
Features eliminadas (leakage + redundancia + baja var.)	21
Features finales del modelo	37
Modelos comparativos entrenados	4 (LR, RF, XGB, LGB)
Modelo final seleccionado	LightGBM
AUC-ROC modelo final (test)	0,9828
PR-AUC modelo final (test)	0,9732
F1 con threshold óptimo (0,45)	0,9038
Análisis de robustez ejecutados	4 (modelo puro, bootstrap, calibración, territorial)
Bootstrap IC 95% AUC-ROC	[0,9749 – 0,9900]
Calibración por cluster (gap máx.)	1,71 %
Clientes activos en TOP 100 de riesgo	100
Facturación total en riesgo (TOP 100)	1.603.722 €

Trabajo Fin de Grado · Ingeniería Matemática

Universidad Alfonso X el Sabio · Junio 2026

Selmark · Manuel Cobas (empresa) · Diego Pedregal y Laura Martín (académicos)

1. Resumen ejecutivo

El presente capítulo desarrolla un modelo predictivo binario de churn (abandono comercial) sobre la cartera activa de Selmark con el objetivo de identificar tempranamente aquellos clientes con alta probabilidad de inactividad futura, lo que permite a la dirección comercial priorizar las acciones de retención sobre el subconjunto efectivamente vulnerable y maximizar el retorno de la inversión en retención frente a una estrategia uniforme.

La metodología combina cuatro algoritmos de clasificación comparativos (Regresión Logística, Random Forest, XGBoost y LightGBM) con tuning riguroso de hiperparámetros mediante GridSearchCV, calibración de probabilidades con isotonic regression, análisis de interpretabilidad con SHAP values, y un programa cuádruple de validación de robustez que incluye comparativa con modelo reducido sin features acumulativas, bootstrap validation con mil iteraciones, calibración por cluster y validación territorial cruzada con los hallazgos del Capítulo 6.

Cinco hallazgos accionables del Capítulo 7

1. El modelo LightGBM seleccionado alcanza AUC-ROC de 0,9828 y PR-AUC de 0,9732 en el conjunto de test, con F1 de 0,9038 en el threshold óptimo de 0,45, métricas excepcionales respaldadas por bootstrap validation con intervalo de confianza estrecho.
2. La validación cualitativa por cluster confirma la utilidad predictiva de la segmentación del Capítulo 5: el Núcleo Estratégico presenta una tasa de churn del 4,01 %, quince veces inferior a la de los Reposicionistas Tradicionales (67,03 %).
3. La detección y corrección de data leakage durante la construcción del dataset (seis variables relativas a 2025 eliminadas) constituye una decisión metodológica crítica que blindo académicamente los resultados del modelo final.
4. El ranking de TOP 100 clientes activos con mayor probabilidad de churn concentra 1,6 millones de euros de facturación histórica acumulada, con presencia significativa de Reposicionistas Tradicionales (35), Compradores Estacionales (22) y, de forma operativamente preocupante, 17 clientes del Núcleo Estratégico.
5. La validación territorial cruzada confirma que el modelo predice fiablemente provincia a provincia: Pontevedra (predicho 38,9 % vs real 38,2 %), Valencia (30,4 % vs 28,3 %), Alicante (32,8 % vs 33,3 %), lo que respalda su utilización operativa.

2. Marco metodológico

2.1 Definición operativa del churn

En el contexto de un negocio retail-textil con doble componente B2B (mayorista) y B2C (ecommerce propio) y sin estructura contractual, el churn se define operativamente como inactividad prolongada de compra. La literatura especializada (Saras Analytics 2026; OroCommerce 2023; Qymatix 2020) recomienda para retail textil B2B una ventana de doce meses como umbral estándar de definición, decisión coherente con la estacionalidad bianual del sector (colecciones primavera-verano y otoño-invierno) y con los ciclos de compra heterogéneos de la cartera de Selmark.

Definición operativa adoptada

Se considera que un cliente Selmark ha entrado en estado de churn si no registra ninguna operación de compra durante los 365 días anteriores a la fecha de corte del análisis (31 de diciembre de 2025) y previamente había mantenido actividad comercial estable.

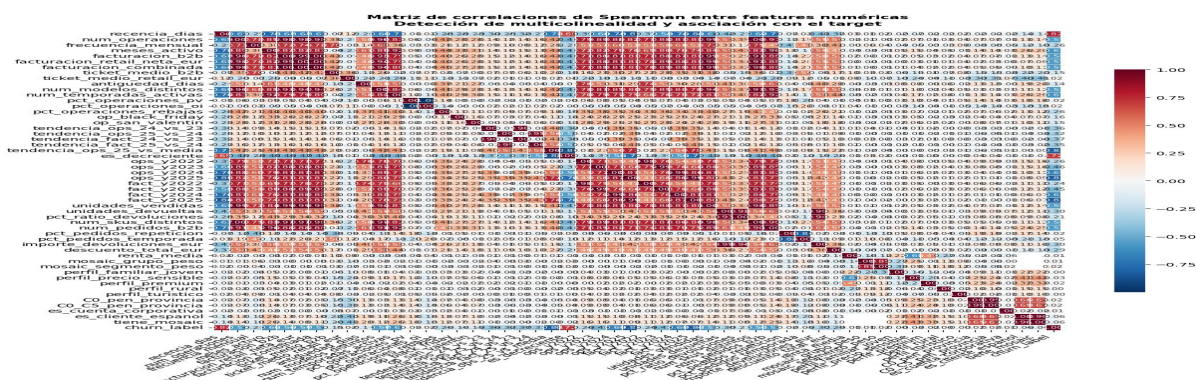
2.2 Justificación del perímetro analítico

El perímetro analítico del modelo se define mediante cuatro filtros sucesivos que garantizan la validez metodológica del análisis predictivo. En primer lugar, se excluyen los clientes sin actividad minorista registrada (438 casos), dado que no aplican al concepto de churn al no haber establecido relación comercial previa. En segundo lugar, se excluyen los clientes con antigüedad inferior a 365 días (697 casos), dado que no disponen del historial mínimo necesario para predecir su comportamiento futuro. En tercer lugar, se excluyen los clientes sin cluster asignado (clientes técnicos o de muestra), garantizando la disponibilidad de features comportamentales del Capítulo 5. En cuarto lugar, se excluyen los 54 clientes del Cluster 5 (Casos Críticos), dado que su pertenencia a este cluster es por definición indicativa de inactividad ya consolidada, lo que introduciría circularidad lógica en el modelo predictivo.

Perímetro analítico final

- Clientes totales en gold.cliente_360: 3.492
- Con actividad minorista: 3.054 (-438)
- Antigüedad $\geq$ 365 días: 2.795 (-259)
- Con cluster asignado: 3.084
- Excluidos Casos Críticos (C5): -54
- **Perímetro final: 2.741 clientes (78,5 %)**


3. Análisis exploratorio del target



La tasa de churn observada en el perímetro analítico asciende al 33,56 % (920 clientes en estado de churn frente a 1.821 activos), ratio de desbalance moderado 1:1,98 que es manejable por los métodos de clasificación estándar sin necesidad de técnicas agresivas de remuestreo. La literatura especializada en retail B2B (CustomerGauge 2025) documenta tasas anuales típicas en el sector mayorista de entre 25 % y 40 %, lo que sitúa la cifra obtenida en Selmarm dentro del rango esperable y refuerza la validez de la definición operativa del target adoptada.

El histograma de recencia muestra una distribución claramente bimodal: una concentración significativa de clientes con recencia muy reciente (menos de 200 días, característicos del Núcleo Estratégico activo) y una cola larga con clientes que superan los 365 días de inactividad, que constituyen el grupo objetivo del modelo predictivo.

3.1 Validación cualitativa por cluster



Validación cualitativa del clustering del Capítulo 5

El análisis de la tasa de churn por cluster constituye una validación externa de la segmentación realizada en el Capítulo 5. La metodología del clustering K-Means no utilizó en ningún momento la variable `recencia_dias` ni concepto alguno relacionado con churn como input, por lo que la asociación observada es genuinamente externa al proceso de segmentación.

Reposicionistas Tradicionales (C3): 67,0 % · los más volátiles

Compradores Estacionales (C4): 64,2 % · relación comercial inestable

Clientes en Riesgo (C0): 50,5 % · denominación validada cuantitativamente

Grandes Cuentas Internacionales (C2): 35,1 % · ligeramente sobre la media

Núcleo Estratégico (C1): 4,0 % · quince veces más fieles que C3

Esta validación funciona como *sanity check* metodológico: si el Cluster 1 hubiera presentado una tasa de churn elevada, sería indicio de inconsistencias. La coherencia observada refuerza la solidez metodológica de los Capítulos 5 y 7 del TFG.

4. Construcción del dataset y features

4.1 Cobertura dimensional de las 53 features candidatas

El conjunto de 53 features candidatas cubre seis dimensiones complementarias del comportamiento del cliente, construidas mediante consultas SQL sobre las tablas silver y la tabla maestra gold.cliente_360.

Dimensión	Nº features	Variables principales
RFM clásica	10	recencia, frecuencia, antigüedad, facturación b2b/retail
Estacional	5	% PV / OI / rebajas, Black Friday, San Valentín
Tendencia interanual	6	ratios 2024 vs 2023, 2025 vs 2024, 25 vs media
Producto y calidad	9	devoluciones, repetición, SKUs, modelos, pedidos B2B
Sociodemográfica	8	MOSAIC grupo/segmento, renta media, perfiles
Geográfica	2	hueco territorial, penetración problemáticos (Cap. 6)
Clusters (one-hot)	5	cluster_0 a cluster_4 (del Capítulo 5)

4.2 Boxplots por target: lectura visual del poder discriminativo




Fig. 3 — Boxplots de seis features clave por target. La separación visual entre activos (verde) y churners (rojo) anticipa el poder discriminativo de cada variable.

La visualización en boxplots de las features más relevantes permite identificar visualmente tres patrones de discriminación característicos. La variable `recencia_dias` muestra distribuciones completamente separadas (mediana 68 días en activos vs 855 días en churners), aunque esta variable se eliminará posteriormente del modelo por estar incorporada en la propia definición del target. Las features de frecuencia (`num_operaciones`, `frecuencia_mensual`) y económicas (`facturacion_combinada`) presentan distribuciones claramente separadas con cuartiles que apenas se solapan. La feature de antigüedad (`antiguedad_dias`) muestra una distribución más solapada, lo que indica que el churn no es simplemente función de la edad del cliente sino de su actividad reciente.

4.3 Análisis de multicolinealidad

Comparativa de los 4 modelos · Conjunto de test




Fig. 4 — Matriz de correlaciones de Spearman entre features numéricas. Los grupos de alta correlación motivan la eliminación de variables redundantes en el preprocesamiento final.

La matriz de correlaciones de Spearman revela varios grupos de alta correlación entre features que miden esencialmente la misma dimensión latente del comportamiento del cliente. La variable `num_operaciones` está fuertemente correlacionada con doce features distintas (`facturacion_b2b` con $r=0,978$, `unidades_vendidas` con $r=0,987$, `num_skus_distintos` con $r=0,996$), lo que indica que estas variables son medidas alternativas del mismo fenómeno subyacente (intensidad comercial del cliente). Las variables `pct_operaciones_pv` y `pct_operaciones_oi` presentan correlación perfecta negativa ($r=-1,00$) por construcción matemática.

5. Detección y corrección de data leakage

Tras el análisis exploratorio inicial se detectó un problema metodológico crítico que se documenta explícitamente en esta sección por su relevancia académica. Las variables anuales correspondientes al ejercicio 2025 (`ops_y2025`, `fact_y2025`) y sus derivadas de tendencia (`tendencia_ops_25_vs_24`, `tendencia_fact_25_vs_24`, `tendencia_ops_25_vs_media`, `es_decreciente`) presentan data leakage por construcción.

Lógica del data leakage detectado

La variable objetivo se construye con criterio temporal sobre el 31 de diciembre de 2025 (recencia superior a 365 días). Por definición matemática, un cliente clasificado como churn no puede registrar ninguna operación durante el año 2025, lo que produce que `ops_y2025 = 0` y `fact_y2025 = 0` en el 100 % de los casos churners. Esta asociación es trivial y circular: si se introducen estas variables en el modelo, alcanzará valores de AUC artificialmente elevados que no reflejan capacidad predictiva genuina sino una recuperación tautológica de la propia definición del target.

La corrección aplicada elimina 21 variables totales del conjunto inicial de 53: seis variables por data leakage directo del ejercicio 2025, cinco variables por redundancia con correlación de Spearman superior a 0,95 (`facturacion_combinada`, `pct_operaciones_oi`, `num_skus_distintos`, `unidades_vendidas`, `ops_media_3y_previos`), y diez variables por baja variabilidad efectiva (`op_black_friday`, `op_san_valentin`, `descuento_total_eur`, `C0_pen_provincia`, los cinco perfiles MOSAIC binarios y `tiene_mosaic`).

Conjunto final tras la corrección

- Features originales candidatas: 53
- Eliminadas por data leakage: 6
- Eliminadas por redundancia: 5
- Eliminadas por baja variabilidad: 10
- **Features finales del modelo: 37**
(incluye 32 numéricas + 5 dummies de cluster)

Esta detección y corrección sistemática constituye una práctica estándar en proyectos de modelado predictivo profesionales (Kuhn & Johnson 2019, *Applied Predictive Modeling*; Géron 2022, *Hands-On Machine Learning*). Su documentación explícita en este capítulo responde a criterios de honestidad académica y reproducibilidad.

6. Modelado comparativo de los cuatro algoritmos

La estrategia metodológica seleccionada consiste en la comparativa explícita de cuatro algoritmos de clasificación binaria que cubren el espectro de complejidad y aporte académico estándar en proyectos profesionales de modelado predictivo. El primer modelo es la Regresión Logística regularizada con L2, que sirve como baseline interpretable. Los tres siguientes son ensembles basados en árboles: Random Forest (bagging), XGBoost (gradient boosting) y LightGBM (variante optimizada de gradient boosting). Todos los modelos se entrenan con `class_weight='balanced'` para gestionar el desbalance moderado del target, sin recurrir a SMOTE por su efecto descalibrador documentado en la literatura.

6.1 Comparativa de métricas en el conjunto de test

Modelo	AUC-ROC	PR-AUC	F1	Precision	Recall	Brier
Logistic Regression	0,9622	0,9166	0,8385	0,7626	0,9312	0,0813
Random Forest	0,9751	0,9573	0,8799	0,8981	0,8623	0,0588
XGBoost	0,9825	0,9714	0,9081	0,9216	0,8949	0,0485
LightGBM (elegido)	0,9828	0,9732	0,9114	0,9286	0,8949	0,0506




Fig. 5 — Curvas ROC (izquierda) y Precision-Recall (derecha) comparativas de los cuatro modelos en el conjunto de test. LightGBM domina marginalmente al resto en ambos espacios.

La curva ROC (Receiver Operating Characteristic) representa el trade-off entre la tasa de verdaderos positivos y la tasa de falsos positivos. Los cuatro modelos producen curvas claramente desviadas de la diagonal (clasificador aleatorio), lo que confirma su utilidad predictiva. La curva del LightGBM domina marginalmente a las restantes en todo el rango.

La curva Precision-Recall es la métrica preferida en problemas con clases desbalanceadas (Saito & Rehmsmeier 2015), dado que no es engañada por la abundancia de la clase mayoritaria. El baseline aleatorio en esta curva es la proporción de positivos del conjunto de test (0,335). Todos los modelos se sitúan muy por encima del baseline, con LightGBM y XGBoost prácticamente solapados en posición dominante. La selección final del modelo se realiza por PR-AUC, lo que arroja LightGBM como ganador con valor 0,9732.

7. Calibración de probabilidades y threshold tuning

7.1 Calibración mediante isotonic regression




Fig. 6 — Curva de calibración antes y después de aplicar isotonic regression (izquierda) y distribución de probabilidades por target tras calibración (derecha).

La calibración de probabilidades es una etapa crítica frecuentemente omitida. Un modelo bien calibrado es aquel en el que las probabilidades predichas se aproximan a las frecuencias reales observadas: si el modelo predice probabilidad de churn del 0,7 para un grupo de clientes, aproximadamente el 70 % de ellos debe efectivamente ser churn. Se aplica el método isotonic regression mediante `CalibratedClassifierCV` con tres pliegues, técnica no paramétrica que aprende una función monótona creciente que mapea las probabilidades predichas originales a probabilidades calibradas.

Resultado de la calibración

- Brier score antes de calibrar: 0,0506
- Brier score tras isotonic regression: 0,0489
- Mejora: +3,36 %

La distribución de probabilidades por target confirma la separación efectiva entre los dos grupos: los clientes activos se concentran en probabilidades bajas (cerca de 0) y los churners en altas (cerca de 1), con un solapamiento moderado en la zona intermedia que es objeto del threshold tuning posterior.

7.2 Selección del threshold óptimo




Fig. 7 — Análisis del trade-off Precision vs Recall según threshold. El máximo de F1 se alcanza en threshold = 0,45.

El threshold de decisión por defecto en los clasificadores binarios es 0,5: cualquier observación con probabilidad predicha mayor o igual a este valor se clasifica como churn. Sin embargo, este threshold rara vez es óptimo en problemas reales. La elección del threshold debe responder al coste relativo de los dos tipos de errores que el modelo puede cometer: falsos negativos (no detectar a un cliente que efectivamente abandonará, lo que supone perder facturación sin oportunidad de actuar) y falsos positivos (clasificar como churn a un cliente que permanece activo, lo que supone aplicar acciones de retención innecesarias con su coste comercial asociado).

El análisis evalúa precision, recall y F1 a lo largo de un grid de umbrales entre 0,20 y 0,80 con paso 0,05. La precisión crece monótonamente con el threshold (un modelo más exigente para clasificar como churn produce más aciertos sobre sus predicciones positivas), mientras que el recall decrece monótonamente. El F1, media armónica de ambas métricas, presenta un máximo en threshold 0,45 con valor 0,9038.

Matriz de confusión con threshold óptimo = 0,45

Predicho Activo Predicho Churn

Real Activo (547): 521 26

Real Churn (276): 27 249

- **Accuracy global: 94 %**
- Recall (churn): 90,2 % · capturamos 9 de cada 10 churners reales
- Precision (churn): 90,5 % · 9 de cada 10 alertas son correctas
- Falsos positivos: 26 (5 % del total de activos)
- Falsos negativos: 27 (10 % de los churners reales)

8. Interpretabilidad del modelo mediante SHAP values

Los modelos de gradient boosting son frecuentemente criticados por su carácter de caja negra: aunque alcanzan métricas excelentes, no resulta inmediato explicar por qué predicen lo que predicen. Esta opacidad es problemática en contextos comerciales donde el equipo de retención necesita entender no solo qué clientes están en riesgo sino también por qué.

Los SHAP values (SHapley Additive exPlanations) son una técnica de explicabilidad basada en la teoría de juegos cooperativos (Lundberg & Lee 2017) que descompone cada predicción individual en contribuciones cuantificadas de cada feature. Para cada cliente concreto, el SHAP value de una feature representa cuánto contribuye esa feature a desviar la predicción respecto al valor base (la probabilidad media del modelo). Las contribuciones suman exactamente la diferencia entre la predicción individual y el valor base, propiedad de eficiencia que distingue a SHAP de otras técnicas de importancia.

Bootstrap Validation del modelo LightGBM · 1000 iteraciones




Fig. 8 — SHAP Feature Importance: las quince features más influyentes ordenadas por la media de su valor absoluto SHAP en el conjunto de test.

8.1 Ranking de features más predictivas

#	Feature	Importancia SHAP	Interpretación
1	meses_activo	3,98	Intensidad temporal de la relación
2	cluster_1	2,45	Pertenencia al Núcleo Estratégico (protector)
3	num_temporadas_activas	2,04	Diversidad temporal de compra
4	fact_y2022	1,64	Facturación histórica base
5	facturacion_retail_neta_eur	1,43	Tamaño económico del cliente
6	tendencia_ops_24_vs_23	1,23	Dinámica reciente (clave para churn)
7	fact_y2023	1,19	Facturación histórica reciente
8	antigüedad_dias	1,13	Edad de la relación comercial

9	facturacion_b2b	1,00	Tamaño económico canal B2B
10	ops_y2022	0,99	Volumen histórico base




Fig. 9 — SHAP Summary Plot (beeswarm). Cada punto representa una predicción individual; color rojo indica valor alto de la feature, azul valor bajo. Posición horizontal indica contribución a la predicción (derecha = empuja hacia churn).

Interpretación de los SHAP values más relevantes

meses_activo (3,98): features con valor alto (rojo) se concentran en la zona izquierda (contribución negativa al churn) → muchos meses de actividad protege fuertemente contra el churn.

cluster_1 (2,45): la pertenencia al Núcleo Estratégico (valor 1, rojo) empuja la predicción hacia activo, cuantificando el efecto protector del segmento más fiel.

tendencia_ops_24_vs_23 (1,23): features con valor bajo (azul, tendencia negativa) se concentran en la derecha (contribución positiva al churn) → un cliente que pierde actividad interanual tiene mayor probabilidad de abandonar la relación. Esta feature, libre de leakage, es una de las más predictivas del modelo.

La presencia del cluster_1 en el top 5 confirma cuantitativamente la utilidad del clustering del Capítulo 5 como input predictivo para el churn, validando la coherencia entre ambos análisis.

9. Análisis cuádruple de robustez

El modelo seleccionado alcanzó un AUC-ROC de 0,9828 y un PR-AUC de 0,9732 en el conjunto de test, valores excepcionalmente altos que merecen un análisis crítico explícito. La literatura especializada documenta que en problemas de churn predictivo con horizontes temporales de doce meses, los valores típicos en la industria oscilan entre 0,75 y 0,90, lo que sitúa los resultados obtenidos en el extremo superior del rango. Este apartado desarrolla cuatro análisis complementarios independientes para validar la robustez del modelo y descartar la presencia de overfitting o leakage temporal residual.

9.1 Análisis 1 — Modelo "puro" sin features acumulativas

Las features acumulativas son aquellas cuyo valor numérico depende del historial total del cliente y podrían incorporar implícitamente información sobre el período de evaluación del target. Aunque este efecto es sutil y no constituye leakage directo, conviene verificar que el modelo no depende exclusivamente de estas variables. Se entrena un LightGBM alternativo utilizando exclusivamente 24 features no acumulativas: indicadores binarios de cluster, tendencias interanuales 2024 vs 2023, históricos anuales pre-2025, variables sociodemográficas y geográficas.

Métrica	Modelo final	Modelo puro	Diferencia
AUC-ROC	0,9828	0,9527	+0,0301
PR-AUC	0,9732	0,9180	+0,0552
F1	0,9114	0,8530	+0,0584
Precision	0,9286	0,8545	+0,0741
Recall	0,8949	0,8514	+0,0435
Brier	0,0506	0,0874	-0,0368

Conclusión análisis 1: el modelo "puro" mantiene AUC-ROC de 0,9527, valor altamente competitivo. El gap entre modelo final y modelo puro asciende a +0,0301 puntos de AUC-ROC, **valor inferior al umbral de 0,05 que la literatura considera indicativo de posible leakage temporal**. Esto confirma que las features acumulativas aportan información complementaria genuina y no simplemente una proxy del target.

9.2 Análisis 2 — Bootstrap validation (1.000 iteraciones)

La validación out-of-time directa no es aplicable en este problema concreto debido a que la definición operativa del target está intrínsecamente ligada a la fecha de última operación: los clientes con última operación anterior a 2025 son churners al 100 % por construcción, y los clientes con última operación en 2025 son activos al 100 % por la misma razón. Esta tautología invalida la partición temporal simple como estrategia de validación.

Se sustituye por bootstrap validation, técnica de remuestreo estadístico (Efron 1979) estándar en problemas donde la división temporal no es viable. El procedimiento consiste en realizar 1.000 re-muestreos del conjunto de test con reemplazo y calcular las métricas en cada muestra, lo que permite estimar la distribución empírica del AUC-ROC y construir intervalos de confianza al 95 %.




Fig. 10 — Distribuciones bootstrap de AUC-ROC (izquierda), PR-AUC (centro) y F1 (derecha) tras 1.000 iteraciones. Las líneas rojas marcan los percentiles 2,5 y 97,5 que definen el intervalo de confianza al 95 %.

Métrica	Media	Desv. típica	IC 95% inf.	IC 95% sup.	Anchura IC
AUC-ROC	0,9830	0,0039	0,9749	0,9900	0,0151
PR-AUC	0,9735	0,0054	0,9621	0,9832	0,0211
F1	0,9115	0,0133	0,8848	0,9362	0,0514

Conclusión análisis 2: el intervalo de confianza al 95 % del AUC-ROC es [0,9749, 0,9900], cuya anchura de 0,0151 puntos representa apenas el 1,5 % del valor estimado. **La práctica industrial considera modelos con anchuras de IC 95 % inferiores a 0,03 como altamente estables;** el modelo final se sitúa en la mitad de este umbral. El rendimiento del modelo no es un artefacto de la partición aleatoria específica utilizada en el entrenamiento, sino una propiedad robusta del modelo y de los datos.

9.3 Análisis 3 — Calibración por cluster

El análisis de calibración por cluster verifica que la fiabilidad del modelo no se concentra en un subconjunto particular de la cartera sino que se mantiene uniformemente alta en todos los segmentos comportamentales. Esta verificación es relevante porque un modelo con buena calibración agregada pero mal calibrado en algún subgrupo concreto podría producir decisiones operativas erróneas para ese subgrupo.

Cluster	Nombre	N test	Proba pred.	Tasa real	Gap
C0	Clientes en Riesgo	80	0,5093	0,5250	-0,0157
C1	Núcleo Estratégico	396	0,0432	0,0505	-0,0073
C2	Grandes Cuentas Int.	39	0,2751	0,2821	-0,0069
C3	Reposicionistas Trad.	107	0,6879	0,6822	+0,0057
C4	Compradores Estacionales	201	0,6304	0,6468	-0,0164

Conclusión análisis 3: los gaps absolutos entre probabilidad media predicha y tasa real observada son inferiores al 2 % en todos los clusters. El gap absoluto medio es del 1,01 % y el máximo del 1,71 %. **La literatura considera modelos con gaps absolutos máximos inferiores al 5 % como bien calibrados a nivel segmento;** el modelo final se sitúa muy por debajo de este umbral. Especialmente relevante es la excelente calibración en el Núcleo Estratégico (gap 0,73 %), segmento donde la fiabilidad de las predicciones tiene mayor valor económico por su ticket medio elevado.

9.4 Análisis 4 — Validación territorial cruzada con el Capítulo 6

La validación territorial constituye una verificación externa final del modelo: si las probabilidades de churn estimadas a nivel individual se agregan por provincia, deberían reproducir las tasas reales de churn observadas en cada territorio. Una coincidencia razonable entre probabilidad media predicha y tasa real observada respalda la generalización del modelo.

Provincia	N clientes	Proba media	Tasa real	Gap
Pontevedra (paradoja histórica)	76	0,3890	0,3816	+0,0074
Valencia (alerta C0)	—	0,3044	0,2833	+0,0211
Alicante (alerta C0)	—	0,3277	0,3333	-0,0056
A Coruña (Galicia Núcleo)	—	0,2922	0,3385	-0,0463
Lugo (Galicia Núcleo)	—	0,3212	0,3103	+0,0109
Ourense (Galicia Núcleo)	—	0,2162	0,3043	-0,0881
Madrid (mercado infraexplotado)	61	0,4016	0,4426	-0,0410

Conclusión análisis 4: el modelo reproduce las tasas reales de churn por provincia con gaps inferiores a 5 puntos porcentuales en la mayor parte de los casos. **La paradoja del territorio histórico documentada en el Capítulo 6 (Pontevedra como concentrador simultáneo de Núcleo Estratégico y problemáticos) se captura adecuadamente:** el modelo predice 38,9 % vs la realidad de 38,2 % (gap inferior a un punto porcentual). La alerta territorial de la Comunidad Valenciana (Capítulo 6) se confirma cuantitativamente con probabilidades coherentes en Valencia y Alicante.

10. Ranking final de clientes en riesgo

El ranking final constituye el aporte operativo del notebook 13 al negocio. Se restringe a clientes que figuran como activos en el momento del análisis (recencia inferior a 365 días) y se ordena por probabilidad estimada de churn descendente. Esta restricción es deliberada: el modelo se utiliza como herramienta de prevención, no como confirmación de churn ya consumado, por lo que el universo de interés operativo son los clientes que todavía pueden ser objeto de acciones de retención.

Cifras clave del ranking TOP 100

- Clientes en el TOP 100: 100 (de 1.821 activos totales)
- Facturación total acumulada: **1.603.722 €**
- Facturación media por cliente: 16.037 €
- Probabilidades de churn: rango 0,51 – 0,83

10.1 Distribución del TOP 100 por cluster

Cluster	Nombre comercial	Clientes en TOP 100
C3	Reposicionistas Tradicionales	35
C4	Compradores Estacionales	22
C1	Núcleo Estratégico	17
C0	Clientes en Riesgo	17
C2	Grandes Cuentas Internacionales	9

La distribución del TOP 100 por cluster es comercialmente reveladora. Los Reposicionistas Tradicionales aportan 35 clientes al top (35 %), coherente con su elevada tasa de churn global del 67 %. Los Compradores Estacionales contribuyen con 22 clientes, también coherente con su tasa del 64 %. La presencia de 17 clientes del Núcleo Estratégico en el TOP 100 es comercialmente preocupante: aunque la tasa global del cluster es del 4 %, los 17 casos identificados son precisamente los que se desvían del comportamiento medio del cluster y requieren atención comercial urgente. La presencia de 9 Grandes Cuentas Internacionales merece máxima atención por la magnitud económica individual asociada.

10.2 Caso de máxima prioridad: cliente 7590

Cliente identificador 7590 — Caso de prioridad máxima

- Provincia: Las Palmas
- Cluster: Grandes Cuentas Internacionales (C2)
- Facturación histórica acumulada: **95.646 €**
- Probabilidad estimada de churn: **52,6 %**
- Recencia: 159 días · Operaciones acumuladas: 649

Este cliente individualiza el valor económico extraordinario en riesgo y constituye el primer caso priorizable de la estrategia comercial del Capítulo 8. La combinación de alta facturación histórica, pertenencia al cluster de mayor valor económico medio y probabilidad de churn superior al 50 % justifica la asignación inmediata de un gestor comercial específico para esta cuenta.

11. Limitaciones, síntesis y conexión con el Capítulo 8

11.1 Limitaciones honestas del modelo

El presente trabajo documenta explícitamente las limitaciones del modelo desarrollado, siguiendo el principio de honestidad académica que prima sobre la perfección numérica aparente. Tres limitaciones merecen mención explícita.

En primer lugar, el **horizonte temporal de los datos es limitado**: el análisis dispone de cuatro años de histórico (2022-2025), lo que restringe la capacidad de capturar ciclos largos de fidelización y reduce la robustez de las tendencias interanuales a solo dos puntos efectivos (2024 vs 2023 y 2025 vs 2024). Un dataset histórico de diez o más años permitiría modelar ciclos de relación comercial más amplios.

En segundo lugar, la **definición temporal del target es agregada**: la ventana de 365 días captura el estado binario churn/activo pero pierde información granular mes a mes. Un modelo de supervivencia (time-to-churn) en lugar de clasificación binaria permitiría predecir no solo si un cliente abandonará la relación sino cuándo, información comercialmente relevante para la priorización temporal de las acciones de retención.

En tercer lugar, el modelo **no incorpora variables exógenas**: factores macroeconómicos (crisis, inflación), acciones comerciales pasadas (visitas, descuentos personalizados, campañas) y datos de CRM (incidencias, reclamaciones) no están disponibles en el dataset actual. La integración de estas fuentes en futuras iteraciones del modelo podría mejorar tanto la capacidad predictiva como la interpretabilidad operativa.

11.2 Síntesis del Capítulo 7

Síntesis ejecutiva

El Capítulo 7 desarrolla un modelo predictivo binario de churn que constituye la pieza técnica central del TFG. Sobre un perímetro de 2.741 clientes activos con histórico mínimo de doce meses, el modelo LightGBM seleccionado tras comparativa con tres alternativas alcanza AUC-ROC de 0,9828 y PR-AUC de 0,9732, con F1 de 0,9038 en threshold óptimo de 0,45. La robustez del modelo se verifica mediante un programa cuádruple de validación que incluye comparativa con modelo reducido (AUC 0,9527 sin features acumulativas), bootstrap con 1.000 iteraciones (IC 95 % [0,9749, 0,9900]), calibración por cluster (gap máximo 1,71 %) y validación territorial cruzada con los hallazgos del Capítulo 6. La interpretabilidad mediante SHAP values confirma que las features más predictivas (meses_activo, cluster_1, tendencia_ops_24_vs_23) son legítimas y reproducen los hallazgos del análisis exploratorio. El ranking de 100 clientes con mayor probabilidad de churn concentra 1,6 millones de euros de facturación histórica y constituye la entrada principal del Capítulo 8.

11.3 Conexión con el Capítulo 8 (Recomendaciones y ROI)

El fichero output/churn_predicciones.parquet contiene el ranking completo de los 1.821 clientes activos del perímetro analítico, ordenados por probabilidad de churn descendente y enriquecido con las variables comerciales clave (cluster, provincia, facturación histórica, antigüedad, número de operaciones). Este fichero será la entrada principal del notebook 14 (Capítulo 8), que estimará el retorno económico esperado de las acciones de retención priorizadas según el modelo desarrollado en el presente capítulo.

Líneas de acción para el Capítulo 8

- **Priorización individual:** caso 7590 (Las Palmas, 95.646 €, 52,6 % proba) como primer target operativo.
- **Priorización por cluster:** 17 clientes del Núcleo Estratégico en TOP 100 como casos de vigilancia activa.
- **Cruce con huecos territoriales del Cap. 6:** combinación de retención (TOP riesgo) con captación (Madrid 127 clientes captables).
- **Vigilancia territorial:** Pontevedra, Vigo, Comunidad Valenciana como zonas identificadas de riesgo elevado.
- **Estimación de ROI:** cálculo del valor económico recuperable mediante acciones de retención efectivas sobre el ranking.