

Introducción

TFG · Análisis de cliente y geomarketing en moda íntima — Caso de estudio Selmark S.L.U.

Universidad Alfonso X El Sabio · Escuela Business & Tech · Grado en Ingeniería Matemática

1.1 Contexto: empresa y sector

El sector de la moda íntima opera en un entorno crecientemente competitivo en el que el conocimiento profundo del cliente se ha convertido en un activo estratégico de primer orden. En ese contexto se enmarca este trabajo. Selmark S.L.U. es una empresa española del sector, con sede en Galicia y una trayectoria consolidada tanto en el mercado nacional como en el internacional. Su modelo de negocio es marcadamente dual: opera un canal mayorista B2B, que distribuye colección por temporadas a una amplia red de clientes profesionales, y un canal retail minorista. Durante el cuatrienio 2022-2025 ambos canales han generado de forma conjunta una facturación documentada del orden de 170 millones de euros, repartida de manera prácticamente equilibrada entre los dos.

El sector presenta una estacionalidad propia, articulada en torno a las temporadas de colección (primavera-verano y otoño-invierno) y a eventos comerciales como San Valentín o las rebajas. Comprender el comportamiento de compra de la cartera de forma cuantitativa constituye el punto de partida de este trabajo.

1.2 Motivación y planteamiento del problema

La información comercial de Selmark se encontraba dispersa en distintas fuentes operacionales del ERP — maestro de clientes, pedidos mayoristas, operaciones retail y enriquecimiento sociodemográfico externo— sin un modelo analítico unificado que permitiera una visión integral del cliente. Esta fragmentación dificultaba responder a preguntas estratégicas básicas: quiénes son los clientes más valiosos, cómo se distribuyen geográficamente, qué patrones estacionales siguen, qué clientes presentan riesgo de abandono y dónde existen oportunidades de captación.

El presente trabajo aborda ese problema construyendo una base analítica única a partir de las fuentes originales y aplicando sobre ella técnicas cuantitativas de análisis de cliente y geomarketing, con el fin de traducir los datos en recomendaciones comerciales cuantificadas.

1.3 Objetivos

El objetivo general del proyecto es desarrollar un sistema de análisis de cliente y geomarketing para Selmark que, partiendo de las fuentes operacionales, permita caracterizar la cartera y fundamentar decisiones comerciales. Este objetivo se concreta en los siguientes objetivos específicos:

- **Unificación de datos.** Integrar las fuentes del ERP en una base analítica única mediante una arquitectura por capas y procesos de ETL reproducibles.
- **Análisis descriptivo.** Caracterizar la cartera en sus dimensiones económica, territorial, temporal y sociodemográfica.
- **Segmentación de clientes.** Identificar segmentos de comportamiento homogéneo mediante técnicas de clustering (K-Means).
- **Geomarketing.** Analizar la distribución territorial de la cartera y detectar huecos de mercado con potencial de captación.

- **Previsión de demanda.** Modelar la facturación mediante series temporales (SARIMA) para anticipar su evolución.
- **Riesgo de abandono.** Estimar el riesgo de pérdida de clientes (churn) con técnicas de aprendizaje supervisado.
- **Recomendaciones y ROI.** Formular acciones comerciales segmentadas y cuantificar su retorno potencial.

1.4 Datos y alcance del proyecto

El estudio se circunscribe a los 3.492 clientes activos del cuatrienio 2022-2025, descritos a partir de tres fuentes operacionales de Selmark —maestro de clientes, líneas de pedido B2B y operaciones retail— y una fuente externa de enriquecimiento sociodemográfico por código postal (tipologías Experian MOSAIC, obtenidas de forma independiente). El resultado de la integración es una tabla con una fila por cliente y 56 variables, base de todos los análisis posteriores.

3.492 Clientes activos (2022-2025)	2.105 / 1.387 Nacional / internacional
≈ 170 M€ Facturación documentada	339.705 Líneas de pedido B2B
2.867.565 Operaciones retail	56 Variables · 5 bloques

1.5 Estructura de la memoria

La memoria se organiza siguiendo el flujo natural del proyecto, desde la construcción de la base de datos hasta las recomendaciones finales:

Capítulo	Contenido
1. Introducción	Contexto, problema, objetivos y alcance del trabajo.
2. Marco teórico	Fundamentos de Business Intelligence y técnicas analíticas empleadas.
3. Metodología y arquitectura	Enfoque de BI, arquitectura técnica, modelo de datos y decisiones clave.
4. Análisis descriptivo	Caracterización económica, temporal y sociodemográfica de la cartera.
5. Segmentación de clientes	Clustering K-Means y caracterización comercial de los segmentos.
6. Geomarketing	Distribución territorial y detección de oportunidades de captación.
7. Análisis de churn	Modelado del riesgo de pérdida de clientes.
8. Conclusiones y ROI	Recomendaciones comerciales y cuantificación del retorno.

Nota. El análisis de series temporales (SARIMA) se incorpora como anexo del trabajo.

Marco teórico y estado del arte

Fundamentos conceptuales y revisión de la literatura de las técnicas analíticas empleadas en el trabajo

Este capítulo establece el marco conceptual sobre el que se construye el trabajo y revisa el estado del arte de las técnicas que se aplican en los capítulos posteriores. El proyecto se inscribe en la disciplina de la analítica de cliente (*customer analytics*), entendida como la aplicación de métodos cuantitativos al conocimiento del comportamiento del cliente para fundamentar decisiones comerciales. La revisión se organiza siguiendo el flujo metodológico del trabajo: la arquitectura analítica de datos, la caracterización del cliente, la segmentación no supervisada, el geomarketing, la previsión de demanda, la predicción del abandono y, por último, la cuantificación económica del retorno.

2.1 Inteligencia de negocio y arquitectura analítica de datos

La inteligencia de negocio (*Business Intelligence*, BI) engloba el conjunto de procesos y tecnologías que transforman datos operacionales en información útil para la toma de decisiones. Chen, Chiang y Storey (2012) sitúan su evolución desde los sistemas de informes tradicionales hacia la analítica avanzada y el aprendizaje automático, y subrayan el desplazamiento del valor desde el almacenamiento del dato hacia su explotación predictiva. En el plano arquitectónico, el paradigma del almacén de datos dimensional (Kimball y Ross, 2013) y su evolución por capas de calidad creciente —popularizada como arquitectura *medallion* (Bronce, Plata, Oro)— se ha consolidado como estándar de ingeniería de datos por su trazabilidad y su separación entre ingesta, transformación y consumo, principios que vertebran la arquitectura del presente trabajo.

2.2 Analítica de cliente: el modelo RFM y el valor del cliente

La caracterización cuantitativa de la cartera se apoya tradicionalmente en el modelo RFM —*Recency, Frequency, Monetary*—, formalizado por Hughes (1994) como un esquema parsimonioso que resume el comportamiento de compra en tres dimensiones: cuán reciente, cuán frecuente y de qué valor es la relación. Fader, Hardie y Lee (2005) demostraron la conexión entre las variables RFM y el valor del cliente a lo largo del tiempo (*Customer Lifetime Value*), estableciendo que las variables conductuales son mejores predictoras del comportamiento futuro que los atributos puramente sociodemográficos. Esta evidencia fundamenta la decisión metodológica, central en este trabajo, de construir la segmentación sobre variables de comportamiento de compra y no sobre la renta o el perfil del entorno del cliente.

2.3 Reducción de dimensionalidad y segmentación no supervisada

La segmentación agrupa a los clientes en conjuntos de comportamiento homogéneo. Entre las técnicas no supervisadas, el algoritmo K-Means (MacQueen, 1967; Lloyd, 1982) es uno de los más extendidos: particiona los datos en k grupos minimizando la varianza intra-grupo. Su aplicación al ámbito del marketing fue sistematizada por Punj y Stewart (1983), que recomiendan combinar varios criterios de validación para fijar el número de grupos en lugar de confiar en un único índice. Es práctica habitual precederlo de un Análisis de Componentes Principales (PCA; Jolliffe, 2002), que reduce la dimensionalidad y mitiga la multicolinealidad antes del agrupamiento, mejorando la convergencia y la interpretabilidad de los segmentos resultantes.

2.4 Geomarketing y segmentación geodemográfica

El geomarketing incorpora la dimensión territorial al análisis comercial, cruzando la cartera con información geográfica y sociodemográfica del entorno de cada cliente (Cliquet, 2006). Su instrumento característico es la segmentación geodemográfica, que clasifica las unidades territoriales —en este caso,

los códigos postales— en perfiles de consumo homogéneos. Las tipologías MOSAIC de Experian son un exponente consolidado de este enfoque, ampliamente empleado para caracterizar el contexto socioeconómico y detectar áreas con potencial de captación no explotado. El análisis per cápita —normalizado por población— es la práctica recomendada para neutralizar el sesgo que la densidad poblacional introduce en los recuentos absolutos.

2.5 Previsión de demanda mediante series temporales

El análisis de series temporales modela la evolución de una magnitud a lo largo del tiempo. La metodología de Box y Jenkins (1970) para los modelos ARIMA y su extensión estacional SARIMA constituye el marco de referencia clásico, al capturar de forma explícita la tendencia y la estacionalidad de la serie y producir previsiones acompañadas de intervalos de confianza. Hyndman y Athanasopoulos (2021) sistematizan las buenas prácticas de selección y diagnóstico de estos modelos, advirtiendo de los riesgos de las búsquedas automáticas por criterios de información cuando comprometen la significatividad de los coeficientes o la invertibilidad del modelo —compromiso que se documenta explícitamente en el anexo de este trabajo.

2.6 Predicción del abandono de clientes y aprendizaje supervisado

La predicción del abandono (*churn*) se aborda como un problema de clasificación supervisada. El estudio comparativo de Neslin et al. (2006) estableció que la elección de la técnica de modelado influye de forma material en el valor económico capturado, y Verbeke et al. (2012) actualizaron esa evidencia incorporando criterios de interpretabilidad y de rentabilidad. En cuanto a los algoritmos, el trabajo compara una regresión logística regularizada (base interpretable) con tres *ensembles* de árboles: *Random Forest* (Breiman, 2001) y los métodos de potenciación del gradiente XGBoost (Chen y Guestrin, 2016) y LightGBM (Ke et al., 2017). Dos cuestiones metodológicas son críticas en este dominio. La primera es el desbalance de clases: Burez y Van den Poel (2009) documentan su impacto en la predicción de *churn* y Saito y Rehmsmeier (2015) justifican el uso de la curva *Precision-Recall* frente a la curva ROC cuando los positivos son escasos. La segunda es la fuga de información (*data leakage*): Kaufman et al. (2012) la describen como una de las causas más frecuentes de métricas artificialmente infladas, especialmente cuando variables construidas sobre la ventana del objetivo filtran la respuesta al modelo —fenómeno que este trabajo detecta y corrige de forma explícita. Por último, la interpretabilidad se aborda mediante los valores SHAP (Lundberg y Lee, 2017), que descomponen cada predicción en la contribución cuantificada de cada variable.

2.7 Cuantificación del retorno: aprendizaje sensible al coste y análisis coste-beneficio

La traducción de un modelo predictivo en valor económico exige superar las métricas estadísticas y adoptar una perspectiva de coste-beneficio. Elkan (2001) formaliza el aprendizaje sensible al coste, asignando un valor económico diferenciado a cada tipo de acierto y de error del clasificador. Sobre esa base, Verbeke et al. (2012) defienden los enfoques orientados al beneficio (*profit-driven*), que valoran las celdas de la matriz de confusión —verdaderos y falsos positivos y negativos— en términos del retorno de la acción comercial asociada. Este es precisamente el marco que articula la cuantificación del retorno de la inversión (ROI) del último capítulo, donde el valor de las predicciones del modelo de abandono se evalúa frente al contrafactual de no actuar.

Síntesis del marco

El trabajo se apoya en un cuerpo de literatura consolidado: una arquitectura de datos por capas (BI), una caracterización conductual del cliente (RFM), una segmentación no supervisada validada con múltiples criterios (PCA y K-Means), una capa territorial (geomarketing geodemográfico), una previsión estacional (SARIMA), una predicción de abandono con aprendizaje supervisado —atenta al desbalance, a la fuga de datos y a la interpretabilidad— y una cuantificación del retorno sensible al coste. Los capítulos siguientes aplican este marco al caso de Selmark S.L.U.

2.8 Referencias principales

- Box, G. E. P. y Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- Burez, J. y Van den Poel, D. (2009). Handling class imbalance in customer churn prediction. *Expert Systems with Applications*, 36(3), 4626-4636.
- Chen, H., Chiang, R. H. L. y Storey, V. C. (2012). Business Intelligence and Analytics: From Big Data to Big Impact. *MIS Quarterly*, 36(4), 1165-1188.
- Chen, T. y Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proc. 22nd ACM SIGKDD*, 785-794.
- Cliquet, G. (ed.) (2006). *Geomarketing: Methods and Strategies in Spatial Marketing*. ISTE.
- Elkan, C. (2001). The Foundations of Cost-Sensitive Learning. *Proc. IJCAI*, 973-978.
- Fader, P. S., Hardie, B. G. S. y Lee, K. L. (2005). RFM and CLV: Using Iso-Value Curves for Customer Base Analysis. *Journal of Marketing Research*, 42(4), 415-430.
- Hughes, A. M. (1994). *Strategic Database Marketing*. Probus Publishing.
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts.
- Jolliffe, I. T. (2002). *Principal Component Analysis* (2.ª ed.). Springer.
- Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in Data Mining. *ACM TKDD*, 6(4), 1-21.
- Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in NeurIPS*, 30.
- Kimball, R. y Ross, M. (2013). *The Data Warehouse Toolkit* (3.ª ed.). Wiley.
- Lloyd, S. P. (1982). Least Squares Quantization in PCM. *IEEE Trans. Information Theory*, 28(2), 129-137.
- Lundberg, S. M. y Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in NeurIPS*, 30.
- MacQueen, J. (1967). Some Methods for Classification and Analysis of Multivariate Observations. *Proc. 5th Berkeley Symposium*, 281-297.
- Neslin, S. A., Gupta, S., Kamakura, W., Lu, J. y Mason, C. H. (2006). Defection Detection. *Journal of Marketing Research*, 43(2), 204-211.
- Punj, G. y Stewart, D. W. (1983). Cluster Analysis in Marketing Research. *Journal of Marketing Research*, 20(2), 134-148.
- Saito, T. y Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot on Imbalanced Datasets. *PLOS ONE*, 10(3).
- Verbeke, W., Dejaeger, K., Martens, D., Hur, J. y Baesens, B. (2012). New insights into churn prediction. *European Journal of Operational Research*, 218(1), 211-229.

Metodología y arquitectura del proyecto

Enfoque de Business Intelligence · arquitectura técnica · modelo de datos

3.1 Enfoque metodológico

El proyecto se aborda como un trabajo de *Business Intelligence* clásico, siguiendo la estructura piramidal empleada a nivel de consultoría. La pirámide ordena el trabajo en cuatro niveles: en la base, las fuentes de datos; sobre ellas, el ETL y la arquitectura de transformación; encima, el almacén analítico que consolida la información; y en la cima, el análisis y la visualización que sostienen la decisión comercial. A medida que se asciende, el **volumen de datos disminuye** y el **valor de negocio aumenta**: cada nivel se corresponde con una fase del proyecto.




Figura 1. Pirámide de Business Intelligence aplicada al proyecto. Cada nivel se corresponde con una fase del TFG.

Nivel	Función	Fase del proyecto
Análisis y visualización	Traduce el dato en decisión comercial.	Power BI e informes (cap. 4-8)
Almacén analítico	Consolida la información en una tabla por cliente.	gold.cliente_360
ETL y arquitectura medallón	Limpia, normaliza e integra las fuentes.	Bronze → Silver → Gold
Fuentes de datos	Dato operacional en crudo.	Azure Databricks (4 tablas)

3.2 Stack técnico

El proyecto se ha desarrollado íntegramente con herramientas de código abierto sobre un entorno local, lo que garantiza su reproducibilidad. La tabla siguiente resume las herramientas empleadas y su función.

Herramienta	Función en el proyecto
DuckDB	Motor analítico: almacenamiento y procesamiento de las tres capas.
Python 3.11	Lenguaje de orquestación del pipeline y de análisis.
Jupyter Notebook	Entorno de desarrollo y documentación de cada fase.
pandas , numpy	Manipulación y transformación de datos tabulares.
holidays	Calendario oficial español de festivos para la dimensión temporal.
VS Code + Claude Code	Editor de código con asistencia al desarrollo.
Anaconda	Gestión de entornos y dependencias.

3.3 Arquitectura técnica

Los datos operacionales se originan en el entorno *cloud* de Selmark, una instancia de Microsoft Azure Databricks que aloja el maestro de clientes y las tablas del ERP. El enriquecimiento sociodemográfico no procede de Selmark: las tipologías Experian MOSAIC se obtuvieron de forma independiente y se incorporaron como fuente externa. Al no disponer de permisos de escritura sobre dicho entorno, la información se extrajo de forma local mediante la función `display()` del workspace, descargando cada tabla a fichero CSV. A partir de ahí, todo el procesamiento —las tres capas de datos y los notebooks de análisis (09 a 14)— se ejecuta en una máquina personal con DuckDB, generando como salidas los ficheros CSV de respaldo, las figuras y el modelo de Power BI. Se trata de una arquitectura híbrida, con Azure como origen y tratamiento posterior local, plenamente trazable.



Figura 2. Arquitectura técnica: origen en Azure, extracción manual y procesamiento local en DuckDB.

3.4 Arquitectura de datos: patrón Medallion

El procesamiento sigue el patrón Medallion, que organiza el trabajo en tres capas sucesivas y validadas. La capa **Bronze** ingiere las fuentes en crudo, sin transformación; la capa **Silver** aplica limpieza, normalización y reglas de negocio sobre cada fuente; y la capa **Gold** integra todo en una única tabla analítica por cliente, `gold.cliente_360`.



Figura 3. Flujo de transformación Bronze → Silver → Gold.

El paso de Bronze a Silver concentra el grueso de las reglas de negocio. La tabla siguiente documenta la volumetría y la transformación principal aplicada a cada fuente.

Fuente	Bronze	Silver	Transformación principal
dim_cliente	3.492	3.492	Clasificación nacional/internacional (reglas A/B/C/D).
fact_lineas_pedido	470.963	339.705	Filtro temporal, descarte de anulados, MAX por pedido.
ventas_minoristas	4.009.222	2.867.565	Filtro temporal e incorporación de importes (cobertura 100 %).
mosaic	6.457	6.457	Normalización de CP y derivación de 5 perfiles comerciales (fuente externa).
tiempo	—	1.461	Dimensión de calendario generada en Python (4 años).

3.5 Modelo de datos e integración

La tabla `gold.cliente_360` reúne 3.492 clientes y 56 variables organizadas en cinco bloques temáticos. Se construye tomando `silver.dim_cliente` como base e incorporando el resto de fuentes mediante uniones documentadas, específicas de cada bloque.




Figura 4. Mapa de integración: las seis tablas Silver y sus claves de unión hacia `gold.cliente_360`.

El modelo físico detalla la estructura relacional completa: cada tabla con sus claves primarias (PK) y

MOSAIC, tiempo) enriquecen el maestro de clientes, que a su vez actúa de eje sobre el que se agregan las tablas de hechos hasta construir la tabla analítica final.




Figura 5. Modelo físico de datos: claves primarias (PK), foráneas (FK) y relaciones de las tablas *silver* hacia *gold.cliente_360*.

Bloque	Variables	Contenido y cobertura
1 · Identificación	9	Identificador, razón social, mercado y país. Cobertura 100 %.
2 · Geográfico	12	Enriquecimiento MOSAIC (grupo, segmento, renta, 5 perfiles). Cartera nacional: 96,8 %.
3 · Económico B2B	6	Nº de pedidos, facturación, ticket medio e IVA. Presente en 88,3 % de clientes.
4 · Comportamiento + retail	17	Operaciones, unidades, devoluciones, facturación retail y canal. Presente en 87,5 %.
5 · Temporal	12	Recencia, antigüedad, frecuencia, estacionalidad y eventos comerciales.

3.6 Decisiones metodológicas clave

Tres decisiones condicionan la validez de todos los análisis posteriores y se documentan de forma explícita.

Regla D — rescate de clientes mal clasificados

El ERP clasificaba como internacionales a doce clientes españoles (entre ellos El Corte Inglés). Una cuarta regla los rescata por su identificador, elevando la cartera nacional de 2.093 a 2.105 clientes.

MAX por pedido — corrección de la granularidad B2B

La exportación de `fact_lineas_pedido` conserva una sola línea representativa por pedido; sumar el importe de cabecera infla la facturación en un factor próximo a 7,5. Se calcula con `MAX(importe_total_pedido)` por pedido, capturando los 85,2 M€ reales.

JOIN MOSAIC restringido a la cartera nacional

Códigos postales internacionales coinciden numéricamente con españoles (p. ej. 28100 en Madrid y en Novara). La condición `tipo_mercado = 'NACIONAL'` se incluye en el propio JOIN para evitar enriquecimientos erróneos.

La arquitectura modular descrita garantiza que cualquier ajuste futuro —nuevos clientes, actualización del ERP o refresco de MOSAIC— pueda realizarse **re-ejecutando únicamente los notebooks afectados**, preservando el resto del trabajo.

Análisis descriptivo de la cartera

Resumen visual de hallazgos · el desarrollo interactivo se realiza en Power BI

El análisis descriptivo caracteriza la cartera de Selmark en sus dimensiones económica, territorial, temporal y sociodemográfica. Dado que el detalle se desarrolla en el cuadro de mando de Power BI, este capítulo se concentra en los hallazgos de mayor relevancia comercial. La cartera responde a un modelo de negocio dual —mayorista B2B y retail minorista— en el que el 87 % de los clientes opera simultáneamente en ambos canales, con una facturación documentada cercana a los 170 millones de euros en el cuatrienio.

3.492

Clientes activos (2022-2025)

60 / 40

Nacional / internacional (%)

≈ 170 M€

Facturación documentada

87 %

Clientes multicanal (B2B + Retail)

2,98 M€

Pico mensual · septiembre

+133 %

San Valentín sobre día normal

4.1 Tres hallazgos críticos

Tres resultados, por su carácter contraintuitivo y su impacto metodológico, orientan los capítulos posteriores:

1 · Septiembre es el pico, diciembre el valle

La facturación retail alcanza su máximo en **septiembre (2,98 M€/mes)** y su mínimo en **diciembre (0,40 M€)**. El patrón refleja un negocio mayorista por temporadas de colección, no un retail puro, y refuta la intuición del refuerzo navideño.

2 · La renta del entorno NO predice el gasto

La correlación de Spearman entre la renta del código postal y la facturación del cliente es **$\rho = +0,004$** (prácticamente nula). El producto íntimo es transversal a los estratos socioeconómicos.

3 · Los perfiles MOSAIC NO separan por gasto

Los cinco perfiles presentan tickets medios casi idénticos (**30 – 44 K€**); Premium (34,9 K€) ≈ Sensible al precio (34,8 K€). Por eso la segmentación del Capítulo 5 se basa en variables conductuales, no sociodemográficas.

Panel ejecutivo de la cartera

Selmark · cuatrienio 2022-2025 · sin cuentas técnicas

3.492

Cientes activos

2.105 / 1.387

Nacional / internacional

≈ 170 M€

Facturación total

57,9 %







Factura el top 10 % B2B

Septiembre

Pico anual de facturación

ρ = +0,004

Renta vs gasto (nula)



Lectura del panel

Negocio mayorista estacional (pico en septiembre), muy concentrado en B2B (top 10 % = 57,9 % de la facturación) y con una dimensión internacional dominada por Italia y Portugal. Ni la renta del entorno ni los perfiles MOSAIC discriminan el gasto: la segmentación de clientes debe apoyarse en variables de comportamiento.

4.2 Lectura comercial

Los hallazgos del análisis descriptivo no son meramente académicos: cada uno se traduce en una orientación comercial concreta que se desarrollará y cuantificará en los capítulos posteriores del trabajo. Se resumen en tres líneas de actuación.

Calendario comercial

Concentrar la inversión en San Valentín (+133 % sobre un día normal) y en la ventana julio-septiembre, con desinversión proporcional en Black Friday (-65 %), un evento atípico para la lencería tradicional frente a otras categorías de gran consumo.

Segmentación conductual

Diseñar las acciones por comportamiento de compra y no por perfil sociodemográfico, dado que ni la renta del entorno ni las tipologías MOSAIC discriminan el gasto del cliente. Esta evidencia fundamenta la metodología del Capítulo 5.

Reactivación de cartera

El 12 % de clientes sin actividad económica documentada (405 clientes) constituye el mayor pool de reactivación potencial identificado, con un retorno que se estimará en el análisis de recomendaciones.

En conjunto, el retrato que emerge es el de una cartera madura y muy concentrada: un núcleo reducido de grandes cuentas mayoristas sostiene la mayor parte de la facturación, frente a una larga cola de clientes de menor volumen. Esta estructura, unida a la ausencia de poder predictivo de las variables sociodemográficas, justifica que el esfuerzo analítico posterior se dirija a la segmentación por comportamiento y a la identificación de palancas de crecimiento sobre los segmentos de mayor valor.

Nota. Este capítulo recoge únicamente los hallazgos de mayor relevancia. El desarrollo interactivo y el detalle de la caracterización de la cartera se materializan en el **cuadro de mando de Power BI**, donde los gráficos aquí presentados son explorables por mercado, canal, periodo y segmento.

Segmentación de clientes mediante clustering

K-Means

Análisis de componentes principales · K-Means · caracterización comercial de los segmentos

Este capítulo aplica técnicas de aprendizaje no supervisado para segmentar la cartera activa de Selmark en grupos de comportamiento homogéneo. El análisis se desarrolla en dos notebooks: el 11a implementa la segmentación —reducción de la dimensionalidad mediante PCA, determinación del número óptimo de grupos y aplicación de K-Means— y el 11b la caracteriza mediante índices de afinidad, importancia de variables con Random Forest y un *naming* comercial fundamentado en evidencia cuantitativa.

Una decisión metodológica vertebró todo el capítulo: la segmentación se construye **exclusivamente sobre variables de comportamiento de compra** —no sociodemográficas—, en coherencia con el hallazgo del Capítulo 4 según el cual la correlación entre la renta del código postal y la facturación del cliente es estadísticamente nula ($p = +0,004$). De los 3.492 clientes activos del cuatrienio, el clustering opera sobre los **3.084 clientes con comportamiento de compra documentado**; se excluyen las cuentas técnicas y los clientes sin actividad económica registrada, coherentes con el *pool* de reactivación identificado en el análisis descriptivo. La pregunta de investigación es directa: ¿es posible identificar grupos diferenciados de clientes a partir únicamente de su comportamiento de compra y caracterizarlos de forma cuantitativamente robusta para informar las decisiones de retención, captación y rentabilización?

Concepto	Resultado
Perímetro analizado	3.084 clientes activos (sin cuentas técnicas)
Variables conductuales	8 indicadores (recencia, frecuencia, ticket, etc.)
Componentes PCA seleccionadas	4 componentes · 85,87 % de la varianza
Número de clusters	6 (k elegido por Davies-Bouldin y Calinski-Harabasz)
Accuracy media Random Forest	0,9829 (segmentos muy distinguibles)
Hallazgo Pareto	Los 2 clusters de mayor valor concentran el 90,1 % de la facturación
Confirmación renta	La renta del CP no discrimina entre clusters

Tabla 5.1. Síntesis cuantitativa de los principales resultados del capítulo.

5.1 Reducción de la dimensionalidad: análisis de componentes principales

El Análisis de Componentes Principales (PCA) transforma las ocho variables conductuales en un nuevo sistema de coordenadas ortogonales, ordenadas según la varianza que capturan. Su aplicación previa al K-Means persigue tres objetivos: mitigar la maldición de la dimensionalidad mejorando la convergencia del algoritmo, eliminar el ruido de las componentes de menor varianza y crear un espacio adecuado para la visualización mediante biplots.

Aplicando el criterio estándar de la literatura —umbral de varianza acumulada del 80 %—, se seleccionan las **cuatro primeras componentes**, que en conjunto explican el **85,87 %** de la varianza total. Esta reducción del 50 % de la dimensionalidad conservando casi el 86 % de la información representa un equilibrio razonable entre simplificación y fidelidad a la estructura latente.




Figura 5.1. Scree plot · varianza explicada por componente. Se seleccionan 4 componentes que acumulan el 85,9 %, superando el umbral del 80 %.

El análisis de los *loadings* revela una estructura interpretable con lectura económica directa, que facilita la posterior interpretación de los clusters.

Componente	Variables dominantes (loading)	Interpretación
PC1 (33,9 %)	ticket_medio_retail_eur (+0,94)	Eje del valor por compra
PC2 (22,6 %)	frecuencia_mensual (+0,56) · % temporada (+0,41) · % repetición (-0,42)	Intensidad y estructura de compra
PC3 (16,7 %)	pct_ratio_devoluciones (+0,84)	Calidad de la relación
PC4 (12,7 %)	recencia (+0,52) · % repetición (-0,49)	Eje temporal y de estabilidad

Tabla 5.2. Interpretación comercial de las cuatro componentes principales.




Figura 5.2. Heatmap de loadings de las cuatro componentes principales. Cada celda muestra la contribución de cada variable conductual a cada componente.

5.2 Determinación del número óptimo de clusters

La elección de *k* es la decisión más crítica del K-Means. Siguiendo la práctica recomendada, ninguna métrica se emplea de forma aislada: se combinan cuatro indicadores complementarios —el método del codo sobre

la inercia (sugerido por la dirección académica), el coeficiente de Silhouette, el índice de Davies-Bouldin y el índice de Calinski-Harabasz.

Determinación del número óptimo de clusters · 4 métricas combinadas




Figura 5.3. Las cuatro métricas de validación sobre el rango $k = 2..10$. Davies-Bouldin y Calinski-Harabasz coinciden en $k = 6$.

Decisión: $k = 6$ clusters

Las métricas no convergen a un único óptimo: el Silhouette y el codo numérico apuntan a $k = 3$, mientras que Davies-Bouldin y Calinski-Harabasz —las dos más informativas para clusters convexos— coinciden en $k = 6$. Se adopta $k = 6$ por tres razones convergentes: ambas métricas de mayor poder discriminativo lo respaldan; la dirección académica fijó un rango objetivo de 5-6 clusters para garantizar la interpretabilidad comercial; y la solución con $k = 3$ resulta comercialmente pobre, al agrupar el 76 % de la cartera en un único cluster heterogéneo.

La penalización en Silhouette al elegir $k = 6$ frente a $k = 3$ (0,3065 frente a 0,3708, una diferencia de 0,064 en una escala de -1 a +1) es modesta y queda más que compensada por las ganancias en interpretabilidad comercial y alineación con la dirección del trabajo.

5.3 Aplicación de K-Means y distribución de la cartera

Con $k = 6$ fijado, se aplica K-Means sobre el espacio de las cuatro componentes principales. El algoritmo minimiza la suma de cuadrados intra-cluster (WCSS); para mitigar el sesgo de inicialización se ejecutan 50 inicializaciones distintas y se garantiza la reproducibilidad con semilla fija (random_state = 42). La asignación de los 3.084 clientes produce una distribución desigual pero no degenerada: ningún grupo colapsa en un tamaño extremo, lo que respalda la idoneidad de $k = 6$.




Figura 5.4. Distribución de la cartera por cluster (K-Means, k = 6). Cartera total clusterizada: 3.084 clientes activos.

Los dos clusters mayoritarios (Cluster 1 con el 43,5 % y Cluster 4 con el 26,9 %) concentran el 70,4 % de los clientes y constituyen el tejido comercial principal. En el extremo opuesto, los clusters minoritarios (Cluster 2 con el 4,0 % y Cluster 5 con el 1,8 %) son reducidos en número pero comercialmente muy relevantes, como se verá al cruzarlos con el peso económico.

El biplot proyecta los clientes sobre el plano PC1-PC2 y superpone los vectores de las variables originales: la dirección de cada vector indica hacia dónde crecen sus valores y los ángulos entre vectores informan de las correlaciones (vectores opuestos → correlación negativa).




Figura 5.5. Biplot PCA · PC1 vs PC2 con los 6 clusters de K-Means. Puntos: clientes proyectados · flechas: vectores de las variables conductuales.

Destaca la posición casi horizontal del vector *ticket_medio_retail_eur*, coherente con su dominio en PC1: los clusters situados a la derecha presentan tickets elevados. La oposición visual entre

pct_pedidos_temporada y *pct_pedidos_repeticion*, alineados en sentidos contrarios, confirma gráficamente su fuerte correlación negativa ($p = -0,77$).

5.4 Peso económico por cluster: el principio de Pareto cuantificado

La comparación entre el peso poblacional (% de clientes) y el peso económico (% de facturación) de cada cluster revela uno de los hallazgos centrales del capítulo: la confirmación empírica y cuantificada del principio de Pareto sobre la cartera de Selmark.

Distribución de clientes (izq.) y de facturación (der.) por cluster




Figura 5.6. Distribución de clientes (izq.) y de facturación (der.) por cluster. C1 y C2 concentran el 90,1 % de la facturación con solo el 47,5 % de los clientes.

Cluster	N	% cartera	Facturación	% fact.	Fact./cliente
C0 — Clientes en Riesgo	306	9,92 %	2,97 M€	2,19 %	9.720 €
C1 — Núcleo Estratégico	1.341	43,48 %	87,88 M€	64,57 %	65.532 €
C2 — Grandes Cuentas Internac.	123	3,99 %	34,75 M€	25,54 %	282.555 €
C3 — Reposicionistas Tradic.	429	13,91 %	1,39 M€	1,02 %	3.233 €
C4 — Compradores Estacionales	831	26,95 %	9,00 M€	6,62 %	10.835 €
C5 — Casos Críticos	54	1,75 %	0,10 M€	0,07 %	1.878 €

Tabla 5.3. Dimensión económica de los seis clusters identificados.

Hallazgo crítico: el principio de Pareto cuantificado

El Cluster 1 (43,48 % de los clientes) genera el 64,57 % de la facturación; el Cluster 2 (3,99 %) aporta un 25,54 % adicional. En conjunto, los dos clusters de mayor valor (47,5 % de la cartera) concentran el **90,11 % del negocio**. En el extremo opuesto, los clusters 0, 3 y 5 representan el 25,6 % de los clientes pero apenas el 3,3 % de la facturación.

5.5 Caracterización de los segmentos: afinidad e importancia de variables

Los índices de afinidad comparan el comportamiento medio de cada cluster con el comportamiento global de la cartera. Un índice de 100 equivale al comportamiento medio; valores superiores indican sobrerrepresentación e inferiores, infrarrepresentación (p. ej., un índice de 250 en ticket significa que el cluster gasta 2,5 veces más por compra que la media).




Figura 5.7. Heatmap de índices de afinidad por cluster y variable. Azul = infrarrepresentado · Rojo = sobrerrepresentado.

La distribución de *pct_ratio_devoluciones* es uno de los hallazgos más visibles: los clusters 0 y 5 presentan índices de 668 y 873 respectivamente, mientras que los clusters 1, 3 y 4 se sitúan por debajo de 30. La propensión a la devolución no es un rasgo gradual de la cartera sino prácticamente categórico, que aísla a un subconjunto reducido de clientes problemáticos. De forma análoga, *ticket_medio_retail_eur* alcanza un valor extraordinario en el cluster 2 (índice 453), que lo define como un grupo netamente diferenciado por la magnitud de sus operaciones.

Como complemento inferencial, se entrena un Random Forest binario por cluster (200 árboles, profundidad 10, clases balanceadas): mientras los índices cuantifican la magnitud de la desviación, el Random Forest identifica el poder discriminativo de cada variable mediante *permutation importance*.

Cluster	Variable más discriminante	Accuracy
C0 — Clientes en Riesgo	<i>pct_ratio_devoluciones</i>	99,24 %
C1 — Núcleo Estratégico	<i>recencia_dias</i> · <i>meses_activo</i>	97,41 %
C2 — Grandes Cuentas Internac.	<i>ticket_medio_retail_eur</i>	99,57 %
C3 — Reposicionistas Tradic.	<i>pct_pedidos_repeticion</i>	98,06 %
C4 — Compradores Estacionales	<i>meses_activo</i> · <i>pct_pedidos_temporada</i>	95,68 %
C5 — Casos Críticos	<i>ticket_medio_retail_eur</i>	99,78 %

Tabla 5.4. Síntesis del Random Forest binario por cluster (accuracy media: 0,9829).

Las variables más sobrerrepresentadas según los índices de afinidad coinciden con las más discriminantes según el Random Forest (p. ej., *pct_ratio_devoluciones* en C0 y C5; *ticket_medio_retail_eur* en C2). Esta convergencia entre una métrica descriptiva y otra inferencial refuerza la fiabilidad de la caracterización; las altas precisiones (todas > 95,7 %, media del 98,29 %) confirman que los seis clusters son grupos estadísticamente bien diferenciados.

5.6 Validación con variables externas

Los seis clusters se caracterizan ahora mediante variables que **no** intervinieron en su formación —tipo de mercado y renta del CP—. Si los segmentos resultan correlacionados con ellas, esa correlación es un hallazgo genuino sobre la estructura del negocio y no un artefacto de la metodología.




Figura 5.8. Composición de cada cluster por tipo de mercado (nacional / internacional).

El Núcleo Estratégico (C1) y los Reposicionistas (C3) son predominantemente nacionales (74 % y 72 %), mientras que las Grandes Cuentas (C2) y los Compradores Estacionales (C4) tienen mayoría internacional (62 % y 58 %): la dinámica internacional concentra los perfiles de mayor valor (C2) y de cantera (C4).




Figura 5.9. Distribución de la renta media del CP por cluster (clientes nacionales). Todas las medianas entre 25.000 € y 28.000 €.

La renta media del CP se mueve en un rango muy estrecho entre clusters (25.349 € a 28.066 €), con desviaciones estándar superiores a las diferencias entre grupos. Estadísticamente, la renta **no discrimina** la segmentación, lo que valida la decisión fundamental del trabajo: basar el clustering en variables exclusivamente conductuales.

5.7 Matriz estratégica y fichas de segmento

Consolidando los hallazgos anteriores, se asigna a cada cluster un nombre comercial fundamentado en evidencia cuantitativa y se sitúa en una matriz estratégica que posiciona los seis segmentos según su **valor por cliente** (eje X) y su **peso en cartera** (eje Y), con el área de cada burbuja proporcional a su **facturación total**.




Figura 5.10. Matriz estratégica de segmentos. El tamaño de la burbuja representa la facturación total de cada cluster.

La lectura por cuadrantes resume la estrategia comercial: **C1 (Motor del negocio)** es la burbuja dominante, columna vertebral de la facturación; **C2 (Cuentas clave)** reúne poquísimos clientes de valor extraordinario; **C4 (Cantera)** agrupa clientes recientes con potencial de conversión; y los segmentos **C0, C3 y C5 (Bajo retorno · revisar)** aportan poco valor y concentran las relaciones problemáticas.

Segmento	Perfil cuantitativo	Recomendación comercial
C1 · Núcleo Estratégico	Veteranía alta (índice 174), recencia muy baja (24) y baja devolución (29). 74 % nacional.	Retención prioritaria absoluta: su pérdida tendría un impacto desproporcionado.
C2 · Grandes Cuentas Internac.	Ticket 4,5× la media y facturación 6,4× la media; 62 % internacional.	Atención individualizada y contratos estables; cada baja es una caída notable.
C4 · Compradores Estacionales	Clientes recientes (meses_activo al 28 %), alto compromiso de colección (148), devolución baja (8).	Cantera del Núcleo: fidelización dirigida para escalar parte a C1.
C3 · Reposicionistas Tradic.	Concentración extrema en repetición (275), casi nula en temporada (14).	Bajo valor individual; mantener por volumen agregado y presencia distribuida.
C0 · Clientes en Riesgo	Devoluciones 6,7× la media (668), recencia elevada (143), facturación baja (22).	Revisión comercial de causas (tallaje, calidad, catálogo) antes de degradar a C5.
C5 · Casos Críticos	Devoluciones 8,7× la media (873) y ticket al 6 % de la media.	Más coste que valor: revisión individual y, en su caso, terminación controlada.

Tabla 5.5. Fichas de segmento: perfil cuantitativo y recomendación comercial asociada.

5.8 Conclusiones del capítulo

La aplicación de K-Means sobre el espacio reducido por PCA ha permitido identificar **seis segmentos de comportamiento** estadísticamente robustos y comercialmente interpretables. La robustez de la partición queda respaldada por la convergencia entre los índices de afinidad y la importancia de variables del Random Forest, con una precisión media del 98,29 % en la distinción de los segmentos sobre datos no vistos.

El hallazgo central es la confirmación cuantificada del **principio de Pareto** en la cartera de Selmark: el 47,5 % de los clientes (Núcleo Estratégico y Grandes Cuentas Internacionales) concentra el 90,1 % de la facturación, frente a una larga cola de clientes de bajo volumen. La caracterización con variables externas confirma además que ni la renta del código postal ni el perfil sociodemográfico discriminan los segmentos, lo que valida la decisión metodológica de fundamentar la segmentación exclusivamente en variables de comportamiento de compra.

El retrato que emerge es el de una cartera madura y muy concentrada, en la que un núcleo reducido de grandes cuentas sostiene la mayor parte del negocio. Esta estructura justifica que el esfuerzo comercial se oriente, de forma diferenciada, a la retención de los segmentos de mayor valor (C1 y C2), a la conversión de la cantera estacional (C4) y a la revisión activa de los segmentos con relaciones deterioradas (C0 y C5) — líneas que se cuantificarán en el análisis de recomendaciones y ROI.

Análisis geomarketing

Distribución territorial de la cartera y cruce con la segmentación comportamental · Notebooks 12a + 12b

El Capítulo 6 integra dos perspectivas complementarias: la distribución descriptiva de los clientes en el territorio (notebook 12a) y el cruce de esa distribución con los seis segmentos comportamentales del Capítulo 5 (notebook 12b). El geomarketing aporta así una capa de segmentación territorial que complementa a la conductual y prepara las acciones comerciales geográficamente diferenciadas del Capítulo 8.

El perímetro analizado son los 3.084 clientes activos: 1.901 nacionales —1.661 con provincia correctamente mapeada— y 1.183 internacionales repartidos entre 48 países. Una rutina de recuperación de códigos mal transcritos por el ERP (tres dígitos del código postal y abreviaturas de país volcados al campo provincia) elevó la cobertura del campo provincia del 53,1 % al 82,9 % sin alterar ningún dato original. Todas las métricas se calculan en valores absolutos y, sobre todo, normalizadas por población —clientes por cada 100.000 habitantes (INE 2024)—, lo que evita que los mapas queden dominados por la simple densidad poblacional.

Indicador	Valor
Clientes activos analizados	3.084
Nacionales (con provincia mapeada)	1.901 (1.661)
Internacionales · países con presencia	1.183 · 48
Cobertura del campo provincia	82,9 % (desde 53,1 %)
Penetración máxima nacional (Lugo)	8,85 clientes / 100K hab
Penetración de Madrid	0,97 clientes / 100K hab (×9 menor)
Núcleo Estratégico (C1) dominante en	48 / 52 provincias
Huecos territoriales · potencial de captación	11 provincias · 221 clientes C1 (+16,5 %)

Tabla 6.1. Síntesis cuantitativa de los principales indicadores del capítulo.

Seis hallazgos accionables del capítulo

- Eje noroeste-norte.** Lugo (8,85), Pontevedra (8,67), Ourense (8,54) y Asturias (8,20) lideran la penetración por habitante, coherente con la sede histórica de Selmark en Galicia.
- Madrid, el mayor mercado infraexplotado.** Apenas 0,97 clientes por 100.000 habitantes, nueve veces menos que Lugo, pese a su renta superior a la media.
- Pareto territorial.** 9 provincias (17,3 %) concentran el 50 % de la facturación nacional y 25 (48,1 %) el 80 %.
- Núcleo dominante.** El C1 es el clúster mayoritario en 48 de 52 provincias (92,3 %), con excepciones insulares (Compradores Estacionales en Canarias y Baleares).
- Once huecos territoriales** con potencial de 221 clientes del Núcleo captables (+16,5 % sobre la cartera C1 actual), el 57 % de ellos en Madrid (127).
- Tres patrones internacionales:** cantera dominada por Compradores Estacionales (Italia), Grandes Cuentas concentradas (Canadá, Reino Unido, Rusia) y mercado mixto consolidado (Portugal).

Panel geomarketing · Cartera Selmark

Distribución territorial y cruce con los seis segmentos · 3.084 clientes · 52 provincias · 48 países




Figura 6.1. Panel geomarketing de la cartera Selmark: distribución por provincia (clientes, facturación, penetración y facturación por habitante), huella de los seis clusters en el territorio (clúster dominante, penetración de C1 y C2, mapa de vigilancia C0+C5), presencia internacional y mapa de huecos territoriales con el potencial de captación del Núcleo.

6.1 Distribución territorial y concentración del negocio

La distribución absoluta evidencia la concentración geográfica de la cartera. Barcelona lidera ambos rankings con 195 clientes (11,7 % del mercado nacional) y 6,79 M€ de facturación, seguida de Pontevedra y Asturias (83 clientes cada una), Alicante (78), Valencia (74) y A Coruña (69). Las Palmas merece mención aparte: con solo 28 clientes factura 4,94 M€ —segunda provincia por facturación absoluta—, reflejo de clientes de muy alto valor en Canarias.

La facturación se concentra con la misma asimetría que el Capítulo 5 observó a nivel de cliente: las 9 primeras provincias (17,3 % del total) acumulan el 50 % del negocio nacional, las 25 primeras (48,1 %) el 80 % y las 34 primeras (65,4 %) el 90 %. Es un principio de Pareto territorial. La agregación a Comunidad Autónoma, más útil para la dirección comercial, revela los patrones macro.

Comunidad Autónoma	Clientes	% cli.	Facturación	% fact.	Fact./cliente
Cataluña	311	18,7 %	9,81 M€	15,2 %	31.544 €
Andalucía	218	13,1 %	8,84 M€	13,7 %	40.549 €
Galicia	207	12,5 %	8,82 M€	13,6 %	42.589 €
Canarias	81	4,9 %	6,83 M€	10,6 %	84.367 €
C. Valenciana	167	10,1 %	5,63 M€	8,7 %	33.688 €
Asturias	83	5,0 %	3,81 M€	5,9 %	45.871 €
Castilla y León	106	6,4 %	3,71 M€	5,7 %	34.995 €
País Vasco	104	6,3 %	3,40 M€	5,3 %	32.732 €
Madrid	68	4,1 %	2,17 M€	3,4 %	31.965 €

Tabla 6.2. Distribución por Comunidad Autónoma (top 9 por facturación).

Cataluña lidera en número de clientes (18,7 %) pero pesa menos en facturación (15,2 %): perfil de ticket medio. Canarias presenta el patrón inverso —4,9 % de clientes y 10,6 % de la facturación, con la facturación media por cliente más alta de todas las comunidades (84.367 €)—, indicio de Grandes Cuentas. Galicia y Asturias mantienen el equilibrio propio de carteras maduras, y Madrid muestra una desproporción reveladora: el 4,1 % de los clientes genera solo el 3,4 % de la facturación, anticipando su condición de mercado infraexplotado.

6.2 Penetración per cápita: el hallazgo estratégico

La penetración —clientes Selmark por cada 100.000 habitantes— es el indicador más potente del capítulo porque neutraliza el sesgo poblacional que distorsiona los rankings absolutos. El ranking lo domina el cuadrante noroeste peninsular: Lugo (8,85), Pontevedra (8,67), Ourense (8,54) y Asturias (8,20). El contraste con el ranking por volumen es elocuente: Barcelona, primera en número de clientes, cae a 3,40; y Madrid, con 68 clientes, ocupa una de las últimas posiciones con apenas 0,97.

Top 15 provincias por penetración de clientes

Verde: penetración alta (≥6) · Amarillo: media · Rojo: baja (<3) · Métrica normalizada por población INE 2024




Figura 6.2. Top 15 provincias por penetración de clientes (clientes Selmark por cada 100.000 habitantes, INE 2024).

El hallazgo estrella: Madrid frente al eje noroeste

La diferencia entre Lugo y Madrid **supera el factor 9**. Madrid, el mayor mercado potencial de España (más de siete millones de habitantes) y con renta superior a la media, presenta una penetración nueve veces inferior a la del territorio histórico de Selmark. Es la mayor oportunidad de captación de la cartera, y se cuantifica en la Sección 6.5.

6.3 Resolución fina y mercado internacional

A nivel de **código postal** —la resolución más fina del estudio nacional— los 1.901 clientes nacionales se reparten entre 1.199 códigos postales únicos (media de 1,59 clientes por CP). La dispersión es alta: salvo en concentraciones urbanas, la mayoría de los CP tiene un único cliente, lo que evidencia una cobertura territorial muy distribuida. Las concentraciones máximas (5-6 clientes/CP) se dan en capitales y ciudades comarcales (Ávila, Zaragoza centro, Lugo, Pontevedra, Sevilla centro). Esta capa se complementa con un mapa interactivo de Folium (1.098 marcadores agrupados) que se entrega como fichero HTML independiente.

El **mercado internacional** concentra el 38,4 % de la cartera activa (1.183 clientes) en 48 países. La codificación sigue el estándar ISO 3166 alpha-3. Portugal e Italia dominan en volumen, pero el reparto de la facturación está marcado por clientes individuales de facturación millonaria (clientes «monstruo»).

País	Clientes	Facturación	% fact. int.	Fact./cliente
Portugal	301	15,54 M€	25,9 %	51.623 €
Italia	528	8,74 M€	14,6 %	16.550 €
Israel	1	4,82 M€	8,0 %	4.815.764 €
México	3	4,81 M€	8,0 %	1.603.810 €
Reino Unido	5	4,62 M€	7,7 %	924.002 €
Rusia	3	3,63 M€	6,0 %	1.210.584 €

Tabla 6.3. Top 6 países por facturación internacional.

Emergen tres patrones diferenciados. Mercados de **cantera** dominados por Compradores Estacionales: Italia es el caso paradigmático (528 clientes pero ticket medio bajo, 16.550 €), junto a Noruega, Polonia y Países Bajos. Clientes **«monstruo»** y **Grandes Cuentas concentradas**: Israel, México, Reino Unido, Rusia, Kuwait y República Checa mantienen entre uno y cinco clientes con facturaciones millonarias, por lo que la pérdida de un único distribuidor tendría impacto perceptible en la cuenta de resultados. Y el **mercado mixto consolidado** de Portugal, que combina volumen (301 clientes) con dominancia del Núcleo, perfil de mercado maduro favorecido por la cercanía geográfica y cultural.

6.4 Cruce con la segmentación: huella territorial de los clusters

El Núcleo Estratégico (C1) domina en 48 de las 52 provincias (92,3 %), confirmación visual de su peso en cartera, con cuatro excepciones genuinas: tres insulares dominadas por Compradores Estacionales (Tenerife, Baleares y Canarias, dinámica turística) y una por Reposicionistas. A nivel autonómico, País Vasco (63,5 % C1), Aragón (61,5 %) y Castilla-La Mancha (59,7 %) son los territorios más consolidados; Canarias y Baleares, los más estacionales (49,4 % y 46,3 % C4); Castilla y León lidera en Reposicionistas (28,3 % C3); y Madrid es el más heterogéneo, sin clúster dominante (42,6 % C1, 26,5 % C3, 17,6 % C4).

Composición porcentual de clusters por Comunidad Autónoma
Mercado nacional - Vista agregada que complementa el análisis provincial



Figura 6.3. Composición porcentual de los seis clusters por Comunidad Autónoma (mercado nacional).

La paradoja del territorio histórico

Las provincias líderes en penetración del Núcleo presentan también las mayores penetraciones de clientes problemáticos. El ranking combinado de Clientes en Riesgo (C0) y Casos Críticos (C5) lo encabezan Pontevedra (1,98 por 100K hab), Ciudad Real (1,44), Alicante (1,23) y Asturias (1,09): donde Selmark lleva más tiempo presente, el envejecimiento natural de las relaciones acumula tanto clientes consolidados como relaciones deterioradas. Implicación directa para el modelo de churn (Cap. 7): los territorios históricos exigen vigilancia sobre la dinámica reciente de cada cliente.

A nivel municipal, existen 852 municipios con al menos un cliente Selmark. **Vigo** —sede histórica— es el epicentro de la cartera: aparece en cinco de los seis clusters y lidera en Clientes en Riesgo con 20 clientes, el mayor número absoluto de la cartera nacional para ese segmento. El hallazgo es contraintuitivo (cabría esperar la mejor calidad de cartera en la zona de mayor presencia) pero coherente con el patrón de

envejecimiento, y justifica una revisión específica del canal local. Barcelona destaca en Núcleo (18) y Estacionales (13); Madrid muestra una distribución equilibrada entre todos los perfiles.

6.5 Huecos territoriales: 221 clientes captables

La identificación de huecos territoriales es el análisis más accionable del capítulo. Su definición operativa cruza dos condiciones simultáneas: penetración del Núcleo por debajo de la mediana nacional ($< 2,23$ C1/100K hab) y renta media del código postal igual o superior a la media nacional (≥ 25.934 €). La intersección aísla provincias con perfil económico compatible con clientes de alto valor pero comercialmente infraexplotadas.




Figura 6.4. Potencial de captación por hueco territorial: clientes del Núcleo (C1) captables si cada provincia alcanzara la mediana nacional. Total estimado: 221.

Once huecos con 221 clientes captables del Núcleo Estratégico

Bajo la hipótesis conservadora de que cada hueco alcance la mediana nacional de penetración del Núcleo (2,23 C1/100K hab), el potencial total asciende a **221 clientes del Núcleo Estratégico**, un crecimiento del **16,5 %** sobre la cartera C1 actual (1.341 clientes).

Madrid es el target nº 1 con 127 clientes captables (57,5 % del potencial total): gran población (7,01 M hab) y renta superior a la media (30.129 €). Le siguen Valencia (31), Barcelona (28), Toledo (11), León (8) y Castellón (7). Que Barcelona aparezca pese a ser la mayor cartera nacional confirma el valor del análisis per cápita: su penetración relativa (1,75) está por debajo de la mediana.

6.6 Síntesis y conexión con los capítulos 7 y 8

El capítulo localiza geográficamente cada segmento y entrega dos insumos operativos. Para el modelo de **churn** (Cap. 7): los Clientes en Riesgo (C0) y Casos Críticos (C5) quedan georreferenciados, con la Comunidad Valenciana (16,8 % C0) como alerta específica y Pontevedra, Asturias y Vigo como zonas de validación cualitativa. Para las **recomendaciones y el ROI** (Cap. 8): captación priorizada sobre los 11 huecos —con Madrid a la cabeza—, retención reforzada en el noroeste y en las plazas de Grandes Cuentas (Las Palmas, Cádiz; Canadá, Noruega) y conversión de la cantera estacional (C4 → C1), señaladamente en Italia (271 Compradores Estacionales cultivables). El dataset `geomarketing_provincias_cluster.parquet` integra todas las métricas por provincia y constituye la entrada principal del Capítulo 8, donde se estimará el retorno económico esperado de cada acción.

Análisis de churn

Modelo predictivo del riesgo de pérdida de clientes · Notebook 13 · validación as-of 2024 y enfoque fresh churn

Este capítulo desarrolla un modelo predictivo binario de *churn* (abandono comercial) sobre la cartera activa de Selmark, con el objetivo de identificar de forma anticipada a los clientes con alta probabilidad de inactividad futura y permitir que la dirección comercial concentre el esfuerzo de retención sobre el subconjunto realmente vulnerable. El análisis se apoya directamente en los dos capítulos previos: emplea como variable predictora la segmentación del Capítulo 5 y valida sus resultados contra los hallazgos territoriales del Capítulo 6. Dos decisiones metodológicas vertebran el trabajo y se documentan de forma explícita: la corrección de un *data leakage* temporal que inflaba artificialmente las métricas y la adopción del enfoque *fresh churn*, que restringe el análisis a los clientes recuperables.

Indicador	Valor
Perímetro analítico (fresh churn)	1.881 clientes activos al corte
Tasa de churn observada	15,20 %
Corte temporal de las features (as-of)	31/12/2024
Ventana de definición del target	año 2025
Features finales del modelo	33 (todas as-of 2024 / pre-2025)
Modelos comparados	4 (Reg. Logística, Random Forest, XGBoost, LightGBM)
Modelo final seleccionado	Random Forest
AUC-ROC · PR-AUC (test)	0,880 · 0,638
Bootstrap · IC 95 % AUC-ROC	[0,841 – 0,918]
Facturación en riesgo (TOP 100)	470.774 €

Tabla 7.1. Síntesis cuantitativa de los principales resultados del capítulo.

Cinco hallazgos del capítulo

1. Tras corregir el *leakage* y adoptar el enfoque *fresh churn*, el modelo Random Forest alcanza un AUC-ROC de 0,880 y un PR-AUC de 0,638 en test, métricas situadas en el rango realista que la literatura documenta para churn de retail B2B (0,75–0,90).
2. La corrección del *data leakage* es la decisión metodológica central: el AUC pasó de 0,98 (inflado por variables que incluían 2025) a 0,88 (ganado de forma legítima); la bajada no refleja un peor modelo sino la eliminación de la fuga.
3. La tasa de churn por cluster valida externamente la segmentación del Capítulo 5: el Núcleo Estratégico (4,0 %) frente a los Compradores Estacionales (41,5 %), una relación de diez a uno.
4. El ranking de los 100 clientes activos de mayor riesgo concentra 470.774 € y, a diferencia del modelo con fuga, lo forman clientes recientemente activos (recencia de 19 a 305 días) y, por tanto, accionables.
5. El triple análisis de robustez (modelo puro, bootstrap y calibración por cluster) y la validación territorial confirman que la capacidad predictiva es genuina y estable.

7.1 Marco metodológico: definición del churn y corrección del leakage

En un negocio textil con doble componente mayorista (B2B) y minorista (B2C) y sin estructura contractual, el churn se define operativamente como inactividad prolongada de compra: se considera que un cliente ha entrado en churn si no registra ninguna operación minorista durante el año 2025. La ventana de doce meses es coherente con la estacionalidad bianual del sector documentada en el Capítulo 4.

El análisis exploratorio inicial detectó un problema metodológico crítico. La variable objetivo se mide sobre 2025; sin embargo, numerosas variables de comportamiento (meses activos, número de operaciones, facturación acumulada) estaban calculadas sobre toda la vida del cliente, *incluyendo 2025*. Como un cliente en churn no puede, por definición, registrar actividad en 2025, esas variables quedaban truncadas y filtraban la respuesta al modelo (un *lookahead*), elevando el AUC hasta 0,98 de forma artificial.

Corrección aplicada

Todas las variables de comportamiento se recalcularon congelando el reloj al 31/12/2024 (features con sufijo *_pre*), de modo que la ventana de observación es estrictamente anterior a la ventana del target. La recencia se mide igualmente en el corte (*recencia_pre*), por lo que es legítima y muy predictiva. Se excluyeron además las indicadores de cluster, ya que el K-Means del Capítulo 5 se entrenó con variables que incluían 2025, lo que introducía un *leakage* indirecto.

Tras la corrección se observó que buena parte de los churners de 2025 ya llevaban dos o tres años inactivos en el corte: predecirlos es trivial y carece de valor operativo, porque no son recuperables. Por ello se adopta el enfoque estándar de *fresh churn*, restringiendo el perímetro a los clientes que seguían activos a 31/12/2024 (recencia inferior a 365 días). El perímetro analítico se construye mediante filtros sucesivos:

Filtro sucesivo	Clientes
Total en gold.ciente_360	3.492
Con histórico retail ≤ 31/12/2024	2.795
Antigüedad ≥ 365 días y con cluster asignado	2.533
Excluidos Casos Críticos (C5, inactivos por definición)	2.484 (base)
Activos al corte (recencia < 365) → fresh churn	−603
Perímetro final	1.881 clientes (53,9 %)

Tabla 7.2. Construcción del perímetro analítico bajo el enfoque *fresh churn*.

7.2 Análisis exploratorio del target

Sobre el perímetro de *fresh churn* la tasa de abandono observada es del 15,20 % (286 clientes en churn frente a 1.595 activos), con un desbalance moderado de 1:5,58. Es un valor inferior al de versiones previas precisamente porque ahora se excluye la masa de clientes ya inactivos: el 15 % representa el abandono *nuevo* entre clientes que seguían comprando. La tasa de churn por cluster constituye una validación externa de la segmentación del Capítulo 5 —que no usó el churn como input—, y la coherencia es total.

Cluster	Denominación comercial	N	Churn	Tasa
C1	Núcleo Estratégico	1.216	49	4,03 %
C2	Grandes Cuentas Internacionales	71	16	22,54 %
C0	Clientes en Riesgo	175	55	31,43 %
C3	Reposicionistas Tradicionales	149	54	36,24 %
C4	Compradores Estacionales	270	112	41,48 %

Tabla 7.3. Tasa de churn por segmento. El Núcleo Estratégico abandona diez veces menos que los Compradores Estacionales, confirmando la validez comercial de la segmentación del Capítulo 5.

7.3 Construcción de features y diagnóstico del leakage

El conjunto candidato cubre seis dimensiones del comportamiento del cliente —RFM, estacionalidad, tendencia interanual, producto y calidad, sociodemografía y geografía (penetración de problemáticos del Capítulo 6)—, todas en su versión as-of 2024. La tabla siguiente cuantifica la fuga: las variables acumuladas que incluían 2025 presentaban una mediana del grupo churn desplomada respecto al grupo activo, simplemente porque a los churners les faltaba todo el ejercicio 2025.

Variable acumulada (incluía 2025)	Mediana activo	Mediana churn
meses_activo	21,0	6,5
num_temporadas_activas	13,0	6,0
num_operaciones	818	211
facturacion_b2b (€)	19.688	4.664
facturacion_retail_neta (€)	17.710	4.758

Tabla 7.4. Evidencia del data leakage. Tras recalcular las features as-of 2024, la variable más asociada al target pasa a ser *recencia_pre* (correlación punto-biserial 0,45), un predictor legítimo.

El conjunto final queda en 33 features tras eliminar dos por redundancia (correlación de Spearman superior a 0,95). La matriz de correlaciones confirma los grupos de variables que miden la misma dimensión latente de intensidad comercial.



Figura 7.1. Matriz de correlaciones de Spearman entre las features as-of 2024. Los bloques de alta correlación motivan la eliminación de variables redundantes.

7.4 Modelado comparativo de los cuatro algoritmos

Se entrenan cuatro clasificadores que cubren el espectro estándar de complejidad —Regresión Logística regularizada (baseline interpretable) y tres ensembles de árboles: Random Forest, XGBoost y LightGBM—, todos con *class_weight='balanced'* y ajuste de hiperparámetros por GridSearchCV. La selección se realiza por PR-AUC, métrica preferida en problemas desbalanceados, lo que arroja como ganador a Random Forest.

Modelo	AUC-ROC	PR-AUC	F1	Precision	Recall	Brier
Regresión Logística	0,851	0,532	0,521	0,386	0,802	0,157
Random Forest (elegido)	0,880	0,638	0,613	0,662	0,570	0,088
XGBoost	0,870	0,620	0,527	0,543	0,512	0,102
LightGBM	0,873	0,623	0,559	0,600	0,523	0,103

Tabla 7.5. Comparativa de los cuatro modelos en el conjunto de test.

Comparativa de los 4 modelos · Conjunto de test




Figura 7.2. Curvas ROC (izquierda) y Precision-Recall (derecha) de los cuatro modelos. El baseline aleatorio de la curva PR es la proporción de positivos (0,152); Random Forest ocupa la posición dominante.

7.5 Calibración de probabilidades y selección del threshold

Se aplica calibración mediante *isotonic regression* con validación cruzada de tres pliegues. El Brier score se mantiene estable (0,088), lo que indica que las probabilidades de Random Forest ya estaban bien calibradas de partida. La distribución de probabilidades separa con claridad ambos grupos.




Figura 7.3. Curva de calibración antes y después de la isotonic regression (izquierda) y distribución de probabilidades predichas por target (derecha).

El threshold por defecto de 0,5 rara vez es óptimo. Evaluando precisión, recall y F1 sobre un grid de umbrales, el F1 se maximiza en 0,35, punto que prioriza la captura de churners frente a un coste asumible de falsos positivos, coherente con el objetivo de retención.




Figura 7.4. Trade-off Precision / Recall / F1 según el threshold. El máximo de F1 se alcanza en 0,35.

Matriz de confusión (threshold = 0,35)	Predicho Activo	Predicho Churn
Real Activo (479)	429	50
Real Churn (86)	31	55

Lectura del punto de operación

Accuracy global del 86 %. Recall de churn del 64 % (se capturan dos de cada tres abandonos reales) y precision del 52 % (algo más de la mitad de las alertas son correctas). Para una prevalencia del 15 %, es un compromiso realista y operativamente útil: el coste de una alerta de retención es bajo frente al de perder un cliente sin haber actuado.

7.6 Interpretabilidad del modelo mediante SHAP values

Los SHAP values (Lundberg & Lee, 2017) descomponen cada predicción en la contribución cuantificada de cada variable, lo que permite explicar no solo qué clientes están en riesgo sino por qué. El ranking de importancia es, además, una verificación clave de la corrección del leakage: todas las variables dominantes son legítimas y están medidas antes de 2025.

#	Feature	SHAP medio	Interpretación
1	ops_y2024	0,068	Operaciones del último año pre-target
2	fact_y2024	0,065	Facturación del último año pre-target
3	recencia_pre	0,049	Recencia medida en el corte (legítima)
4	tendencia_ops_24_vs_23	0,046	Dinámica interanual de actividad
5	meses_activo_pre	0,029	Intensidad temporal hasta 2024

Tabla 7.6. Las cinco variables más influyentes según el valor medio absoluto de SHAP.

En la versión con fuga la variable más influyente era meses_activo (acumulada hasta 2025) y la indicadora cluster_1 ocupaba el segundo puesto. Tras la corrección, el modelo se apoya en la actividad del año previo, la recencia al corte y las tendencias interanuales, exactamente los predictores que un modelo de churn debe utilizar.




Figura 7.5. Importancia media |SHAP| de las variables más influyentes (izquierda) y SHAP summary plot / beeswarm (derecha): rojo = valor alto de la feature; posición a la derecha = empuje hacia churn.

7.7 Análisis de robustez y validación territorial

La solidez del modelo se contrasta mediante tres análisis independientes y una validación territorial externa. **Modelo puro:** al reentrenar eliminando las 14 features acumulativas, el AUC apenas baja de

0,880 a 0,854 (gap +0,026, inferior al umbral de 0,05), lo que descarta leakage residual. **Bootstrap:** mediante 1.000 remuestreos del conjunto de test, el intervalo de confianza al 95 % del AUC-ROC es [0,841 – 0,918], con anchura estrecha. **Calibración por cluster:** el gap absoluto entre probabilidad media predicha y tasa real es del 3,4 % de media y del 5,87 % máximo, muy por debajo del umbral del 10 %.




Figura 7.6. Distribuciones bootstrap de las métricas tras 1.000 iteraciones (izquierda) y calibración por cluster: probabilidad media predicha frente a tasa real observada (derecha).

Por último, agregando las probabilidades individuales por provincia, el modelo reproduce las tasas reales de abandono, lo que respalda su generalización geográfica y conecta con el Capítulo 6: la paradoja del territorio histórico de Pontevedra se captura con precisión y la alerta de la Comunidad Valenciana se confirma cuantitativamente.

Provincia	N	Proba media	Tasa real
Pontevedra (paradoja histórica)	56	0,214	0,196
A Coruña (Núcleo gallego)	54	0,199	0,204
Ourense (Núcleo gallego)	21	0,224	0,238
Madrid (mercado infraexplotado)	34	0,195	0,294
Valencia (alerta C0 · Cap. 6)	—	0,141	0,129
Alicante (alerta C0 · Cap. 6)	—	0,092	0,081

Tabla 7.7. Validación territorial cruzada con el Capítulo 6.

7.8 Ranking final de clientes en riesgo

El aporte operativo del capítulo es el ranking de los clientes activos con mayor probabilidad de churn. Los 100 primeros concentran 470.774 € de facturación histórica (media de 4.708 € por cliente). A diferencia del modelo con fuga —cuyo top estaba dominado por clientes inactivos desde hacía años—, los objetivos tienen ahora recencias bajas (entre 19 y 305 días): son clientes que compraban y se están enfriando.

id_cliente	Cluster	Provincia	Fact. (€)	Recencia	Proba
16352	Núcleo Estratégico	Internacional	19.608	19	0,613
5124	Núcleo Estratégico	S.C. Tenerife	15.204	305	0,613
1929	Núcleo Estratégico	Internacional	9.523	188	0,628
7672	Núcleo Estratégico	A Coruña	3.760	213	0,613
1512	Compradores Estac.	Internacional	1.472	113	0,790
7337	Reposicionistas Trad.	Pontevedra	516	183	0,878

Tabla 7.8. Extracto del TOP de clientes activos con mayor probabilidad de churn.

Caso de máxima prioridad

El cliente 16352 (Núcleo Estratégico) acumula 19.608 € y 958 operaciones, con una recencia de solo 19 días pero una probabilidad de churn del 61 %: un cliente de alto valor que el modelo señala como en riesgo pese a su actividad reciente. Junto con los clientes 1929 y 5124, son candidatos inmediatos a la asignación de un gestor comercial dentro de la estrategia del Capítulo 8.

7.9 Limitaciones, síntesis y conexión con el Capítulo 8

Se documentan tres limitaciones. Primera, el histórico disponible es de cuatro años (2022-2025), lo que reduce las tendencias interanuales a dos puntos efectivos. Segunda, el target es binario y agregado: un modelo de supervivencia (time-to-churn) permitiría predecir no solo si un cliente abandonará sino cuándo. Tercera, el modelo no incorpora variables exógenas (acciones comerciales, campañas, incidencias de CRM, factores macroeconómicos) que podrían mejorar la capacidad predictiva.

Síntesis del capítulo

Sobre un perímetro de 1.881 clientes activos al corte, el modelo Random Forest alcanza AUC-ROC 0,880 y PR-AUC 0,638, con F1 de 0,576 en el threshold óptimo de 0,35. La corrección del data leakage temporal (features as-of 2024 y exclusión de las dummies de cluster) hace que estas métricas sean honestas y defendibles, frente al 0,98 artificial de la versión previa. La robustez se confirma mediante modelo puro (AUC 0,854), bootstrap (IC 95 % [0,841–0,918]) y calibración por cluster (gap máximo 5,87 %), y la interpretabilidad SHAP demuestra que el modelo se apoya en predictores legítimos.

El fichero de predicciones contiene el ranking completo de clientes activos enriquecido con sus variables comerciales (cluster, provincia, facturación, recencia) y constituye la entrada principal del Capítulo 8, donde se estimará el retorno económico esperado de las acciones de retención priorizadas: el caso 16352 y demás clientes de alto valor del Núcleo Estratégico como vigilancia activa, el cruce con los huecos territoriales de captación del Capítulo 6 (Madrid a la cabeza) y la vigilancia de las zonas de riesgo identificadas (Pontevedra y el eje gallego).

Recomendaciones y retorno de la inversión

Plan comercial basado en analítica · marco de no actuar frente a actuar (DO NOTHING / DO SOMETHING) · Notebook 14 y modelo de ROI

Este capítulo cierra el TFG traduciendo los hallazgos analíticos de los capítulos anteriores —la segmentación del Capítulo 5, el geomarketing del Capítulo 6 y el modelo de churn del Capítulo 7— en un plan comercial concreto, y cuantifica su retorno económico esperado (ROI). El objetivo es demostrar que las técnicas aplicadas no son un ejercicio académico, sino que producen valor cuantificable para Selmark. El análisis se articula sobre el marco DO NOTHING vs DO SOMETHING y se materializa en un modelo de cálculo en Excel con análisis de sensibilidad. La tabla siguiente resume el resultado final.

Escenario	Ingresos 2026	Δ vs DN	Coste plan	Beneficio	ROI
DO NOTHING	37,25 M€	—	0 €	—	n/a
DO SOMETHING · Opción 1 (volumen)	37,84 M€	+589 K€	482 K€	+107 K€	22,2 %
DO SOMETHING · Opción 2 (volumen + ticket)	37,86 M€	+614 K€	482 K€	+132 K€	27,4 %

Tabla 8.1. Síntesis de los tres escenarios. El plan genera un ROI defendible del 22-27 % anual, dentro del rango 15-25 % recomendado por la literatura sectorial y la dirección académica.

Cuatro claves del capítulo

1. El ROI siempre se mide sobre el *incremento* respecto a no hacer nada (DO NOTHING), no sobre la facturación total.
2. El plan se concreta en cuatro palancas comerciales, cada una trazable a un hallazgo cuantificado de los capítulos 5, 6 y 7.
3. La diferencia entre la Opción 1 (22,2 %) y la Opción 2 (27,4 %) —cinco puntos de ROI sin coste extra— cuantifica el valor económico concreto de la segmentación del Capítulo 5.
4. El análisis de sensibilidad muestra que el plan sigue siendo rentable ante desviaciones moderadas, y las limitaciones se documentan de forma explícita.

8.1 Marco de comparación: DO NOTHING frente a DO SOMETHING

Para evaluar una inversión no basta con calcular cuánto se gana al hacerla: hay que compararla con lo que ocurriría si no se hiciera nada. El marco *DO NOTHING / DO SOMETHING* fuerza esa comparación y es el armazón conceptual del modelo. El ROI se mide siempre sobre el *incremento* respecto a no actuar, no sobre la facturación total.

Los dos escenarios contrapuestos

DO NOTHING. Selmark continúa igual, sin plan basado en analítica. La facturación de 2026 se estima como la suma del *forecast retail* del Anexo SARIMA (15,95 M€) y la proyección B2B inercial (media del cuatrienio 2022-2025, ~21,3 M€): un total de **37,25 M€** con coste cero.

DO SOMETHING. Selmark activa un plan que usa el modelo de churn del Cap. 7 para retener clientes en riesgo, el geomarketing del Cap. 6 para captar en zonas con potencial y la segmentación del Cap. 5 para reenfocar ofertas. Se contemplan dos versiones: la **Opción 1** aporta solo volumen, y la **Opción 2** añade un incremento de ticket (*uplift*) del +8 % en el ticket de las palancas de captación y conversión, lo que cuantifica el valor económico del clustering del Capítulo 5.

8.2 Las cuatro palancas comerciales

El plan se concreta en cuatro palancas, cada una trazable a un hallazgo cuantificado de un capítulo previo, lo que garantiza que ninguna es una idea inventada para rellenar. Las palancas de retención (P1 y P2)

proviene del ranking de riesgo del Capítulo 7; las de captación y conversión (P3 y P4), de los hallazgos territoriales del Capítulo 6.

Palanca	Acción comercial	Universo	Ticket/año	Tasa éxito	Origen
P1 · Retención Núcleo (C1)	Customer Success a clientes C1 en riesgo	17	16.380 €	30 %	Cap. 7
P2 · Retención Grandes Cuentas (C2)	Atención individualizada a C2 en riesgo	9	70.640 €	30 %	Cap. 7
P3 · Captación Madrid	Captar perfil Núcleo en hueco territorial	127	16.380 €	8 %	Cap. 6
P4 · Conversión C4→C1 Italia	Convertir estacionales italianos a Núcleo	271	13.672 €	4 %	Cap. 6

Tabla 8.2. Las cuatro palancas del plan, su universo objetivo, ticket unitario anualizado (Cap. 5) y tasa de éxito asumida según benchmarks sectoriales.

Las tasas de éxito —30 % en retención dirigida (*Customer Success*), 8 % en captación B2B en frío y 4 % en conversión de cluster— son el parámetro más crítico e incierto del modelo, y se basan en benchmarks del sector. La palanca P1 incorpora explícitamente al cliente de máxima prioridad identificado en el Capítulo 7 (cliente 16352, Núcleo Estratégico, 19.608 € y recencia de 19 días), cuya retención justifica por sí sola la asignación de un gestor de cuentas.

P1 — Retención del Núcleo (C1). Sobre los clientes del Núcleo Estratégico que el modelo de churn señala en riesgo se activa un equipo de gestión de cuentas (*Customer Success*) que les presta atención preferente y resuelven proactivamente incidencias. **P2 — Retención de Grandes Cuentas (C2).** Misma lógica sobre las cuentas internacionales de mayor ticket (70.640 €/año), donde la acción no es automatizada sino presencial: visitas, eventos y atención individualizada. **P3 — Captación en Madrid.** El Capítulo 6 reveló que Madrid tiene una penetración del Núcleo nueve veces inferior a la del eje noroeste; cerrar ese hueco hasta la mediana nacional supone 127 clientes captables, sobre los que se activa un comercial dedicado con campañas geolocalizadas. **P4 — Conversión en Italia.** De los 271 Compradores Estacionales italianos, un partner comercial trabaja su conversión hacia el perfil de Núcleo, con un diferencial de ticket de 13.672 € por cliente convertido.

8.3 Cálculo del ROI

El modelo se apoya en tres fórmulas sencillas. Los **ingresos de cada palanca** son el producto de su universo por su tasa de éxito por su ticket anual; los **costes totales** suman partidas fijas y variables; y el **ROI** es el cociente entre el beneficio incremental y los costes:

Ingreso de palanca = Universo × Tasa de éxito × Ticket unitario | ROI = (Ingresos incrementales – Costes) / Costes

Palanca	Ingreso Opción 1	Ticket con uplift	Ingreso Opción 2
P1 · Retención C1	83.538 €	— (retención pura)	83.538 €
P2 · Retención C2	190.728 €	— (retención pura)	190.728 €
P3 · Captación Madrid	166.421 €	17.690 € (+8 %)	179.735 €
P4 · Conversión Italia	148.204 €	14.766 € (+8 %)	160.061 €
TOTAL ingresos incrementales	588.891 €		614.061 €

Tabla 8.3. Ingresos incrementales por palanca. La Opción 2 aplica un uplift de ticket del +8 % a P3 y P4 (donde el reenfoque por cluster tiene sentido), aportando ~25 K€ adicionales sin coste extra.

Los **costes del plan ascienden a 482.000 €**, repartidos entre partidas fijas (equipo e infraestructura) y variables (campañas y operación). Todas se basan en valores de mercado de España 2026 con fuentes

citables (salarios según Glassdoor con cargas sociales, infraestructura según tarifas públicas de proveedores cloud y SaaS de marketing).

Partida de coste	Importe	Categoría
Business Analyst · Customer Success Manager	105.000 €	Fijo
Comercial Madrid · Agente Italia	105.000 €	Fijo
Infraestructura Data + Email + CRM	12.000 €	Fijo
Campañas de marketing (medios)	100.000 €	Variable
Diseño, localización y visitas · samples y onboarding	125.000 €	Variable
Generales / administración / legal	35.000 €	Variable
TOTAL costes anuales (222 K fijos + 260 K variables)	482.000 €	—

Tabla 8.4. Costes anuales del plan comercial.

Aplicando la fórmula, el **ROI de la Opción 1 es del 22,18 %** $((588.891 - 482.000) / 482.000)$ y el de la **Opción 2 del 27,40 %**. Por cada euro invertido, el plan devuelve entre 1,22 € y 1,27 €.

8.4 Conexión con el Capítulo 7: matriz coste-beneficio

El vínculo formal con el modelo de churn del Capítulo 7 se establece mediante una matriz coste-beneficio sobre su matriz de confusión (umbral 0,35): se asigna un valor económico a cada celda y se calcula el retorno de actuar según las predicciones del modelo. Siendo V el valor anual del cliente objetivo, c el coste de intervención por cliente y r la tasa de retención, cada acierto en churner (TP) aporta $r \cdot V - c$, cada falsa alarma (FP) cuesta c y cada churner no detectado (FN) supone un coste de oportunidad de V.

Celda (Cap. 7, umbral 0,35)	Recuento	Valor económico unitario
TP · churner detectado	55	$r \cdot V - c$ (= 2.914 €)
FP · falsa alarma	50	$-c$ (= -2.000 €)
FN · churner no detectado	31	$-V$ (coste de oportunidad)
TN · no-churner correcto	429	0 €

Tabla 8.5. Valoración de la matriz de confusión del Capítulo 7 ($V = 16.380$ €, $c = 2.000$ €, $r = 30$ %).

Lectura económica

El valor neto de la intervención dirigida es de 60.270 € sobre un coste de 210.000 €, es decir, un ROI de la intervención del 28,7 %. La rentabilidad depende críticamente de V: con tickets bajos, $r \cdot V$ no cubre c. Esto justifica analíticamente que la retención se concentre en los clusters de mayor ticket (C1 y C2, palancas P1 y P2) y no en toda la cartera, y conecta el retorno del Capítulo 8 directamente con las predicciones del Capítulo 7.

8.5 Análisis de sensibilidad y el caso de la palanca P1

Como todo modelo económico descansa sobre hipótesis (las tasas de éxito), se realiza un análisis de sensibilidad que mide cuánto se mueve el ROI cuando cada parámetro varía entre un valor pesimista y uno optimista. Reconocer esta incertidumbre de forma explícita es señal de rigor.

Parámetro	Pesimista → ROI	Base → ROI	Optimista → ROI
Tasa éxito P1 (Retención C1)	15 % → 13,5 %	30 % → 22,2 %	45 % → 30,8 %
Tasa éxito P2 (Retención C2)	15 % → 2,4 %	30 % → 22,2 %	45 % → 42,0 %
Tasa éxito P3 (Captación Madrid)	4 % → 4,9 %	8 % → 22,2 %	15 % → 52,4 %
Tasa éxito P4 (Conversión Italia)	2 % → 6,8 %	4 % → 22,2 %	8 % → 52,9 %

Tabla 8.6. Sensibilidad univariante del ROI. Las palancas de captación (P3) y conversión (P4) son las más sensibles y, por tanto, las más críticas de calibrar en la ejecución real.

El modelo incorpora además un análisis de sensibilidad cruzada que explora simultáneamente las dos palancas más sensibles (P3 y P4) mediante un mapa de calor de combinaciones de tasas, en el que se marca visualmente la banda defendible 15-25 %. Aproximadamente el 13 % de las combinaciones caen dentro de esa banda; el resto queda o demasiado bajo (el plan no compensa) o demasiado alto (poco creíble). Esta herramienta permite responder en la defensa a cualquier combinación de hipótesis que plantee el tribunal —por ejemplo, una captación del 6 % en Madrid con una conversión del 3 % en Italia— leyendo directamente la celda correspondiente.

El caso de la palanca P1: ROI negativo en aislado

Analizada de forma individual, la palanca P1 (Retención del Núcleo) presenta un ROI negativo: 17 clientes objetivo, 5,1 retenidos efectivamente, 83.538 € de ingreso anual frente a 107.000 € de coste asignado (beneficio -23.462 €, ROI -21,9 %). No es un error, sino un hallazgo genuino: su universo es pequeño y la atención individualizada es cara. La recomendación de mantenerla se defiende por su **valor estratégico no capturado en un horizonte anual**: el valor de un cliente del Núcleo se libera durante varios años, el coste de reposición de una cuenta de ese tipo es 5-7 veces el de retención, y su pérdida tiene impacto reputacional. El modelo es anual; la realidad de la retención es plurianual.

8.6 Limitaciones, síntesis y cierre del TFG

El modelo asume varias simplificaciones que conviene reconocer. El ROI se calcula sobre ingresos (facturación) y no sobre margen de contribución (en textil el margen bruto típico del 30-40 % situaría el ROI sobre beneficio en una cifra menor pero aún positiva); las tasas de éxito son estimaciones sectoriales, no observaciones propias de Selmark; las cuatro palancas se tratan como independientes, sin capturar posibles canibalizaciones o sinergias; el horizonte es anual, lo que penaliza a P1; y la proyección B2B es inercial, frente a la proyección retail rigurosa del Anexo SARIMA. Todas son líneas naturales de mejora futura.

Síntesis del capítulo y del trabajo

El Capítulo 8 demuestra cuantitativamente que las técnicas analíticas desarrolladas a lo largo del TFG —segmentación (Cap. 5), geomarketing (Cap. 6) y churn predictivo (Cap. 7)— se traducen en un plan comercial con un retorno defendible del **22-27 % anual**, dentro del rango 15-25 % recomendado. El marco DO NOTHING / DO SOMETHING acredita que el plan aporta valor sobre el contrafactual de no actuar; el análisis de sensibilidad evidencia robustez frente a la incertidumbre; y el reconocimiento explícito de las limitaciones refuerza el rigor metodológico. Con ello, el trabajo cierra el círculo que abrió el Capítulo 1: convertir datos operacionales dispersos en decisiones comerciales cuantificadas.

Previsión de demanda · SARIMA

Material complementario · no forma parte de la exposición principal

Este anexo resume el modelo de series temporales desarrollado para anticipar la evolución de la facturación de Selmark. Se incorpora como material complementario del trabajo.

A.1 Planteamiento y modelo

La facturación semanal del cuatrienio 2022-2025 se modela mediante un SARIMA estacional sobre la serie transformada logarítmicamente, con un periodo anual de 52 semanas. El modelo seleccionado es $\text{SARIMA}(0,0,0)(1,1,0)[52]$ con logaritmo, que captura la fuerte estacionalidad anual característica del negocio mayorista por temporadas.




Figura A.1. Facturación anual observada (2022-2025) y previsión para 2026.

A.2 Selección del modelo

La búsqueda automática por criterio de información proponía un modelo con un AIC ligeramente mejor, pero se descartó por presentar coeficientes no significativos y violar la condición de invertibilidad. Se optó por un modelo más parsimonioso y estadísticamente válido.

Modelo	Resultado	Decisión
Ingenuo (grid search)	Mejor AIC, pero coeficientes no significativos y modelo no invertible.	Rechazado
$\text{SARIMA}(0,0,0)(1,1,0)[52]$ + log	Coeficientes significativos e invertible; capta la estacionalidad anual.	Seleccionado

A.3 Diagnóstico del modelo

La varianza de la serie está dominada casi por completo por la componente estacional (94,9 %), mientras que la tendencia es marginal. El diagnóstico de los residuos confirma la ausencia de autocorrelación, aunque no se alcanza la normalidad, atribuible a siete semanas anómalas asociadas a eventos comerciales




Figura A.2. Descomposición de la varianza de la serie semanal.

Prueba / métrica	Resultado	Lectura
Ljung-Box (autocorrelación)	No significativa	Residuos sin autocorrelación
Jarque-Bera (normalidad)	Significativa	Residuos no normales
Anomalías detectadas	7 semanas	Eventos comerciales puntuales
RMSE / MAE	136.757 / 98.954 €	Error de previsión semanal

A.4 Previsión para 2026

El modelo proyecta una facturación en torno a **15,95 M€** para 2026, coherente con un decaimiento sostenido de aproximadamente el **-2 % anual** observado en el histórico reciente.




Figura A.3. Previsión para 2026 con intervalos de confianza al 80 % y 95 %.

Interpretación. La amplitud de los intervalos de confianza (IC 95 % entre 6,9 y 37,1 M€) refleja una incertidumbre elevada, propia de una serie corta y muy estacional. La previsión debe leerse como una **tendencia orientativa** — ligera contracción del negocio— y no como una cifra exacta de planificación.