

Informe de decisiones metodológicas

Fase Silver → Gold

TFG Selmark — Análisis de cliente y geomarketing

Documento que registra las decisiones adoptadas para cada cuestión metodológica del proyecto, distinguiendo entre las resueltas con información del cliente y las asumidas de forma provisional con justificación técnica.

Introducción

Durante la construcción de la capa de datos limpios (Silver) del proyecto se identificaron diez cuestiones metodológicas distribuidas en tres bloques. Tres de ellas han quedado resueltas con información proporcionada por Selmark o mediante investigación complementaria documentada, tres con criterio operativo aplicado durante la propia fase Silver, y las cuatro restantes se han asumido de forma provisional siguiendo un razonamiento técnico defendible, dejando la posibilidad de ajustar el diseño si las respuestas posteriores del cliente o del tutorado modifican alguna asunción.

Cada decisión se documenta con cuatro elementos: una breve descripción de la situación detectada, la decisión tomada, su justificación técnica y la implicación práctica que tiene sobre la construcción de la tabla analítica gold.cliente_360 y los análisis posteriores. El documento constituye, por sí mismo, un anexo metodológico que podrá incorporarse a la memoria del TFG.

Convención de estados

Estado	Significado
RESUELTA	Cuestión cerrada con información proporcionada por Selmark o por el tutor.
APLICADA	Decisión técnica aplicada durante la fase Silver con criterio operativo defendible.
ASUMIDA	Asunción provisional basada en razonamiento técnico, susceptible de revisión.

Bloque 1. Modelado económico

1.1. Granularidad de la tabla de pedidos e interpretación de los importes

RESUELTA

Situación detectada

Durante la exploración se observó que cada identificador de pedido aparecía asociado a una sola línea (granularidad 1:1) y que en el 10,8 % de los casos el importe_total_pedido era mayor que el importe_total_linea. Esto generaba dudas sobre cómo calcular correctamente la facturación real del cliente.

Decisión tomada

Se utiliza **MAX(importe_total_pedido) agrupado por id_pedido** como referencia de la facturación real de cada pedido. La suma final por cliente se calcula sobre estos valores agregados (no sobre las líneas).

Por qué esta decisión

Selmark ha facilitado documentación interna que aclara que los campos terminados en **_pedido** (importe_bruto_pedido, importe_base_imponible_pedido, importe_total_pedido, importe_iva_pedido, importe_re_pedido) son **campos de cabecera**: contienen el total del pedido completo y se repiten idénticos en cada línea del pedido. La propia documentación advierte explícitamente que estos campos **no deben sumarse entre líneas del mismo pedido**, sino agregarse mediante MAX() o FIRST() agrupando por id_pedido. Esto confirma que la suma de importe_total_linea daría siempre un valor parcial y, por tanto, incorrecto, mientras que MAX(importe_total_pedido) refleja el importe real facturado al cliente.

Qué significa en la práctica

En gold.cliente_360, la facturación del cliente y métricas derivadas (CLTV, ticket medio) se calculan en dos pasos: primero se obtiene el importe único de cada pedido con MAX(importe_total_pedido) agrupado por id_pedido; después se suman estos importes por cliente. Lo mismo aplica a otras métricas económicas derivadas de campos de cabecera (importe_iva_pedido, importe_bruto_pedido).

1.2. Alcance funcional de la tabla de pedidos

ASUMIDA

Situación detectada

fact_lineas_pedido contiene 41.709 registros, frente a 2.870.570 de ventas_minoristas para el mismo periodo. No queda explícito qué tipos de operación llegan a cada tabla, lo que afectaba a la decisión sobre qué fuente utilizar para cada análisis.

Decisión tomada

Se asume que fact_lineas_pedido contiene únicamente **pedidos formalizados** (operaciones B2B y de canales corporativos digitales con importe en euros), mientras que ventas_minoristas recoge la operativa completa, incluyendo ventas al consumidor final.

Por qué esta decisión

La diferencia de volumen entre ambas tablas (un factor de 69x) descarta que se trate del mismo universo de operaciones. La estructura de fact_lineas_pedido (con id_pedido, fechas de pedido y entrega, importes en euros) es propia de un proceso comercial formalizado, mientras que ventas_minoristas tiene la estructura típica de un registro de movimientos de inventario (cantidades, tipos de operación que incluyen devoluciones, depósitos y muestras). Esta interpretación es coherente con la práctica habitual en sistemas ERP y permite usar cada tabla para el tipo de análisis al que su estructura mejor se adapta.

Qué significa en la práctica

Las dos tablas se tratan como fuentes complementarias y no equivalentes. La validación de esta asunción depende de la respuesta de Manuel, pero el diseño actual es reversible: si fuera necesario cambiar el criterio, solo afectaría a la definición de algunas variables económicas en gold.cliente_360, no a la arquitectura del proyecto.

1.3. Fuente de referencia para variables económicas y de comportamiento

APLICADA

Situación detectada

La tabla analítica cliente_360 necesita una fuente única y coherente para cada bloque de variables. Las dos tablas disponibles aportan información distinta y complementaria.

Decisión tomada

Se establece la siguiente división de responsabilidades: **fact_lineas_pedido es la fuente de las variables económicas en euros** (facturación, CLTV, ticket medio, IVA aportado), mientras que **ventas_minoristas es la fuente de las variables de comportamiento** (frecuencia de compra, recencia, mix de canal, ratio de devoluciones, estacionalidad).

Por qué esta decisión

Cada tabla cubre con solvencia el bloque al que se le asigna y carece de información para cubrir el otro. fact_lineas_pedido tiene importes en euros pero no representa toda la operativa; ventas_minoristas representa toda la operativa pero solo registra cantidades, no importes. La única forma técnicamente correcta de aprovechar la información disponible sin duplicar registros ni inventar datos es asignar cada tabla al bloque de variables que efectivamente puede sustentar.

Qué significa en la práctica

En gold.cliente_360 las variables se organizan en cinco bloques: identificación (dim_cliente), económico (fact_lineas_pedido), comportamiento por canal (ventas_minoristas), temporal (tiempo + ambas fuentes) y geográfico (mosaic). Esta arquitectura es trazable y reproducible.

Bloque 2. Interpretación y calidad de los datos

2.1. Codificación heterogénea del campo de provincia

RESUELTA

Situación detectada

El campo `codigo_provincia_cliente` presenta tres tipos de codificación distintos: códigos de provincia española de dos dígitos, códigos numéricos de tres dígitos asignables a países (410, 231, 471, etc.) y códigos ISO de letras (CAN, MD, NO, KR). Adicionalmente, 238 clientes presentan el valor textual 'null' en este campo, lo que en una primera versión de `silver.dim_cliente` provocaba que fueran clasificados como INTERNACIONAL aunque en realidad fueran españoles.

Decisión tomada

Se han refinado las reglas de clasificación de `tipo_mercado` en `silver.dim_cliente` añadiendo una **Regla C** que rescata como NACIONAL a los clientes con código de provincia no informativo (NULL real o texto 'null') pero con código postal español válido de cinco dígitos en el rango 01000-52999. Adicionalmente se ha construido la tabla auxiliar **`silver.mapeo_paises`**, que asigna a cada código de provincia internacional un país concreto a partir del análisis de localidades y patrones de código postal.

Por qué esta decisión

La investigación complementaria documentada en el notebook 03b ha permitido identificar el país de origen de 53 grupos distintos a partir de evidencia objetiva: nombres de localidades reconocibles y formatos de código postal característicos de cada país. La Regla C, basada en patrones numéricos del código postal, ha permitido recuperar 213 clientes españoles previamente clasificados como internacionales por tener el campo de provincia con el valor textual 'null', llevando la cartera nacional de 1.869 a 2.082 clientes (+11,4 %). El mapeo de países cubre el 97,8 % de la cartera internacional, dejando un residuo de 31 clientes con datos incompletos como caso documentado.

Qué significa en la práctica

La cartera nacional final asciende a 2.082 clientes y la cobertura MOSAIC alcanza el 97,2 % sobre esta cartera (2.024 cruces validados). La cartera internacional cuenta con país identificado para 1.356 de 1.387 clientes, lo que permite construir un análisis comercial por país en la sección específica de la cartera internacional. Las tablas resultantes son `silver.dim_cliente` (refinada) y `silver.mapeo_paises` (nueva tabla auxiliar).

2.2. Clientes españoles con código de provincia de tres dígitos

APLICADA

Situación detectada

Se identificaron 24 clientes con código de provincia formato tres dígitos (036, 028) cuya dirección y localidad corresponden a territorio español. Entre ellos figura el propio registro de SELMARK, S.L.U.

Decisión tomada

Se confía en la lógica automática de tipo_mercado, que ya clasifica correctamente a estos 24 clientes como NACIONAL al comparar los dos primeros dígitos del código postal con el código de provincia.

Por qué esta decisión

La lógica implementada en silver.dim_cliente no se limita al código de provincia, sino que verifica la coincidencia con el código postal. Los 24 clientes detectados tienen códigos postales españoles válidos (5 dígitos) cuyos dos primeros dígitos coinciden con la provincia real, por lo que la clasificación es correcta sin necesidad de tratamiento especial. Que SELMARK figure así no afecta a los análisis, ya que no se trata de un cliente activo del análisis.

Qué significa en la práctica

No se requiere acción adicional. La incidencia queda documentada para trazabilidad.

2.3. Fiabilidad del campo fecha_entrega

APLICADA

Situación detectada

Se identificaron 116 registros con fecha de entrega anterior a la del pedido y 2.199 registros con fecha de entrega posterior en más de 180 días. La naturaleza exacta del campo (objetivo, prevista, real) no consta documentada.

Decisión tomada

Se aplica el filtro **[0, 180] días** sobre la diferencia entre fecha_entrega y fecha_pedido. Los registros fuera de este rango quedan con la columna derivada dias_hasta_entrega = NULL. El KPI de días hasta entrega se calcula solo sobre los registros con valor válido.

Por qué esta decisión

El rango [0, 180] descarta valores claramente anómalos (entregas anteriores al pedido y demoras de más de seis meses, ambos casos físicamente improbables en el sector). El filtro conserva el 97,6 % de los registros, manteniendo una base muestral suficientemente representativa para construir indicadores de servicio. No se descartan los registros completos: solo se marca como NULL el campo derivado, preservando toda la información económica y de cliente.

Qué significa en la práctica

En gold.cliente_360, el indicador 'media de días hasta entrega' por cliente se calcula con AVG() ignorando NULL automáticamente, lo que produce un KPI fiable y comparable entre clientes.

2.4. Relación entre los tipos de pedido «Temporada» y «Repetición»

RESUELTA

Situación detectada

Los dos tipos de pedido más voluminosos en ventas_minoristas son Temporada (1,6 millones de registros, 55,9 %) y Repetición (615 mil registros, 21,4 %). Ambos cubren aproximadamente la misma cartera de unos 2.500 clientes, lo que generaba dudas sobre si se trataba de canales independientes o de fases del mismo proceso.

Decisión tomada

Se agrupan ambos tipos como un **único canal B2B** en la variable tipo_cliente de gold.cliente_360. Se conserva el campo id_tipo_pedido original como variable auxiliar para construir la métrica **ratio_repeticion** (porcentaje de operaciones de cada cliente que son de repetición).

Por qué esta decisión

Se ha confirmado que el tipo Repetición corresponde a clientes B2B que vuelven a pedir, típicamente para reponer stock tras la campaña inicial registrada como tipo Temporada. Ambos tipos describen el mismo proceso comercial (cliente B2B haciendo pedidos a Selmark) en distintas fases. La conservación de la distinción como variable auxiliar permite construir una métrica rica para el clustering: el ratio de repetición es un indicador directo de fidelidad y consumo regular del producto.

Qué significa en la práctica

En gold.cliente_360 los clientes con operaciones en Temporada o Repetición se etiquetan como tipo_cliente = 'B2B'. La variable ratio_repeticion entra como predictor de fidelidad en los análisis de clustering y modelización del churn.

2.5. Naturaleza de las cuentas asociadas a canales digitales

ASUMIDA

Situación detectada

Los canales Ecommerce (111.233 operaciones, 5 clientes), Depósito (140.135 operaciones, 6 clientes) y ECI (92.678 operaciones, 8 clientes) presentan un volumen muy elevado concentrado en muy pocos clientes únicos, lo que sugiere que se trata de cuentas corporativas únicas que agrupan las ventas a consumidores finales.

Decisión tomada

Se crea el flag **es_cuenta_corporativa** (TRUE si el cliente pertenece a Ecommerce, Depósito o ECI) en gold.cliente_360. Estas cuentas se **excluyen del clustering principal** y se analizan en una sección específica.

Por qué esta decisión

Estas cuentas no son comparables con clientes B2B reales: un cliente B2B representa un comercio minorista que compra al por mayor para revender, mientras que una cuenta corporativa digital agrega miles de ventas al consumidor final. Si entraran en el clustering general, su volumen las llevaría a dominar uno o varios clusters y distorsionaría la segmentación. El tratamiento separado preserva la calidad analítica del segmento B2B y permite, en paralelo, un análisis específico del peso de cada canal digital.

Qué significa en la práctica

El clustering y los análisis de fidelidad se ejecutan sobre la cartera B2B clásica. La sección de análisis de canales digitales se construye con las cuentas marcadas como `es_cuenta_corporativa = TRUE`, centrada en evolución de volumen, estacionalidad y mix de producto.

Bloque 3. Cuestiones operativas y de alcance

3.1. Tratamiento diferenciado de cartera nacional e internacional

ASUMIDA

Situación detectada

La cartera activa se compone, tras el refinamiento descrito en la consulta 2.1, de 2.082 clientes nacionales y 1.387 internacionales. El análisis geomarketing se apoya en MOSAIC, que solo cubre territorio español, lo que sugiere un tratamiento diferenciado entre ambos segmentos.

Decisión tomada

Se adopta un **enfoque dual**: la cartera nacional será la población objetivo del análisis técnico (segmentación, geomarketing, modelización de fidelidad), mientras que la cartera internacional se reservará para una **sección específica de análisis comercial** (peso de mercados, ticket medio comparativo, principales países por facturación).

Por qué esta decisión

MOSAIC, herramienta clave del geomarketing, solo está disponible para códigos postales españoles, lo que convierte a la cartera nacional en la única población técnicamente analizable con geomarketing. La cobertura efectiva del cruce `dim_cliente × mosaic` alcanza el 97,2 % sobre la cartera nacional refinada, una base sólida para los análisis de clustering y segmentación. Por otro lado, los mercados internacionales son demasiado heterogéneos (lengua, regulación, hábitos de consumo, divisas) para integrarlos en un análisis técnico unitario. Sí tiene sentido, en cambio, ofrecer una lectura comparativa de su aportación al negocio, apoyada en la tabla `silver.mapeo_paises` que asigna país a 1.356 de los 1.387 clientes internacionales.

Qué significa en la práctica

Los notebooks de clustering, geomarketing y churn (a partir del 11 hacia delante) filtran por `tipo_mercado = 'NACIONAL'`. El notebook de análisis de negocio incluye una sección específica para la cartera internacional con sus propios indicadores, agregando por país a través del cruce con `silver.mapeo_paises`.

3.2. Clientes presentes en operaciones de venta sin registro en el maestro

APLICADA

Situación detectada

Se detectaron 3 identificadores de cliente (32211, 4753, 2443) presentes en silver.ventas_minoristas pero ausentes de silver.dim_cliente. En total acumulan 273 registros (0,01 % del volumen total), concentrados en uno o dos días concretos, lo que apunta a altas puntuales no consolidadas en el maestro.

Decisión tomada

Se ejecuta un **LEFT JOIN** entre las tablas de hechos y dim_cliente. Los tres clientes huérfanos aparecen en gold.cliente_360 con valores NULL en los atributos descriptivos del maestro.

Por qué esta decisión

Eliminar registros válidos de operaciones por la ausencia de un maestro consolidado sería un sesgo evitable. El uso de LEFT JOIN preserva la totalidad de la información transaccional y la imposibilidad de enriquecerla con maestro queda explícita como NULL, lo cual es trazable y auditable. El volumen es despreciable (0,01 %) por lo que no compromete la representatividad del análisis.

Qué significa en la práctica

Estos tres clientes aparecerán en cualquier conteo de ventas pero quedarán fuera de análisis que requieran datos del maestro (clustering, geomarketing). Es el comportamiento metodológicamente correcto, no requiere acción adicional.

Resumen y próximos pasos

De las diez cuestiones planteadas, tres han quedado **resueltas**: la cuestión sobre los importes de cabecera gracias a la documentación del modelo de datos facilitada por Selmark; la relación entre los tipos Temporada y Repetición gracias a la confirmación del responsable de proyecto; y la codificación heterogénea del campo de provincia mediante una investigación complementaria (notebook 03b) que ha permitido refinar las reglas de clasificación de tipo_mercado y construir la tabla auxiliar silver.mapeo_paises. Tres cuestiones han quedado **aplicadas** con criterio operativo durante la propia fase Silver (los clientes españoles con código de provincia de tres dígitos, la fiabilidad de fecha_entrega y los clientes huérfanos). Las cuatro restantes se han **asumido** de forma provisional con razonamiento técnico documentado.

Tras el refinamiento de silver.dim_cliente, la cartera nacional asciende a 2.082 clientes (frente a los 1.869 iniciales, un incremento del 11,4 %) y la cobertura MOSAIC sobre esta cartera alcanza el 97,2 %, una base sólida para los análisis posteriores. La cartera internacional cuenta con país identificado para el 97,8 % de los clientes a través de la nueva tabla silver.mapeo_paises.

Con este conjunto de decisiones, el proyecto avanza a la construcción de gold.cliente_360 sin bloqueos. Si las respuestas posteriores del tutor o del cliente modificaran alguna de las asunciones, los ajustes necesarios se limitarían a la definición de variables específicas dentro de gold.cliente_360 y no afectarían a la arquitectura del proyecto ni a la fase Silver, que queda cerrada y validada.

Las cuestiones asumidas se revisarán en cuanto haya información adicional disponible y, en su caso, se actualizará este documento con las decisiones definitivas. Las decisiones documentadas aquí constituyen la base metodológica con la que se inicia la fase de construcción de la tabla analítica del cliente.